◆ DRAGONAI · 烛龙智元

AI FDE 工程师就业实训营

学生讲义

Day 1

认知与环境

AI 发展史与大模型格局，模型选型与成本测算，工具链装机

目录

学习目标 1

01 开营与 FDE 岗位 1

1.1 开营第一问 1

1.2 FDE 岗位 1

1.3 招聘启事拆解 2

1.4 智与能 3

1.5 人工智能的含义 3

1.6 强 AI 与弱 AI 4

1.7 十天的路线与学法 4

1.8 预热五问 4

02 AI 发展史与期望管理 5

2.1 AI 出生前的准备 5

2.2 图灵测试与中文屋 6

2.3 达特茅斯会议 6

2.4 七十年速览 7

2.5 第一次浪潮与寒冬 7

2.6 第二次浪潮与寒冬 8

2.7 从深蓝到 AlphaGo 8

2.8 知识来源与三大学派 9

2.9 寒冬的公式 9

2.10 规模与涌现 10

2.11 大模型时间轴 11

03 大模型白话原理 12

3.1 生成式 AI 与基本名词 12

3.2 Token 与词嵌入 13

3.3 注意力与 Transformer 15

3.4 自回归与温度 16

3.5 预训练与对齐 17

3.6 上下文窗口与推理模型 17

3.7 一句话的旅程 19

3.8 一本正经的错与幻觉 19

3.9 多模态与文生图 20

04 能力边界与责任 21

4.1 能力的双刃剑 21

4.2 给客户设预期 21

4.3 隐私泄露的路径 22

4.4 深度伪造 23

4.5 电车难题 23

4.6 一线合规常识 24

4.7 负责任的 AI 24

4.8 午饭思辨题 24

05 二〇二六年大模型格局 25

5.1 三层格局 25

5.2 闭源三家 25

5.3 开源梯队与商用条件 26

5.4 国产模型的落地优势 26

5.5 补全型与代理型工具 27

5.6 平台注册与信息渠道 27

06 模型选型与成本测算 28

6.1 训练成本的量级 28

6.2 没有免费的午餐定理 28

6.3 横评案例与榜单口径 29

6.4 性价比象限 29

6.5 模型体积与显存估算 30

6.6 选型五问 31

6.7 月账单与价目表 31

6.8 API 与私有化 33

6.9 模型能力的增强路线 33

6.10 微调方式 34

6.11 检索增强生成 35

07 工具链装机 36

7.1 装机清单 36

7.2 VSCode 编辑器 36

7.3 第一位 AI 同事 37

7.4 CC Switch 切换器 37

7.5 常用命令行 37

7.6 国内镜像 38

7.7 环境隔离与虚拟环境 38

7.8 git 版本控制 39

7.9 装机自救与提问 39

7.10 提示词的两层结构 40

7.11 首次对话示例 40

08 下午实践：本地 HTML 网页 41

8.1 下午任务 41

8.2 三层验收细则 42

8.3 起手式清单 42

8.4 常见的坑与解法 42

8.5 收尾与明日预告 43

练习与作业 43

复习题 43

课后作业 44

学习目标

第一天先建立对 AI 的整体认识，再安装日常开发要用的工具链，最后用 Claude Code 交付第一件作品，即一个单文件 HTML 个人主页。

1. 说明 FDE 岗位的工作内容与市场需求，以及十天课程怎样围绕这个岗位安排。
2. 以“知识从哪里来”为主线，复述 AI 七十年里的三次浪潮与两次寒冬，并写出寒冬的成因。
3. 用通俗的语言说明大模型的工作原理，包括 token 与词嵌入，注意力与 Transformer，预训练与对齐。
4. 解释大模型产生幻觉的原因，说明隐私，深度伪造与合规方面的风险，并写出给客户设预期的三句话。
5. 区分闭源模型，开源模型与工具层，说明选型为什么要按任务实测，并按“业务量 → token 量 → 单价 × 用量 = 月账单”估算成本。
6. 完成工具链装机，用 Claude Code 做出个人主页，并通过跑通，看懂与能改三层验收。

01
开营与 FDE 岗位

1.1 开营第一问

人工智能的英文是 Artificial Intelligence，简称 AI。AI 已经会写代码，会做设计，也会读文档。开营的第一个问题由此而来：既然 AI 已经具备这些能力，企业为什么还要雇人。

换一个角度看，问题就具体了。AI 的能力已经过剩，缺的是把 AI 接入一家具体公司的人。企业缺的不是模型，而是能把模型变成生产力的人，学员将来要做的就是这个岗位。

本营的信条是“一个人的力量，不取决于他自己多强，而取决于他能调动多少个 AI 协同工作”。第一天的目标分三步：先建立认知坐标系，再装好日常工作要用的工具链，最后交付第一件作品。认知坐标系指对 AI 的整体认识，既包括 AI 的历史与原理，也包括 AI 的能力边界与市场格局。

1.2 FDE 岗位

FDE 是 Forward-Deployed Engineer 的缩写，中文叫前线部署工程师，指驻在客户身边负责 AI 落地的工程师。国内的招聘启事里，这个岗位常叫解决方案工程师，交付工程师或大模型应用工程师。FDE 一半是工程师，负责搭建能上线的应用。另一半是交付者，负责听懂需求，管理好客户的预期。

这个岗位缺人，原因在于模型能力每年都在大幅提升，而会用模型的企业远少于想用模型的企业。FDE 这个名称源自 Palantir 公司。图中是该公司官网的招聘页，一行行职位名称都以 Forward Deployed 开头，名称下方标着各自的工作城市。

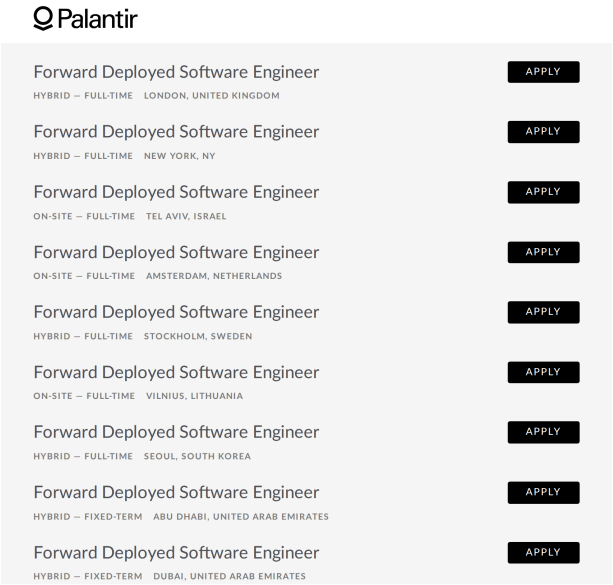


图 1　FDE 这个名称源自 Palantir。来源：官网截图。

驻场交付周里的一个典型工作日，可以帮助学员直观地认识这个岗位。上午在客户会议室，业务方提出“想要个 AI 客服”，FDE 要把这句话拆解成具体需求：接入什么渠道，回答哪些问题，答错了由谁兜底。午后回到工位，修改提示词，调整知识库，把上午拆出的需求做成可以演示的 Demo。傍晚向客户演示，并管理好预期：说明能做到什么，暂时做不到什么，下周交付什么。全天还会穿插一些零散的追问，例如“会不会泄露数据”和“这条为什么答错”，第一天上午所学的认知内容，就是回答这类追问的依据。

FDE 的工作一半是写代码，一半是做翻译，在业务语言和技术语言之间来回转换。十天之后，学员去面试的就是这类岗位，本营的全部内容都按这个岗位的要求反推设计。

1.3　招聘启事拆解

职位描述的英文是 Job Description，简称 JD。把市面上 FDE 类 JD 的高频要求归纳起来逐条对照，就能看清市场需要什么样的人。表中第二列是每条要求的通俗解释，第三列是本营对应的课程日，D3 表示第三天，其余类推。

JD 高频要求	通俗解释	本营对应
大模型应用开发经验	会用 API 搭建能上线的应用	D3 后端与 D6 工作流
熟悉 RAG 与知识库	会把企业文档变成 AI 可以查阅的资料	D4 全天
了解 Agent 框架	会让 AI 自己调用工具完成任务	D7 上午
私有化部署能力	会在客户机房里部署模型	D5 全天
客户沟通与需求分析	能听懂业务需求，能写出方案	D8 到 D10

读 JD 时，每一条要求都要能对应到自己的一件作品，能指着作品说“这个我做过”。这十天积累的就是这些作品。表里几乎没有一条要求“发过论文、训过模型”，市场看重的是把模型用到业务里的能力。

1.4 智与能

早在两千年前，荀子就为“智能”写好了一份岗位说明书。荀子在“正名篇”里写道：“知有所合谓之智，能有所合谓之能。”荀子把智能拆成两部分：智在内，指知识与思考，能在外，指动手与行动。

对应到今天，大语言模型对应智，英文是 Large Language Model，简称 LLM。智能体对应能，英文是 Agent。FDE 就是把智与能接在一起，再交付给企业的人，所以这个岗位要求又智又能。

第一天先讲认知，再练工具，理由在一句古话里：“有道无术，术尚可求；有术无道，止于术。”道指对事物的认识与方法，术指具体的技能，上午修道，下午练术。

1.5 人工智能的含义

人工智能不是一种单一的技术，而是一族技术，人的每一类智能都在被逐一模拟。加德纳在 1983 年的“智能的结构”里提出多元智能理论，把人的智能分成七类，每一类都有对应的人工智能技术。表中的 NLP 是自然语言处理的英文缩写，第三列是本营哪一天会接触到这类技术。

人的智能	对应的人工智能	接触时间
语言智能	NLP 与大语言模型	D1 起每天
逻辑数理智能	定理证明与代码生成	D2 到 D3
空间智能	机器视觉与图像生成	D3 多模态 API
音乐智能	语音识别与音频生成	D3 语音接口
身体运动智能	机器人与自动驾驶	课外延伸
人际智能	对话系统与情感计算	D4 智能客服
内省智能	Agent 的自我反思	D7

人工智能有四个经典定义，分别出自四位学者：

- 麦卡锡：让机器的行为，看起来像人所表现出的智能行为。
- 明斯基：让机器去做那些过去只有人的智能才能做到的事。
- 尼尔逊：关于知识的表示，获取与使用的学科。
- 温斯顿：研究如何让计算机做过去只有人才能做的智能工作。

今天通行的表述是：人工智能是“模拟、延伸和扩展人的智能的理论、方法、技术及应用系统”。面试中常考三个概念的关系：人工智能包含机器学习，机器学习又包含深度学习。

1.6 强 AI 与弱 AI

强 AI 指机器拥有心智与通用智能，至今只存在于论文与科幻作品里。**弱 AI** 指在具体任务上替代或超越人，人脸与车牌识别，下棋和聊天，都属于弱 AI。ChatGPT 同样不是强 AI，只是处理语言的弱 AI，并没有自我意识。

按能力排成一条谱系，左端是弱 AI，也就是专用智能，人脸识别，下棋与 ChatGPT 都在这一段。中段是强 AI，也叫 AGI，即通用智能，目前尚未实现。右端是 ASI，即超级智能，属于科幻与假设。今天所有落地的 AI，全部在左端。

FDE 要把客户的科幻想象拉回工程现实。客户想要“什么都会的 AI”，FDE 要把这个要求翻译成“几个具体任务的弱 AI 组合”。方案的底线是：AGI 何时到来，没有人能确定，所以方案里永远不要承诺还不存在的东西。

1.7 十天的路线与学法

十天的课程分成两段，每天下课都有一件实际产出。D1 到 D5 是能力构建，路线是“环境 → 前端 → 后端 → RAG → 部署”，贯穿一条智能客服主线。D6 到 D10 是产品化与就业，路线是“工作流 → Agent 与评测 → Demo Day → 简历与面试”。大作业在 D5 领题，题目来自真实的客户业务，周末与 D6，D7 的下午用来开发，D8 全天验收。

学习方法是一架三级的梯子：模仿，改写与编写，这是许多工程师验证过的公共经验。模仿指照着做，先让程序运行起来，这一级允许不求甚解。改写指改动一处，观察结果有什么变化，理解往往出现在“改坏了”的那一刻。编写指从空白文件开始，做出自己的版本，到这一级，作品才真正属于自己。每天下午的实践也按这三级安排：上手任务对应模仿，进阶任务对应改写，大作业对应编写。

从第一天起要养成两个习惯。第一个习惯是把报错当作教材，读完报错信息再提问。第二个习惯是先问 AI，再核实，概念不必死记，要学会提问。每天开课前还有 10 分钟的“AI 快讯轮值”，由学员轮流介绍行业动态，目的是让学员持续关注行业信息。

1.8 预热五问

预热五问是贯穿十天的五个问题。每一问都标了收口日，也就是用作品完整回答这一问的日子，在此之前，各天的课程会逐步积累答案。

编号	问题	收口日
Q1	“AI 都能写代码了，企业为什么还雇你？你卖的是什么？”	D8，D9
Q2	“客户问‘你们的 AI 会不会出错’，你怎么答？”	D7
Q3	“同一个任务，选 GPT 还是 DeepSeek？凭什么？”	D1 上午
Q4	“客户数据绝不能出公司，方案怎么做？”	D5
Q5	“你没有 AI 行业经验，凭什么要你？”	D10

这五个问题，面试官会问，客户也会问，FDE 将来每天都会遇到。

小结

FDE 的职责是把 AI 落地到客户的业务里，工作一半是开发，一半是在业务与技术之间做翻译。市场缺的是能把模型接入业务的人，招聘要求看重的也是亲手做出的作品。今天落地的 AI 都属于弱 AI，向客户承诺的只能是具体任务的组合。十天的学习按模仿，改写与编写三级推进，预热五问的答案会在各自的收口日用作品给出。

02
AI 发展史与期望管理

2.1 AI 出生前的准备

AI 在 1956 年得名之前，已经有了理论，机器与思想三方面的准备。1936 年，图灵提出图灵机，划定了“可计算”的边界，这是理论准备。1946 年，第一台通用电子计算机 ENIAC 在宾夕法尼亚大学诞生，这是机器准备。1951 年，明斯基造出第一台神经网络计算机，“学习”从此进入机器，这是思想准备。

图灵机的英文是 Turing Machine，出自图灵 1936 年的论文“论可计算数”，是一切计算机的理论模型。图灵机是由“纸带 + 读写头 + 规则表 + 状态 + 移动”五个部件构成的抽象计算模型。凡是可计算的问题，图灵机都能算，所以图灵机划定了计算的边界。图中下方的长条是纸带，格子里写着 0 和 1，读写头停在标红的那一格。图里只画了纸带，读写头与程序三样，规则表和当前状态都装在上方的程序里，移动指读写头沿纸带逐格左右移动。

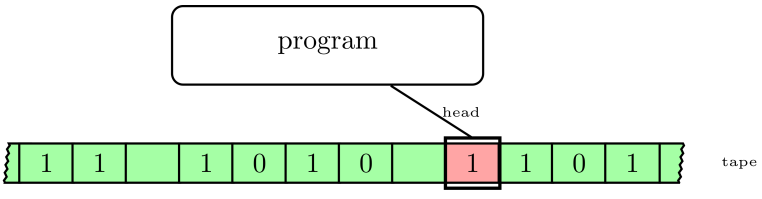


图 2　图灵机的组成：纸带，读写头与程序。来源：CC 转引。

图灵机是可计算性的数学模型，冯诺伊曼机是存储程序的工程模型，面试中常把两者放在一起比较。“AI 之父是谁”也有两个答案：理论之父是图灵，命名之父是麦卡锡。从 FDE 的视角看，“理论上能算”与“工程上算得动”是两回事，AI 的每一次寒冬都源于两者之间的差距。

2.2 图灵测试与中文屋

图灵测试的英文是 Turing Test，由图灵在 1950 年提出，形式是一场模仿游戏。人类 A 和机器 B 隔着屏幕回答问题，两边只传文字。裁判 C 只看回答，判断哪一个是人，如果分辨不出，就算机器通过。

30% 这个数字，本是图灵对 2000 年的预测：到那时，机器能让约 30% 的裁判分辨不出人和机器。2014 年，聊天程序 Eugene Goostman 让 33% 的裁判分辨不出，首次“通过”测试。这里的通过要加引号，因为 30% 只是图灵当年的预测，并不是测试规定的标准。

逆向图灵测试就是日常使用的滑块验证码，这一回是机器在判断屏幕前的是不是人。中文屋由塞尔提出：一个人只按规则搬运符号，这样算不算“理解”。这个问题没有标准答案，留作午饭时的讨论题。

这三个典故三十秒就能讲完，面试中聊到“AI 的边界”时，可以借这三个典故从容作答。

2.3 达特茅斯会议

1956 年是现代 AI 元年，人工智能在这一年的达特茅斯会议上得名。1955 年 8 月，麦卡锡联合明斯基，香农与罗切斯特四人联名提案，提案中首次写下 Artificial Intelligence 一词，即人工智能。会议由洛克菲勒基金会出资，1956 年夏天，与会学者在达特茅斯研讨“模拟人的智能”。

与会者的阵容很强：其中有 4 位图灵奖得主，西蒙还获得了诺贝尔经济学奖，另有信息论之父香农与机器感知之父塞弗里奇。照片里每位学者旁都标出了姓名与身份，可以对照找出四位图灵奖得主。



图 3　达特茅斯会议部分与会学者的合影，照片上标出了姓名与身份。来源：转引。

然而这样一批顶尖学者，也没能控制住世界对 AI 的期望，代价体现在后来的两次寒冬里。

2.4 七十年速览

从 1956 年到今天，AI 经历了三次浪潮与两次寒冬。年表从达特茅斯会议排到学员入行之前，第三列标出每个年份所处的阶段。

年份	事件	阶段
1956	达特茅斯会议，次年感知机问世	第一次浪潮起
1965	DENDRAL：第一个专家系统	
1973	莱特希尔报告：“只能解决玩具问题”	第一次寒冬
1980	XCON 专家系统商用，1986 年出现 BP 算法	第二次浪潮起
1987	Lisp 机市场崩盘，五代机随后未达目标	第二次寒冬
1997	深蓝胜卡斯帕罗夫，LSTM 提出	
2006	辛顿让深层网络可以训练，次年 ImageNet 立项	第三次浪潮起
2012	GPU 算力突破，深度学习起飞	
2016	AlphaGo 胜李世石	
2017	Transformer：Attention Is All You Need	
2022	ChatGPT 发布，大模型时代到来	全面爆发
2024	Sora 文生视频，DeepSeek 登场	学员入行之前

表中的 BP 算法即反向传播算法，LSTM 即长短期记忆网络，两者都是神经网络的重要技术。前两次浪潮都以寒冬收场，第三次浪潮从 2006 年开始，到 2022 年全面爆发。

2.5 第一次浪潮与寒冬

第一次浪潮由感知机点燃。1957 年，罗森布拉特提出感知机，英文是 Perceptron。罗森布拉特造的 Mark I 感知机用光电单元“看”字母，自动调整权重，是第一台从样例中学习的机器。当时的“纽约时报”写道，Mark I 是“能走路、说话、看东西、写字的电子计算机的胚胎”。

1969 年，明斯基与佩珀特出版“感知机”一书，证明单层网络连“异或”都学不会，热潮随之降温。异或是一种简单的逻辑运算，两个输入不同时输出真，相同时输出假。媒体过度宣传，数学研究指出局限，研究经费随之撤退，这个过程后来还会重演。

第一次寒冬始于 1973 年的莱特希尔报告。英国政府委托评估 AI 近二十年的成果，报告的结论只有一句话：AI“只在玩具问题上成功”，离承诺的通用智能还很遥远。技术上的根本原因是组合爆炸，英文是 Combinatorial Explosion，指搜索空间随问题规模呈指数增长，当年的算力无法处理真实规模的问题。结果是英国基本停止了 AI 经费，美国随后收缩。此后十年，研究者申请经费时都尽量避开“AI”这个词。

由此可以记下一条铁律：预算的耐心只有几年，承诺必须落在预算周期内能交付的成果上。今天客户问“多久见效”时，答案要以周或月为单位，依据就是这条铁律。

2.6 第二次浪潮与寒冬

第二次浪潮的主角是专家系统，AI 第一次成为生意。**专家系统**的英文是 Expert System，由知识库与推理引擎构成：知识库里是一条条“if–then”规则，推理引擎按规则推导结论。专家系统的历史从 1965 年的 DENDRAL 算起，里程碑还有 MYCIN 与 XCON。1980 年，XCON 投入商用，为 DEC 公司配置订单，每年节省数千万美元，第二次浪潮由此兴起。1982 年，日本的“五代机”计划立项跟进。

这段历史说明：AI 不必“通用”也能创造商业价值，用专用系统解决具体问题，到今天仍是正确的路线。

第二次寒冬从 1987 年持续到 1993 年，问题出在维护成本上。Lisp 机是专门运行 Lisp 语言的计算机，当时多用于 AI 研究。1987 年，专用 Lisp 机的市场一夜崩盘，因为通用工作站和 PC 更便宜，也更快。专家系统自身还受困于知识获取瓶颈：规则要靠工程师访谈专家后逐条手写，规则越积越多，写不完，改不完，彼此还会冲突。1992 年，五代机计划未达目标而结束，第二次寒冬随之席卷全球。

对 FDE 来说，系统上线只是开始，维护成本往往是项目失败的首要原因，报价时要把维护成本算进去。

2.7 从深蓝到 AlphaGo

1997 年 5 月，IBM 的深蓝以 3.5 比 2.5 战胜国际象棋世界冠军卡斯帕罗夫，机器首次战胜人类棋王，这是符号主义的巅峰之战。深蓝靠的不是“理解棋”，而是每秒搜索约两亿个局面，再加上大师手写的评估函数与开局库。深蓝不会下围棋，也不会下跳棋。作为纯粹的专用智能，深蓝换一个任务就得从零开始。

第三次浪潮靠算法，数据与算力三个条件同时到位，缺了任何一个都发展不起来，这三个条件常被比作三支箭。算法方面，2006 年，辛顿让“深”层网络第一次能够训练，深度学习由此得名。数据方面，2009 年，李飞飞的 ImageNet 上线，通过众包标注积累了 1400 万张图片。算力方面，2012 年，AlexNet 用两张游戏显卡训练，网络拆成上下两条流水线，分别在两张显卡上运行，图像识别的错误率从 26% 降到 16%。

GPU 原本是为游戏设计的，通用算力外溢到其他领域，是技术浪潮里常见的情形。前两次浪潮失败于“想法超前于资源”，这一次，资源终于追上了想法。

2016 年 3 月，即深蓝之后十九年，AlphaGo 以 4 比 1 战胜李世石。围棋的局面数远超宇宙中的原子数，靠暴力搜索行不通。AlphaGo 结合了三条技术路线：用神经网络评估局面，用树搜索选择着法，再用自我对弈的强化学习提升棋力，强化学习的英文缩写是 RL。第二局第 37 手让解说员直呼“非人类”，机器第一次展示出自己的“棋风”。

深蓝赢在“算得多”，AlphaGo 赢在“学得会”。AlphaGo 也说明，现代 AI 系统都是混合系统，FDE 将来的方案同样如此，大模型，检索与规则各取所长。

2.8 知识来源与三大学派

回顾七十年的 AI 史，可以抓住一条主线：知识从哪里来。按这条主线，AI 史分成推理期，知识期与学习期三段。

时期	年代	思路	瓶颈
推理期	1956 年到 70 年代	智能等于逻辑推理，于是教机器推理	只会推理，缺少知识
知识期	70 年代到 90 年代	智能等于知识，由人工把知识灌进去	知识写不完，也维护不起
学习期	90 年代至今	智能等于学习，让机器从数据中自己学	数据与算力的军备竞赛

三次转段，转的都是同一个问题：知识从哪里来。人工写不完，只好让机器自己学。面试中被问到“AI 发展脉络”时，不必背年份，讲清这条“知识来源”主线，高下立判。

同一段历史也可以按学派来看，三大学派各自模拟人的不同方面。

学派	模拟对象	技术路线	短板	代表作
符号主义	人的心智	知识表示加逻辑推理	脆弱，跟不上变化	专家系统与深蓝
联结主义	大脑的结构	神经网络，从数据中学习	黑盒，耗费算力	AlexNet 与 ChatGPT
行为主义	人的行为	强化学习，在试错中获得奖惩	试错成本高	AlphaGo 与自动驾驶

今天的主流是联结主义，英文是 Connectionism。联结主义的短板是黑盒，客户问“AI 为什么解释不了自己”，原因就在这里。需要可解释性的工作，例如风控与合规校验，仍然由符号主义负责，符号主义的英文是 Symbolism，常见做法是用规则引擎为大模型兜底。三个学派不是历史名词，而是 FDE 可以组合使用的三类工具，优秀的方案常常三类都用。

2.9 寒冬的公式

用 FDE 的视角重读历史，两次寒冬的成因相同：承诺超过交付，预算就会消失。承诺还会自己膨胀：媒体加一层，甲方再加一层。如果不主动管理，承诺就会失控。

第三次浪潮是一个反例：交付追上了承诺，热潮才没有退去。这里的交付用 ImageNet 图像识别的 Top-5 错误率衡量，Top-5 错误率指模型给出的前五个候选类别里都没有正确答案的比例。

年份	模型	Top-5 错误率
2010		28.2%
2011		25.8%
2012	AlexNet	16.4%
2013	ZFNet	11.7%
2014	VGG	7.3%
2014	GoogLeNet	6.7%
2015	ResNet	3.6%
2016		3.0%
2017	SENet	2.3%

人类在同一任务上的 Top-5 错误率是 5.1%。2015 年的 ResNet 降到 3.6%，第一次低于人类水平。

FDE 的日常工作，就是管理好客户期望，按里程碑交付，避免自己的项目出现第三次寒冬。预热五问的 Q2 是“AI 会不会出错”，回答要从承认边界开始，这是回答 Q2 的第一块砖。

2.10 规模与涌现

规模带来的变化，可以先从两个例子感受。2012 年，谷歌做了一个猫脸实验：用 1.6 万个 CPU 核心与一千万张图片训练 3 天，得到一张模糊的猫脸。今天，一句话就能生成一部短片。两者之间变化的是数据，算力与参数的规模，GPT 系列的参数量就是这样增长起来的。

模型	年份	参数
GPT-1	2018	1.17 亿
GPT-2	2019	15 亿
GPT-3	2020	1750 亿
GPT-4	2023	约 1.8 万亿

GPT-4 的参数量官方没有公布，表中数字是业界估算。向客户报数字时注明口径，是 FDE 的职业习惯。

缩放定律的英文是 Scaling Laws，出自 Kaplan 等人 2020 年的论文，是规模竞赛的理论依据。OpenAI 实测发现，模型的损失随算力，数据与参数的增加按幂律下降。损失衡量模型的预测与正确答案之间的差距，越低越好。图中三张小图的横轴依次是算力，数据量与参数量，纵轴是损失。坐标轴按对数刻度绘制，幂律关系在图上就成了一条下降的直线。左图里的浅蓝细线是许多次训练各自的损失曲线，橙色虚线与另外两张图里的直线，都是拟合出的幂律。

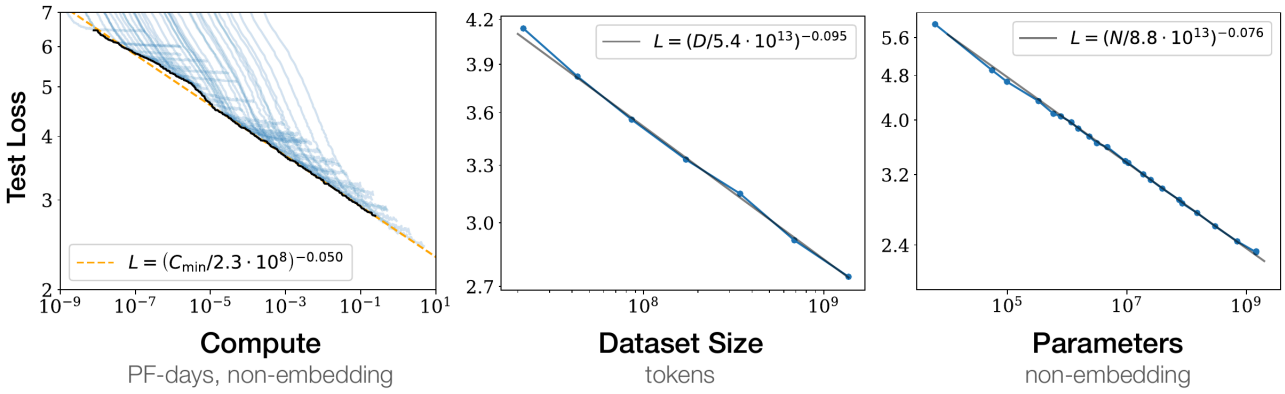


图 4　损失随算力，数据与参数按幂律下降。来源：论文图，转引。

有了缩放定律，加大投入从赌博变成了有依据的投资，GPT-3 的 1750 亿参数就是依据这条曲线确定的规模。这三条直线支撑了此后每一轮千亿级的融资，“数据枯竭”也由此成为热门话题。2022 年的后续研究 Chinchilla 进一步指出，参数与数据要按比例同步增长，否则投入的效果会打折扣。

涌现的英文是 Emergence，出自 Wei 等人 2022 年的论文，指模型规模跨过某个阈值后，某些能力突然出现。算术与解词谜这类任务，中小模型的得分接近随机猜测，规模跨过某个点后，得分突然大幅上升。图中三张小图各对应一个任务，横轴代表模型规模，纵轴是得分，不同颜色的折线代表不同的模型系列，红色虚线是随机猜测的得分。

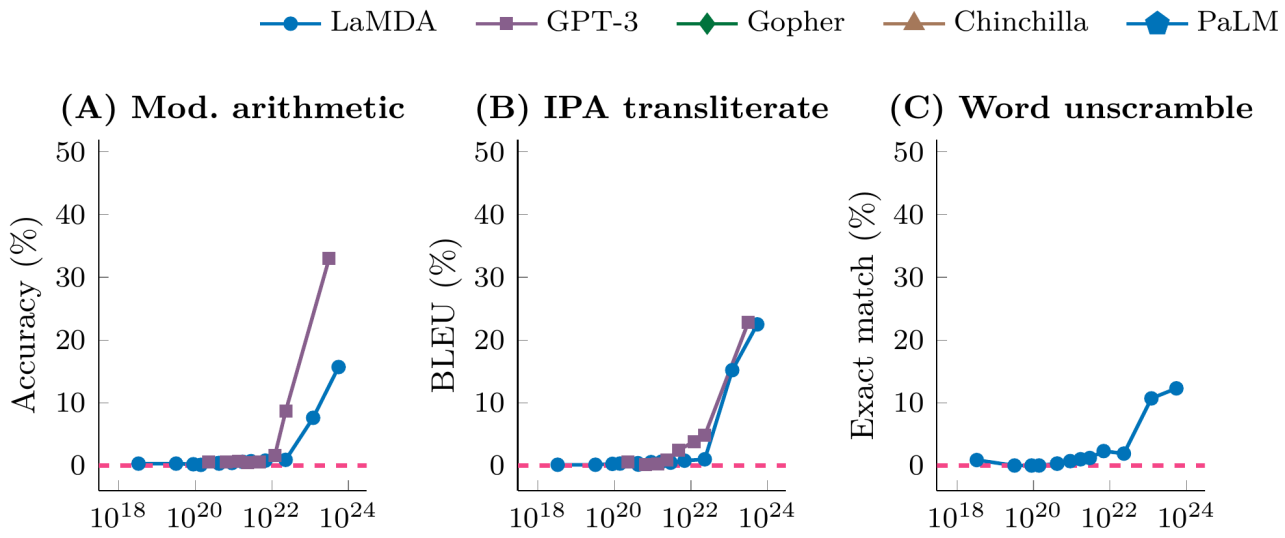


图 5　三个任务的得分在规模跨过阈值后同时上升。来源：论文图，转引。

涌现是真实的能力，还是打分方式造成的视觉假象，学界仍在争论，两种观点都要了解。对 FDE 而言，模型能力无法从小模型外推，更换模型必须重新实测。第 06 节还会介绍一个定理，为“必须实测”提供理论依据。

2.11　大模型时间轴

大模型的发展从 2017 年的一篇论文开始，到 2026 年已经成为 FDE 赖以工作的行业，时间轴的后半段与学员的职业直接相关。

时间	事件	意义
2017.06	Transformer	自注意力，可并行，是一切的地基
2018	GPT-1 与 BERT	生成与理解两条路线分野
2020.05	GPT-3	1750 亿参数，少样本能力涌现
2022.11	ChatGPT	对话式 AI 走进大众
2023.02	LLaMA 权重以研究许可开放	开放权重出现，同年 7 月的 Llama 2 按社区许可允许商用
2023.03	GPT-4	多模态，能力上限抬升
2024	GPT-4o，o1 与 DeepSeek-V3	全模态与推理模型之年
2024.11	MCP 发布	工具接入标准化，相当于 Agent 的插座
2025.01	DeepSeek-R1 开源	低成本推理，行业价格重估
2025 到 2026	Agent 与 Claude Code 普及	从“会聊天”到“会干活”

价值重心正从“模型本身”移向“把模型接进业务的人”，后者就是 FDE。

小结

两次寒冬有同一个成因：承诺超前于交付，预算随之撤走，只有交付追上承诺，热潮才能持续。第三次浪潮的前提是算法，数据与算力同时具备，三者缺一不可。贯穿七十年的问题是知识从哪里来，答案从人工编写规则转向机器从数据中学习，三大学派也成了今天方案里可以组合的三种手段。缩放定律说明加大投入能换来可预期的效果，涌现则提醒模型能力必须逐个实测。

03
大模型白话原理

3.1 生成式 AI 与基本名词

生成式 AI 的英文是 Generative AI，简称 GAI，指能创造出世上原本没有的新内容的模型。生成式 AI 会带来惊喜，也会产生幻觉。

同一首“天净沙·秋思”，交给两种系统，结果完全不同。交给搜索引擎，检索出的是已经存在的图，这是找。交给生成模型，产出的是世上原本没有的画，这是造。图中四幅水墨由通义万相根据这首小令生成，画里都有老树，流水与马，构图各不相同，都是模型新创作的。



图 6　通义万相依“天净沙・秋思”生成的四幅水墨，世上原本没有这四幅画。来源：转引。

向非技术背景的客户解释生成式 AI，用“搜索是找，生成是造”一句就够了。

面试与客户沟通时，有六个基本名词构成最小词汇表。

名词	含义
AIGC	AI 生成的内容，包括文字与图片，也包括音频与视频
GAI	生成式 AI，即能创造内容的那类 AI
LLM	大语言模型，特点是数据量大，参数量大，训练耗资大
GPT	生成式预训练 Transformer，是一种模型架构
ChatGPT	OpenAI 基于 GPT 开发的聊天产品
AGI	通用人工智能，不限领域，不限任务，目前尚未实现

这些名词之间也有包含关系：深度学习模型包含预训练模型，预训练模型包含生成式大模型，生成式大模型又包含大语言模型。

3.2　Token 与词嵌入

token 的中文叫词元，是模型读取文本的最小单位，也是大模型的计量单位与计费单位。图中是一次实测：上方“黄山落叶松叶落山黄”这句 9 个字的话，被切成了 16 个 token，切开的各段用不同底色标出，右边显示 token 数为 16，下方一串数字是每个 token 对应的编号，也就是 token 的 ID。



图 7　9 个字实测切成 16 个 token，每个 token 都有数字 ID。来源：截图。

词表的大小需要权衡。“通用规范汉字表”收录 8105 个字，“牛津英语词典”收录 60 万个词。切分得太细，句子会变长，切分得太粗，词表会过于庞大。

理解 token 有很实际的用处：API 按 token 计费，同样的内容，中文与英文的 token 数和费用可能相差数倍。帮客户估算成本，第一步就是把业务量换算成 token 量，第 06 节会用到这种换算。

词嵌入的英文是 Embedding，也叫词向量，指把语义转换成一组数，意思相近的词，向量也相近。词嵌入好比一张给万物打分的表：每个词在表头的几个维度上各得一个分数，语义就变成了数。

词	水果	公司	手机	粮食
橘子	0.92	0.23	0.02	0.19
苹果	0.96	0.77	0.85	0.15
小米	0.08	0.81	0.98	0.87
华为	0.02	0.93	0.95	0.01

表中苹果在水果，公司与手机三列得分都高，小米在公司，手机与粮食三列得分都高，因为这两个词都有不止一个意思。语境不同，向量也不同：“农民的苹果歉收”里的苹果，与“苹果的用户增加”里的苹果，向量并不相同。

图中每个点代表一个词，意思相近的词彼此靠近：鸡，狗与猫这些动物聚在一侧，香蕉和苹果这些水果聚在另一侧，苹果公司的标志则落在谷歌的标志旁边。发光的位置是查询词小猫，紧挨着猫。右上角的标注说明每个词实际是一个 300 维的向量，图中只画出了三维。



图 8　近义即近邻，意思相近的词在向量空间里距离近。来源：转引。

D4 的知识库检索，英文缩写是 RAG，就建立在这种向量表示之上。

3.3 注意力与 Transformer

注意力的英文是 Attention，作用是让模型学会“看哪里、重点关注哪里”，而不是对所有内容一视同仁。鸡尾酒会效应是一个类比：满屋嘈杂，人仍然能听清对面的人说话，这是大脑在分配注意力。没有注意力，好比死记硬背整本书。有注意力，好比回到原文划重点。

Transformer 团队在官方解读里用过一个经典例句：“The animal didn’t cross the street because it was too tired”。句中的 it 指动物。把 tired 换成 wide，it 就指街道。同一个词指代什么，要看全句的语义，注意力会根据语义消除这种歧义。2017 年，论文“Attention Is All You Need”提出了 Transformer，这篇论文改变了整个行业。

Transformer 在 2017 年提出，沿用至今，是大模型的基本骨架，可以看成一条流水线上的几个工位：

1. 读入：先分词，再做词嵌入，同时加上位置编码，把词序信息补回来。
2. 主体：几十层结构堆叠，每层有两道工序，一道是自注意力，在全句范围内寻找词与词的关联，另一道是前馈，逐个位置加工。
3. 输出：对“下一个 token”给出整个词表上的概率分布。

图中是 Transformer 原论文的架构图：下方是输入与位置编码，左边一列是编码器，右边一列是解码器，每一层里都有注意力和前馈两道工序，旁边标的“N×”表示这一层结构重复堆叠 N 次，顶部输出概率。

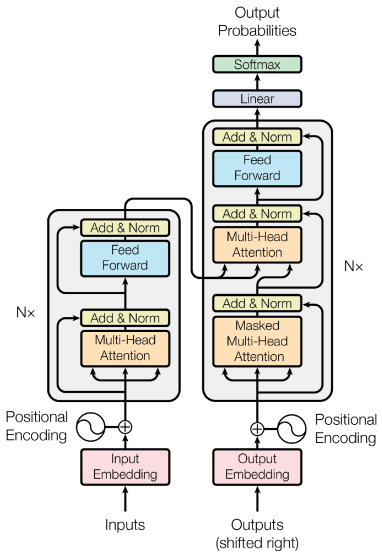


Figure 1: The Transformer - model architecture.

图 9　Transformer 原论文的架构图。来源：转引。

上一代网络逐字串行处理，Transformer 则整句并行处理，规模竞赛由此成为可能。可以这样记：注意力负责“看哪里”，前馈负责“想什么”，层数堆得越深，处理得越深入。

同一副骨架有三种用法。BERT 只用左半的编码器，负责读，擅长理解。GPT 只用右半的解码器，负责写，擅长生成。T5 两半都用，属于翻译式，文本进，文本出。

架构	使用部分	擅长	代表场景
BERT，2018 年	编码器	理解，如分类与抽取	搜索引擎排序
GPT，2018 年	解码器	生成，如续写，对话与代码	ChatGPT 一族
T5，2019 年	编码器与解码器	翻译式，文本进文本出	早期统一框架

GPT 路线后来胜出，原因是生成可以模拟一切任务。面试或与客户交流时聊到 BERT，也要能够应答。

大模型的内部结构可以在网页 `bbycroft.net/llm` 上直接查看。选择 nano-gpt 视图，这个模型只有 8.5 万个参数，可以看到模型把 CBABBC 排成 ABBBCC，数据逐层经过 Embedding 与 Attention，最后输出结果。切换到 GPT-3 视图，结构相同，体量放大约两百万倍，规模差距一目了然。看完结构，再回到 Claude，输入“请通俗解释注意力机制”，让 AI 讲解 AI。Claude 是 Anthropic 的对话 AI，第 07 节安装的 Claude Code 是 Claude 的编程版。先问 AI，再核实，是今后查概念的标准做法。

3.4 自回归与温度

同一个问题问两次，答案可能不一样，原因在于自回归加采样，这种随机性是有意设计的。自回归的英文是 Autoregressive，指模型逐个 token 生成输出，每一步都按概率从整个词表里抽取一个 token，好比掷一次骰子。温度的英文是 temperature，决定这次抽取的概率分布有多集中，好比骰子的形状。

图中的句子是“天气预报说，明天……”，候选的下一个词从“晴”到“下钞票”共五个，红色柱是概率最高的“晴”。左边温度为 0.3，取词保守，几乎只选“晴”，概率 0.85。右边温度为 1.3，取词奔放，概率分散开，什么都可能出现，“晴”降到 0.43，连“下钞票”也有 0.01。

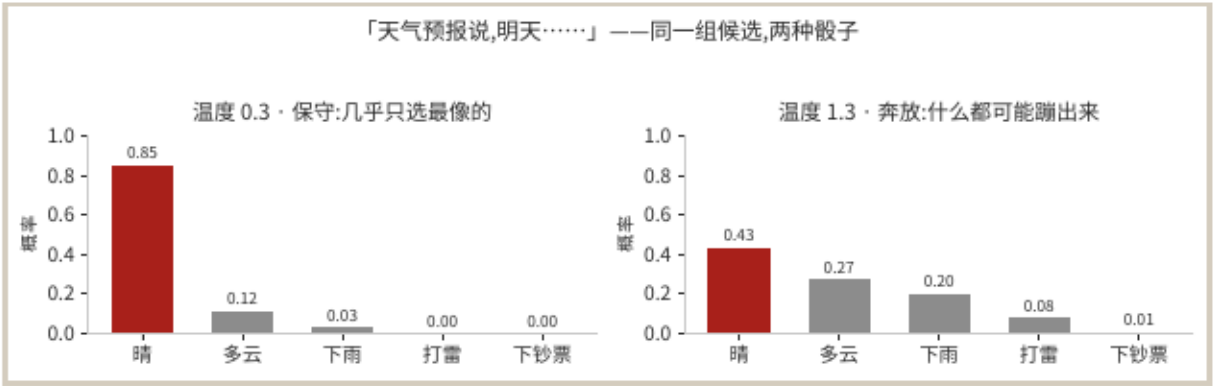


图 10　同一组候选，两种温度：低温集中，高温分散。来源：重制。

演示与评测时，要先把温度调低。向客户解释时可以说：“答案会变”不是故障，而是生成模型的固有特性，需要稳定输出时，就固定参数，使用模板，并建立评测。下午用同一句提示词让 Claude Code 重做，结果也不会完全一样，原因就在这里。

3.5 预训练与对齐

预训练的英文是 Pre-training，指用海量互联网文本训练模型完成一个简单到难以置信的任务：预测下一个词。预测错了就调整参数，这个过程重复万亿次。

这样能学到知识，是因为要把“巴黎是法国的____”这一句预测对，就得把地理知识存进参数。记住知识，是预测下一个词的副产品。训练语料的配比也有讲究，语料包括网页与书籍，也包括代码与论文，代码占比高的模型，推理能力往往更强。

预训练相当于通识教育：读万卷书，但不针对任何岗位。上岗之前还差一步“入职培训”，这一步就是对齐。

对齐让模型从只会补全文本，变成能按指令回答问题。2020 年的 GPT-3 已经掌握大量知识，但向 GPT-3 提问时，常常得到一串新的问题，因为 GPT-3 只会续写。对齐用的方法是 RLHF，英文全称 Reinforcement Learning from Human Feedback，即基于人类反馈的强化学习，ChatGPT 好用主要靠这一步。RLHF 分三步：

1. SFT，即监督微调：由人写出示范回答，让模型照着学。
2. 奖励模型：由人给模型的多个回答排出好坏，用排序结果训练出一个打分的奖励模型。
3. 强化学习：用奖励模型打分，按人的偏好优化模型。

ChatGPT 等于 GPT-3.5 加对齐：能力没有大的变化，但变得“能用”了。下载开源模型时，要认准名字里的 `-Instruct` 或 `-Chat` 后缀。base 版没有经过对齐，直接拿来对话，效果会很差。

3.6 上下文窗口与推理模型

上下文窗口的英文是 Context Window，相当于模型的工作记忆，指一次对话里模型能同时看到的 token 上限。按量级说，8K 约等于一篇长文，128K 约等于一部中篇小说，1M 约等于一小柜文档。中文 1 个字约等于 1 到 2 个 token，用分词的知识就能估算窗口能装下多少字。

窗口有两个陷阱。第一，窗口大不等于全都记得牢，答案埋在中间时，准确率最低。第二，放进窗口的内容越多，费用越高，速度越慢。图中横轴是含答案的那篇文档在 20 篇文档中的位置，纵轴是准确率，紫色折线两头高，中间低。红色虚线是模型不看任何文档，只凭自身知识作答的准确率，答案埋在中间时，准确率甚至低于这条线。

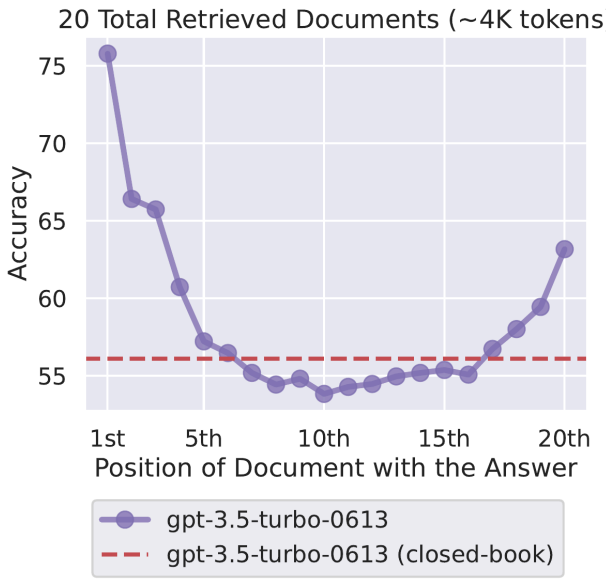


图 11　答案埋在中间时，准确率垫底。来源：论文图，转引。

因此，把全公司的文档都放进窗口不是方案，只会带来一张高额账单。先检索出相关的几段，再放进窗口，才是可行的方案，具体做法在 D4 讲解。

推理模型的做法是先打草稿，再给答案。2022 年的研究发现，在提示里让模型“一步步想”，数学题的正确率会大幅提高，这种方法叫思维链，英文是 Chain-of-Thought，简称 CoT。图中左边是普通提示，示例里只给答案，模型直接作答，结果答错，用红叉标出。右边是思维链提示，示例里用蓝色标出了推理步骤，模型照着一步步计算，绿色部分是模型写出的推理，结果答对，用绿勾标出。

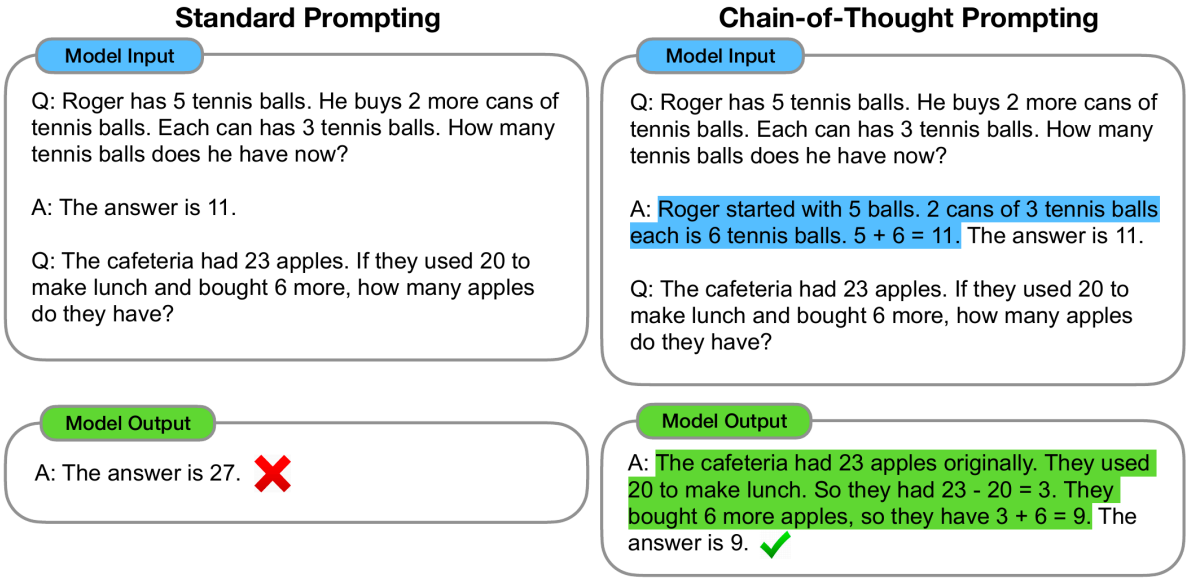


图 12　普通提示与思维链提示的对比。来源：论文图，转引。

2024 年到 2025 年，o1 和 R1 把“打草稿”变成了训练目标，答题前先生成很长的推理过程。代价是速度更慢，费用更高，闲聊类的客服场景用不上，数学，代码与规划类任务才值得使用。选型时，“快思考”与“慢思考”两类模型按任务搭配使用，第 06 节会算一笔账。

3.7　一句话的旅程

把分词，几十层加工与采样这些环节连起来，就是一句话进入大模型的完整过程，共五个环节：

1. 输入：用户的话加上系统提示词。
2. 分词：把输入切成 token，再变成向量。
3. 几十层加工：每层做注意力与前馈。
4. 采样：按概率选出下一个 token，相当于掷一次骰子。
5. 流式回屏：生成的 token 逐个显示在屏幕上，形成“打字机”式的效果。

图中从左到右就是这五个环节。红色回环表示每采样出一个 token，就把这个 token 拼回输入，再生成下一个 token。



图 13　一句话的旅程，红色回环表示逐个 token 生成。来源：重制。

三个商业事实都与这条链有关：按 token 计费，首字延迟与上下文上限。首字延迟指从发出问题到屏幕上出现第一个字的等待时间。到 D3 学习后端开发时，这条链的每个环节都会对应 API 的一个参数。

3.8　一本正经的错与幻觉

大模型会一本正经地出错，两个简单的测试就能看出来。第一个测试是让模型计算一个缺角矩形的周长，模型给出的步骤头头是道，答案却是错的，态度还很自信。第二个测试是拿平台自家的 logo 问模型“这是谁家的”，模型答不出来，因为模型没有实时知识，也没有“自我”。

由此可以得出三个推论：一要接入外部知识，对应 D4 的 RAG，二要接入工具，对应 D7 的 Agent，三要建立评测，对应 D7 的 Evals。预热五问的 Q2 是“AI 会不会出错”，答案是会，而且错得理直气壮，方案的价值在于为这种错误兜底。

幻觉的英文是 Hallucination，指模型把“最像的”当成“对的”说出来。幻觉是生成模型的属性，不是故障，模型并不是在撒谎，而是在按概率补全。幻觉有三个根源：

1. 模型的世界里只有“像不像”，没有“真不真”，概率补全没有真值表可查。
2. 训练数据有边界，问到数据之外的事，例如自家公司的产品，模型只能编造出看似合理的回答。
3. 对齐教会模型“有问必答”，模型宁可编造一个答案，也不会主动说不知道，除非提示词里明确允许模型说不知道。

一个简单的补救办法是在系统提示词里写明“不确定就说不知道”，幻觉会明显减少，下午的实践中可以试一试。

3.9 多模态与文生图

多模态让模型有了“眼睛和耳朵”，能处理图像与语音。多模态大模型的英文缩写是 MLLM，即 Multimodal LLM，文本，图像与语音进入同一个模型，这是业界主流看好的 AGI 路径之一。视觉模型看完一段“奇幻动物”视频，能完整解读出长颈鹿加火烈鸟，鲸鱼加章鱼这样的组合，说明模型确实“看懂”了。对 FDE 来说，客户的需求正从“能聊天”升级为“能看单据，能听录音”。D3 学习后端开发时会接入多模态 API，让智能客服能够“看图”。

文生图由两部分配合完成：CLIP 负责理解文字，扩散模型负责作画。CLIP 于 2021 年提出，用 4 亿组“图-文”对训练，让图像和文字进入同一个空间，可以比较两者的距离。扩散模型的英文是 Diffusion Model，训练时把一张图逐步加噪，直到变成雪花一样的纯噪声，模型从中学会逆向去噪。生成图片时，模型从纯噪声出发，一步步去噪，最后得到画面。

图中左端是纯噪声，右端是清晰的人脸，中间的图噪声逐步减少。实线箭头向右，表示去噪，虚线箭头向左，表示加噪。每一步只依赖上一步的结果，这样的过程叫马尔可夫链。

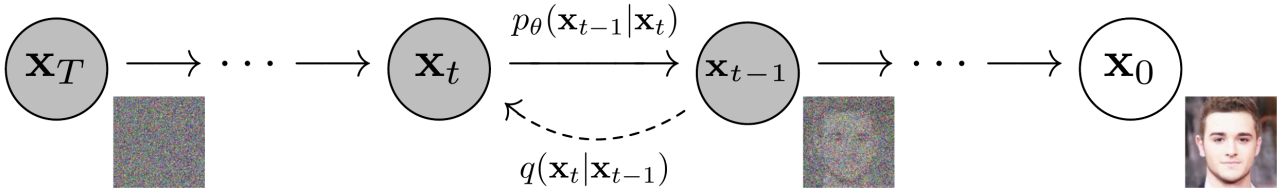


图 14　扩散模型的马尔可夫链：从左往右逐步去噪，从右往左逐步加噪。来源：论文图，转引。

文字经过 CLIP 处理后，为去噪提供方向，扩散模型按这个方向去噪，“一句话出图”就是这样实现的。可以记住一句口诀：“CLIP 懂话，扩散会画；话给方向，噪里出画。”视频生成则是这套方法在时间轴上的延伸。

小结

生成式 AI 的特点是创造新内容，搜索只能找到已有的内容。模型以 token 为单位读写文字，靠词嵌入把语义变成数，靠注意力在全句里建立关联，再逐个 token 采样输出，计费，延迟与窗口上限都由这条流程决定。预训练让模型获得知识，对齐让模型听懂指令，推理模型用更多的计算换取更高的正确率。幻觉源于概率补全，属于模型的固有属性，方案要靠外部知识，工具与评测来兜底。

04
能力边界与责任

4.1 能力的双刃剑

AI 的能力越强，越要清楚 AI 会在哪里出错。每一项能力都有影子，六个领域可以正反各说一句。

领域	亮面	影子
自动化	生产效率跃升	岗位替代焦虑
推荐算法	千人千面的服务	偏见，歧视与信息茧房
数据建模	医疗与科研提速	隐私滥用
AIGC	创作平权	造假与学术诚信危机
个性教学	因材施教	教育资源的新鸿沟
智能机器	交通与制造升级	自主武器与事故责任

这张表不是伦理课作业，表里的每一行，都可能变成客户会议室里的一句质疑。正反两面都讲，是专业的表现。只讲亮面，就成了推销，客户分辨得出来。

4.2 给客户设预期

给客户设预期，以三句话为基础。这三句话被称为压舱石，作用是让客户的预期保持稳定。

第一句：AI 系统没有 100% 的正确率。传统程序可以做到，机器学习做不到，所以方案要谈的是准确率，边界与兜底措施。

第二句：模型的局限多来自数据的筛选。一切结论都默认“训练数据代表现实”，数据筛选出了偏差，结论也会跟着偏。其中名气最大的例子是**幸存者偏差**，英文是 Survivorship Bias。图中红点是飞机上的弹孔。能看到弹孔的，都是中弹后幸存返航的飞机，所以真正该加固的，反而是没有弹孔的部位。

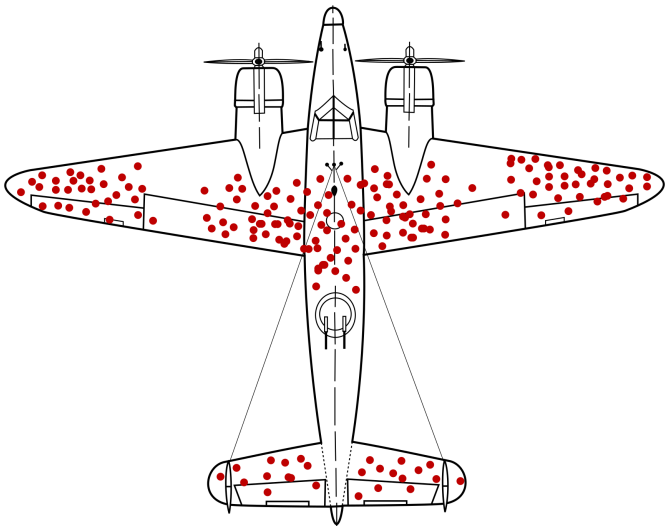


图 15　幸存者偏差：该加固的是没有弹孔的地方。来源：转引。

第三句：模型可以复制，数据不可复制。数据是客户手里价值最高的资产，这也是劝客户自建知识库的理由。

三句话合起来，回答了预热五问 Q2 的一半：AI 会出错，错多少可以测量，出错时有兜底。至于怎样测量，留到 D7 讲解。

4.3　隐私泄露的路径

隐私泄露有三条路径，每一条都有论文证实。第一条是训练数据被模型原样输出：研究者用一段前缀诱导 GPT-2，让模型逐字输出真人的姓名，电话与邮箱。图中上方是输入的前缀，中间是 GPT-2，下方是模型输出的内容，黑块是论文原文对个人信息的打码。

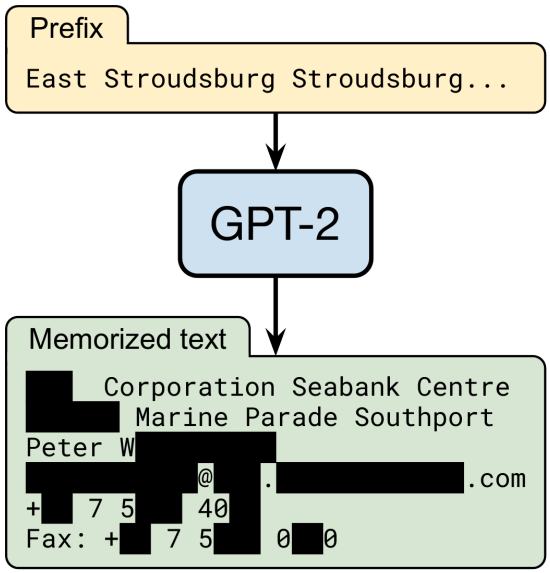


图 16　从 GPT-2 中提取训练数据。来源：论文图，转引。

第二条是生成即复现，文生图模型可能近乎原样地复现训练集里的照片。第三条是 AI 成为帮凶，大模型把“搜集并拼接已泄露信息”的成本压到接近于零。

客户数据进入模型之前，FDE 要先问三个问题：数据能不能出域，要不要脱敏，合同里怎么写。这三个问题回答了预热五问 Q4 的一部分。

4.4 深度伪造

深度伪造的英文是 Deepfake，指用 AI 伪造人脸与声音，眼见不再为实。换脸短剧与克隆声音的诈骗电话，制作门槛已经低到人人都能做。图中左组是换脸，右组是改表情。每组左边的大图是真实的人脸，旁边的小图是另一个人，箭头之后是两种方法各自伪造出的画面，两组合起来共四种伪造方法。



图 17　同一张脸的真身与四种伪造。来源：论文图，转引。

2017 年斯坦福的一项实验发现：面对网上的真假信息，历史学家和大学生都判断失误，只有职业事实核查员通过了测试。核查员靠的是核查流程，不是眼力。工程上的对策有三条：生成内容嵌入水印，平台配备检测工具，发布流程保留人工审核环节。交付时，生成内容的出口要配齐标识和审核环节。

4.5 电车难题

电车难题的英文是 Trolley Problem，问的是要不要扳动道岔：不扳，电车会撞上主轨道上的五个人，扳了，电车会改撞岔道上的一个人，相当于牺牲一人救下五人。哲学界为这个问题争论了六十年，至今没有定论。图中左边是驶来的电车，扳道的人站在道岔旁。

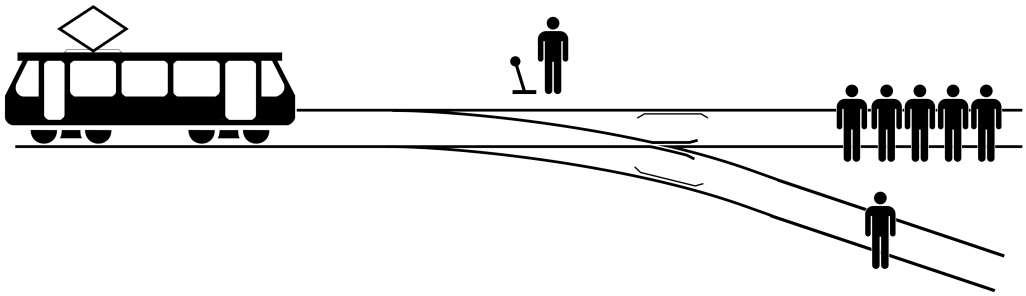


图 18　电车难题：扳道就撞一人，不扳道就撞五人。来源：CC 转引。

机器有没有道德选择权，在自动驾驶上已经是现实问题：危急时刻保护行人还是保护乘客，这不是思想实验，而是要写进产品的参数。工程上的共识是，高风险决策中人必须在环，也就是决策过程必须有人参与：机器给出建议，由人做最终决定，责任写进合同。给客户划定系统边界时，先画出“哪些决定永远留给人”，这条线画清楚了，合同才签得下来。

4.6 一线合规常识

方案书里必有“合规”一节。一线工作需要了解两部规定和一条红线，具体条文以现行有效版本为准。

第一部是“生成式人工智能服务管理暂行办法”，2023 年 8 月起施行，规定面向公众的服务须备案，内容责任由服务方承担。第二部是“互联网信息服务深度合成管理规定”，常简称“深度合成管理规定”，2023 年 1 月起施行，要求 AI 生成的内容须显著标识。数据出境另有安全评估门槛，不是“买个国外 API”那么简单。

一条红线是：客户数据不出域，是很多行业的默认前提。私有化部署存在的理由就在这里，D5 全天讲私有化部署。

4.7 负责任的 AI

负责任的 AI 的英文是 Responsible AI，指把护栏做进交付物。护栏分为事先，事中与事后三道。

- 事先：确保数据来源合法，数据脱敏后再入库，把问题挡在系统之外。
- 事中：用提示词约束模型，拦截敏感词与越权操作，防止问题内容输出。
- 事后：保留审计日志，准备兜底话术，明确责任认定，出现问题时可以追溯。

阿西莫夫提出的“三守则”是科幻作品里的约定，不是工程标准，工程标准是事先，事中与事后这三道护栏。

到这里，预热五问 Q2 的完整答案由三部分组成：边界，兜底与度量。边界与兜底在第一天讲完，度量留到 D7。

4.8 午饭思辨题

三道思辨题没有标准答案，但面试官和客户都可能问到。价值观问题没有对错之分，但有“想过”和“没想过”的区别，D8 的答辩与 D10 的面试都可能遇到。

1. 思考一：“AI 是工具还是伙伴？你对它说过‘谢谢’吗，为什么？”
2. 思考二：“算法出了偏见，该由谁负责：写规则的、供数据的、拍板上线的，还是模型自己？”
3. 思考三：中文屋，英文是 Chinese Room。“只照规则搬符号的大模型，到底‘理解’了没有？这重要吗？”

小结

讲 AI 的能力时要同时讲风险，只讲亮面，客户会把方案当作推销。设预期的三句话分别对应正确率，数据偏差与数据价值。面对隐私，伪造与伦理问题，共同的对策是让人留在高风险决策里，并给生成内容加上标识与审核。合规要在方案书里单独成节，交付的系统要在数据入库，模型输出与事后追溯三个环节都设防护。

05
二〇二六年大模型格局

选模型之前，先要看清市场上有哪些模型与工具，再决定选用哪一家。

5.1 三层格局

2026 年的大模型市场可以分成三层：闭源模型，开源模型与工具层。

层	代表	特点
闭源模型	GPT，Claude 与 Gemini	能力顶尖，按 token 计费
开源模型	DeepSeek，Qwen，Llama 与 GLM	可私有化部署，中文社区强
工具层	Claude Code，Codex 与 Cursor	用于 AI 原生开发，是 FDE 的主力工具

闭源模型的能力处在顶尖水平，按调用时消耗的 token 数量计费。开源模型公开权重，可以部署在客户自己的机房里，这种做法叫**私有化部署**，英文是 Private Deployment。工具层不是模型，而是 AI 原生开发使用的软件，FDE 的日常开发工作都在这些工具里完成。

做方案时要注意合规：ChatGPT 等国外服务在国内的使用受到限制，给客户设计方案时必须考虑这一点。国产开源模型 DeepSeek 与 Qwen 已经进入第一梯队，私有化方案因此在能力上有了保障。

预热五问的 Q3 问的是：同一个任务选 GPT 还是 DeepSeek。这个问题要到模型选型时才能回答，在那之前先要了解格局。

5.2 闭源三家

三家闭源模型各有特点。模型能力会随版本更新而变化，所以要记住的是各家长期稳定的特点，具体选用时以实测结果为准。

厂商与模型	长期特点	常见用途
OpenAI 的 GPT	开发者社区最大，通用旗舰	通用问答与多模态
Anthropic 的 Claude	擅长代码与长文档，Agent 工具链完整	Claude Code 与编程
Google 的 Gemini	超长上下文与多模态，绑定谷歌自家产品	视频理解与检索融合

三家的共同点是按 token 计费，并且在国内直接访问受到限制。给国内客户做方案时，这两点是硬约束。

“哪家最强”的答案每个季度都会变化。面试时回答这类问题，应当按任务分别说明各家的长处，并以自己的实测结果为依据。

5.3 开源梯队与商用条件

开源模型像一顿免费的午餐，但午餐有菜单：模型可以免费获取，使用时却要遵守许可证规定的条件。开源模型公开的是模型权重，这种发布方式叫**开放权重**，英文是 Open Weights。开放权重不等于可以随意商用，使用前先要看许可证。常见的开源模型有四个系列：

- DeepSeek 推理能力强，采用宽松的 MIT 许可证。2025 年 1 月开源的 DeepSeek-R1 以低成本实现了推理能力，引发行业重新评估模型价格。
- Qwen 的中文名是通义，系列内的模型规模齐全，在中文社区处于第一梯队，许可证多为 Apache 2.0。
- Llama 来自 Meta，是国际开源社区的基石，采用“社区许可”，商用需要满足许可条件。
- GLM 来自智谱，在国内的私有化项目中经常使用。

开源模型发布在模型社区里，社区按热度给模型排行，开发者可以像在货架上挑商品一样挑选模型。图中每张卡片代表一个模型，左边是排名，右上是模型名称，右下是下载量与收藏数，排在第三的是智谱的 GLM-5.2。



图 19　模型社区的热门排行，开源模型像货架上的商品一样供人挑选。来源：截图。

给客户选开源模型时，先评估能力，再核对许可证，许可证文件通常名为 LICENSE。客户的法务问起商用条件时，FDE 要能答上来。

5.4 国产模型的落地优势

海外旗舰模型的能力更强，FDE 承接的落地项目却主要使用国产模型，原因有四个方面。

合规方面，境内面向公众的服务必须使用已经备案的模型，用国外 API 直接服务 C 端用户是一条红线。中文方面，在中文语料与文化语境上，国产模型常常反超海外模型，模型选型时的五言绝句横评就是一个例子。价格方面，同档能力下，国产 API 的单价常常低出数倍，用智能客服的月账单可以算出具体差距。私有化方面，开源权重加上国产硬件适配，模型才能进入政企机房。

通用能力的上限由海外模型代表，落地项目则以国产模型为主，两类模型都要熟悉。

5.5 补全型与代理型工具

AI 原生开发工具已经发展了两代。上一代是补全型工具：开发者写代码，工具补全后面的部分。当下的是**代理型工具**，代表有 Claude Code，Codex 与 Cursor：开发者说出目标，工具先读取文件并修改代码，再运行命令检查结果，遇到报错就继续修改，如此循环。

工具换代以后，开发者的角色也变了，从“打字的人”变成“验收的人”，也就是从逐行编写代码，变成提出需求并检查结果。

实训营以一线团队常用的 Claude Code 为主，用 Codex 提供第二意见，两款工具都在工具链装机时安装。

5.6 平台注册与信息渠道

注册大模型平台是第一天的课后作业。几类平台的直连情况与用途分工各不相同。

平台	直连	用途分工
DeepSeek	国内直连	推理与代码，必须注册
通义，Kimi 与豆包	国内直连	长文阅读与日常问答
ChatGPT，Claude 与 Gemini	视网络条件	对照体验海外旗舰

最低要求是在第一天课后至少注册三家国内平台，D2 前端课的第一个小时就要用到。使用时把同一个问题分别交给两个平台，比较两者的回答，选型的经验就是这样积累起来的。

大模型行业变化很快，要跟上变化，可以依靠三类信息来源。一手信息指各家的官方发布与技术报告，新模型发布时，先读官方的说明。榜单指 LMArena 等第三方竞技场，只能作为参考，不能当作定论，原因在模型选型时讲到的“没有免费的午餐”定理里。社区指 HuggingFace 趋势榜与技术社区周报，这是开源领域的风向标。

跟进的方法是每天花 20 分钟，只关注和手头任务有关的更新，什么都追反而什么都跟不上。实训营每天的“AI 快讯轮值”就是这项习惯的集体版本。

小结

大模型格局按闭源模型，开源模型与工具层三层来看。闭源模型能力领先，但受按量计费与国内访问条件的约束，开源模型能私有化部署，商用前要核对许可证。国产模型在合规与价格上占优，中文表现与私有化条件也更适合国内项目，因此成为落地的首选。AI 开发工具进入代理型阶段，开发者的工作重心转向提出需求与验收结果。

06
模型选型与成本测算

选型必须针对具体任务实测，选定模型之后，还要估算需要的资源与费用。

6.1　训练成本的量级

大模型的训练成本很高。以 2023 年的 GPT-4 为参照，有三个数字可以说明量级。三个数字都是业界的估算，量级至今仍然成立。

数字	含义
13 万亿	训练用的 token 总量，相当于把互联网读一遍
1.8 万亿	参数规模，官方没有公布
7800 万美元	一次完整训练的成本量级

训练消耗的算力由显卡提供，图中是一张 A100 显卡。

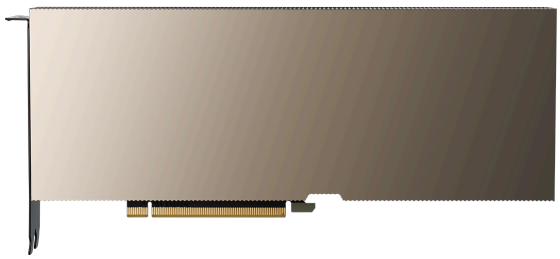


图 20　算力的长相：一张 A100 显卡。来源：官方图。

由于训练成本很高，行业形成了分工：少数巨头训练基础模型，企业“租”模型或者“养”小模型。租指通过 API 调用模型，养指把小模型私有化部署在自己的机器上。客户如果问为什么不自己训练一个模型，这三个数字就是答案。

6.2　没有免费的午餐定理

选型的理论依据是**没有免费的午餐定理**，英文是 No Free Lunch，简称 NFL，由 Wolpert 与 Macready 于 1997 年提出。定理指出：如果一个模型在某一类任务上占优，那么在另一类任务上必然处于劣势，不存在在所有任务上都占优的模型。

定理有两条推论。第一，没有“最好的大模型”，只有“最适合这个任务的模型”。第二，榜单分数反映的是榜单所选任务上的表现，自己的任务必须自己测。

由此得到选型第一原则：具体问题具体分析。这条原则听起来平常，背后却有定理支撑。预热五问的 Q3 到这里得到完整回答：同一个任务选 GPT 还是 DeepSeek，要凭任务实测选出适合这个任务的模型，而不是凭榜单。

6.3 横评案例与榜单口径

榜单第一不等于自己任务上的第一。一次横评用同一道题测试多个模型，题目是“写一首人工智能主题的五言绝句”，模型版本以测试时为准。

结果	模型	说明
合格	文心一言，GPT-4 与通义千问	格律正确
不合格	Claude，GPT-4o mini 与 Gemini 等	格式或格律出错

通用能力顶尖的模型，在中文格律这类具体任务上同样会出错。由此得到两个结论：任务级实测不能省，在中文场景下国产模型可能反超。这类结论会随模型版本变化，D7 会把实测做成可以重复运行的评测集，并与基线对比。

读榜单还要看口径。AA 是 Artificial Analysis 的缩写。以 2026-07-12 的快照为例，四份权威榜单的测法与名次各不相同，引用榜单时必须连同日期一起引用。

榜单	测法	领先者	国产位置
AA 智力指数	榜方自测 9 套题	Claude Fable 5，60 分	GLM-5.2，51 分，国产最高
LMArena 总榜	真人盲测 Elo	claude-fable-5，1509	开源子榜 GLM-5.1 居首
LMArena Agent	真实会话遥测	Claude Fable 5	GLM-5.2 第 10
SWE-bench	第三方提交实测	脚手架加 Claude 4.5，79.2%	GLM-5，72.8%，bash 榜

Elo 是按两两对比的胜负计算出的积分。脚手架指包在模型外层，负责调用工具与执行步骤的程序。

表中“测法”一栏是四种不同的口径，分数之间不能互相比较。日期同样重要：当下的旗舰模型都没有出现在 SWE-bench 上，原因是这份榜单的收录停在 2026 年 2 月。读榜单时先看谁在测，怎么测和测到哪天，再看分数，面试中常用这道题区分水平。

6.4 性价比象限

把智力和成本放在同一张图上，就得到性价比象限。图中纵轴是 Artificial Analysis 智力指数，越高代表越聪明。横轴是每个任务的平均成本，单位是美元，采用对数刻度，越往右越贵。不同颜色的点代表不同厂商的模型，左上角的浅绿色区域是够聪明又便宜的象限，数据为 2026-07-12 的快照。

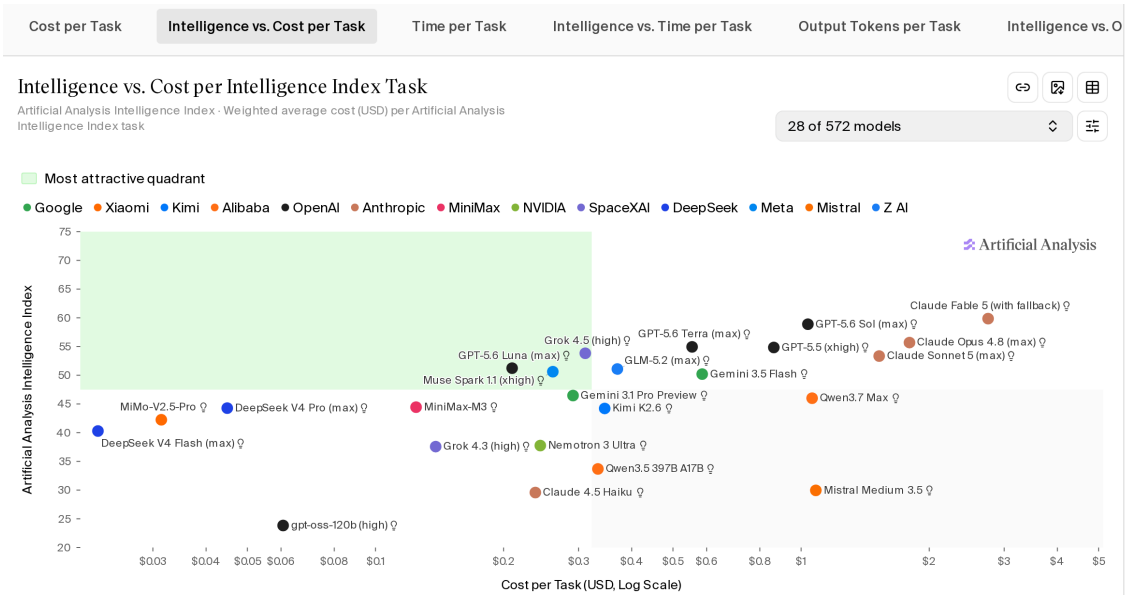


图 21　智力与每任务成本的象限图，左上角的浅绿色区域是够聪明又便宜的象限。来源：榜单截图，转引。

图中位置最高的是 Claude Fable 5，智力指数 60，每个任务 2.75 美元，也是图中成本最高的模型。成本最低的是 DeepSeek V4 Flash，40 分，每个任务 0.02 美元，便宜一百多倍，能力够用时，低成本就是优势。高性价比区间的代表是 GLM-5.2，51 分，每个任务 0.37 美元，这是国产旗舰的典型位置。

客户需要的答案通常落在左上象限，也就是够聪明又便宜的区域，很少是图上的最高点。

6.5　模型体积与显存估算

模型多大，需要多少资源，先要有直观的认识。参数量后面的 B 表示十亿，1.5 B 就是 15 亿个参数。表中的体积按 4bit **量化**后的下载包计算。量化的英文是 Quantization，指用更少的二进制位存储每个参数，4bit 就是每个参数占 4 个二进制位。不量化的 FP16 版本，体积大约是表中数值的 4 倍。

参数量	体积参照	运行设备	典型用途
0.2 B	约 0.2 GB	手机也能运行	演示与教学
1.5 B	约 1.1 GB	没有 GPU 的笔记本	轻量本地助手
8 B	约 4.7 GB	单张消费级显卡	私有化项目常用
数百 B	数百 GB	服务器集群	旗舰 API 的后台模型

一台笔记本就能运行本地模型。装好 Ollama 之后，一条命令就能运行 1.5B 的 DeepSeek-R1：

```
ollama run deepseek-r1:1.5b
```

D5 私有化部署时，会用 Ollama 或 vLLM 正式部署开源模型。

客户报出显卡型号时，FDE 要能很快判断这张显卡能运行多大的模型。显存可以用一条经验公式估算：显存 ≈ 参数量 × 每参数字节数 × 1.2，乘 1.2 是为了留出两成余量。每参数字节数取决于精度：FP16 是 2 字节，INT8 是 1 字节，INT4 是 0.5 字节。FP16 表示 16 位浮点数，INT8 与 INT4 分别表示 8 位与 4 位整数，INT4 对应 4bit 量化。

例如客户有一张显存 24 GB 的 4090 显卡，想知道 14B 模型能不能运行。按公式计算，FP16 下约需 $14 \times 2 \times 1.2 \approx 34$ GB，超出了 24 GB。INT4 下约需 $14 \times 0.5 \times 1.2 \approx 8$ GB，单张 4090 足够。

模型	FP16	INT4	结论
8 B	约 19 GB	约 5 GB	8 GB 消费级显卡运行量化版
14 B	约 34 GB	约 8 GB	单张 24 GB 的 4090 足够
70 B	约 168 GB	约 42 GB	至少需要多卡服务器

公式估算的主要是模型权重。并发请求与长上下文还要额外占用缓存，生产部署的余量怎么留，D5 再详细讲。

6.6 选型五问

接到需求后，FDE 先用五个问题梳理选型条件。

问题	要明确的事
任务	生成，抽取，问答或多模态，任务类型决定模型类型
数据	数据能出域就走 API，不能出域就走私有化
预算	先按 token 估算月账单，再与私有化的显卡和运维费用对比
延迟	在线客服要求即时回复，离线分析可以慢慢计算
合规	行业监管与国产化要求，有时会直接排除部分选项

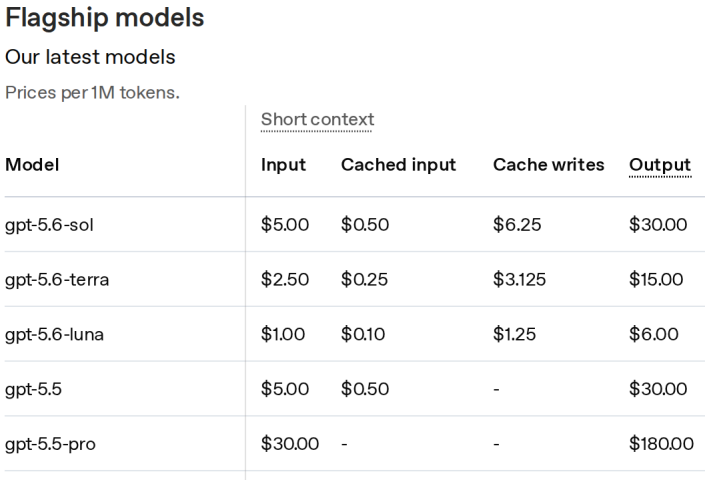
数据这一问回答了预热五问 Q4 的一半。成本测算的起手式是 月账单 = 单价 × 用量，其中用量由业务量换算成 token 量得到。完整的成本测算在 D5 进行。

6.7 月账单与价目表

计算月账单时，方法比具体数字重要，单价以官网当日公布的为准。以一个智能客服为例：日均 1000 个会话，每个会话 8 轮，每轮输入 800 token，输出 150 token。

按每月 30 天计算，月输入量为 $1000 \times 8 \times 800 \times 30$ token，约 1.9 亿 token。月输出量为 $1000 \times 8 \times 150 \times 30$ token，约 3600 万 token。用两家定价页上的单价分别乘以月输入量和月输出量，就得到各自的月账单，同档旗舰之间的价格相差数倍。

两张截图分别是 OpenAI 与 DeepSeek 的定价页，单价都按每百万 token 计，以美元标价。



Flagship models

Our latest models

Prices per 1M tokens.

Model	Short context Input	Cached input	Cache writes	Output
gpt-5.6-sol	$5.00	$0.50	$6.25	$30.00
gpt-5.6-terra	$2.50	$0.25	$3.125	$15.00
gpt-5.6-luna	$1.00	$0.10	$1.25	$6.00
gpt-5.5	$5.00	$0.50	-	$30.00
gpt-5.5-pro	$30.00	-	-	$180.00

图 22　OpenAI 定价页，按每百万 token 列出各模型的单价。来源：截图。

MODEL		deepseek-v4-flash(1)	deepseek-v4-pro
PRICING	1M INPUT TOKENS (CACHE HIT)	$0.0028	$0.003625
	1M INPUT TOKENS (CACHE MISS)	$0.14	$0.435
	1M OUTPUT TOKENS	$0.28	$0.87

(1) The model names `deepseek-chat` and `deepseek-reasoner` will be deprecated on 2026/07/24 15:59 UTC. For compatibility, they correspond to the non-thinking mode and thinking mode of `deepseek-v4-flash`, respectively.

图 23　DeepSeek 定价页，单价分缓存命中，缓存未命中与输出三种。来源：截图。

降低成本的常用做法是路由：简单问题交给便宜的模型，难题才交给旗舰模型，通常能节省三至七成费用。

DeepSeek 4 系列只有两款模型。两款模型在官网 2026-07-12 的人民币价格列在表中，单位是元每百万 token，以官网当日价格为准。

模型	定位	输入	缓存命中	输出
deepseek-v4-flash	经济高吞吐，激活 13B	1 元	0.02 元	2 元
deepseek-v4-pro	旗舰，激活 49B	3 元	0.025 元	6 元

“激活 13B”指每次计算实际参与运算的参数量是 130 亿。两款模型的上下文长度都是 1M token，思考模式与非思考模式同价，默认使用思考模式，推理能力不再单独收费。旧模型名 deepseek-chat 与 reasoner 将于 2026-07-24 停用，分别对应 v4-flash 的非思考模式与思考模式。

读价目表要看缓存。缓存命中指本次输入的开头部分与之前的请求相同，这部分可以直接复用，按低价计费。v4-flash 缓存命中每百万 token 0.02 元，未命中 1 元，相差 50 倍，所以让提示词的开头保持固定，能明显降低费用，具体做法 D3 再讲。

GLM 全系列的价目表可以读出智谱的产品策略。价格来自 open.bigmodel.cn，是 2026-07-12 的价格，单位是元每百万 token。给出区间的版本按输入或输出的长度分档，长度越长，单价越高。

版本	输入	输出	定位
GLM-5.2，新品，1M 上下文	8	28	长任务旗舰
GLM-5.1	6 到 8	24 到 28	次旗舰，按输入长度分档
GLM-5-Turbo	5 到 7	22 到 26	旗舰系提速版
GLM-5	4 到 6	18 到 22	入门旗舰
GLM-4.7	2 到 4	8 到 16	主力中端，按输入与输出长度分档
GLM-4.5-Air	0.8 到 1.2	2 到 8	轻量，性价比高
GLM-4.7-FlashX	0.5	3	付费轻快档
GLM-4.7-Flash，200K 上下文	免费	免费	全系列只有这一档完全免费

从表里能读出策略：免费档用来吸引用户，旗舰档带来收入。给客户选型时，先问清预算落在哪一档。价目页上的“限时免费”指缓存的存储费用，不能理解成模型免费。

6.8 API 与私有化

走 API 还是走私有化，可以用一张决策表判断。

维度	走 API	走私有化
数据敏感度	数据可以出域	数据一律不出域，属于硬门槛
前期投入	接近零	显卡，适配与运维
单位成本	用量小时便宜	用量大时摊薄，反而更便宜
能力上限	旗舰模型随时可用	受限于开源模型与本地算力
运维要求	不需要	需要专人管理机器与升级

两者不必二选一，实战中常见的是混合方案：敏感数据交给本地模型处理，通用能力调用 API。预热五问 Q4 的另一半答案也在这里：客户要求数据不出公司时，采用私有化或混合方案，完整方案在 D5 动手搭建。

6.9 模型能力的增强路线

模型能力不够时，有三条增强路线。先记住每条路线的类比，D4 与 D5 再动手实践。

路线	类比	适用场景
提示词工程	把任务布置清楚	零成本起步，立即可用
RAG 检索增强	开卷考，先发资料再答题	知识经常更新，答案要能溯源
微调	闭卷考，先把知识背进脑子再上场	任务固定，有标注数据

开卷考指回答前先检索相关资料，模型参数不变。闭卷考指通过训练把知识写进模型参数。三条路线的成本依次升高，所以顺序是先用提示词，再上 RAG，最后才考虑微调。开卷考与闭卷考这组类比，可以直接用来向客户解释方案。

6.10 微调方式

微调的英文是 Fine-tuning，指在已有模型的基础上用新数据继续训练。常见的微调方式有五种，成本差别很大。

方式	成本	做法
全参微调	极高	更新全部参数，相当于全身大手术
部分微调	高	冻结大部分层，只训练少数几层
PEFT，如 LoRA	中	冻结原参数，只训练旁挂的少量新参数，单卡可以完成
提示词微调	低	模型参数不动，只训练一小段“软提示”
RLHF	极高	按人类偏好对齐模型的回答

PEFT 是只训练少量参数的高效微调方法。软提示是一小段可以训练的提示向量，放在输入前面，作用类似人写的提示词。

LoRA 像旁挂的小电路。图中蓝色方块是预训练好的原有权重 W，训练时冻结不动。右侧橙色的 A 和 B 组成旁路，输入 x 同时经过两条路径，两路结果相加得到输出 h，训练时只更新 A 和 B。图中 d 是输入向量的维度，r 是旁路中间收窄后的维度，r 远小于 d，所以要训练的参数很少。旁路的初始设置是 B 等于 0，因此训练开始时，旁路不改变原模型的输出。

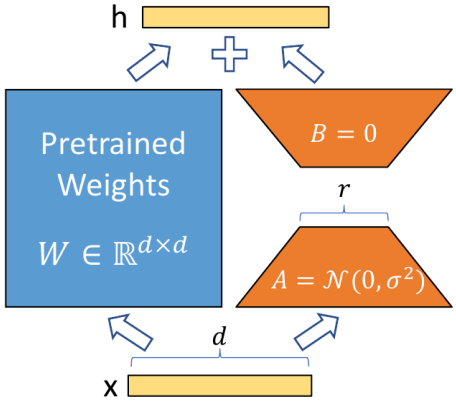


图 24　LoRA 冻结原有权重 W，只训练旁路上的 A 和 B。来源：论文图，转引。

微调的前提不是算力，而是数据。客户提出要微调时，先问“数据在哪”。面试常问什么时候该微调，答案是三个条件同时满足才动手：任务固定，提示词与 RAG 都已用尽，手里有标注数据。

6.11　检索增强生成

RAG 的英文全称是 Retrieval-Augmented Generation，中文叫检索增强生成，也就是开卷考的完整流程：先发资料，再答题。D4 全天会动手搭建一套 RAG。RAG 的流程分五步：

1. 准备企业文档，例如 PDF，Word 与网页。
2. 切块，按段落或条目把文档切成小段。
3. 向量化，把每一段的语义转换成一组数值坐标。
4. 检索，找出与问题相关度最高的几段。
5. 把这几段拼进提示词，交给模型作答，答案可以追溯到原文。

第三步向量化用到的就是 Embedding 那张打分表。RAG 的三个优点都对应企业的实际需求：知识随文档更新，答案可以溯源，企业数据不需要用来训练模型。RAG 的边界也要讲清楚：检索不到的内容就答不出来，切块质量直接决定效果，这些是 D4 的重点。

RAG 不需要训练模型，数据也不离开企业，上线周期以周计算。这样的方案风险低，所以常被当作首选方案。

小结

榜单只能作参考，选型以自己任务的实测为准，引用榜单时还要核对口径与日期。资源用显存公式估算，费用按单价乘用量估算，路由和缓存是两种常用的省钱方法。数据能否出域决定走 API 还是私有化，实际项目多采用两者混合的方案。模型能力不足时，按提示词工程，RAG 与微调的顺序逐步增强，成本也逐级上升。

07
工具链装机

装机时链接会失效，文档会过时，能自己解决问题才算真正装完机。

7.1 装机清单

第一天要装的是一整套工具链。VSCode 是主要的开发环境，Claude Code 是结对编程的 AI 工程师，Codex 提供第二意见。Node.js 与 Python 环境是配套的基础，第一天下午的实践马上要用。

选择这一套工具有现实原因：高校通识课多在教通义灵码，而不少企业一线团队已经在用 Claude Code，学会这一套，就掌握了贴近市场前沿的工具链。

装机完成的标准是 AI 对话，生成文件和解释报错三件事各跑通一次，缺一件都不算装完。

7.2 VSCode 编辑器

VSCode 早已不只是代码编辑器。编辑器里自带命令行窗口，称为集成终端。各类功能可以通过插件添加，其中 Remote-SSH 插件能让本机的 VSCode 直接连接远程服务器，编辑服务器上的文件。客户的服务器没有图形界面，VSCode 一头连着开发者，一头连着机房，这对 FDE 尤其重要。

图中是 VSCode 的界面，左侧是代码编辑区，中间是与 AI 的对话面板，右侧是历史会话列表。

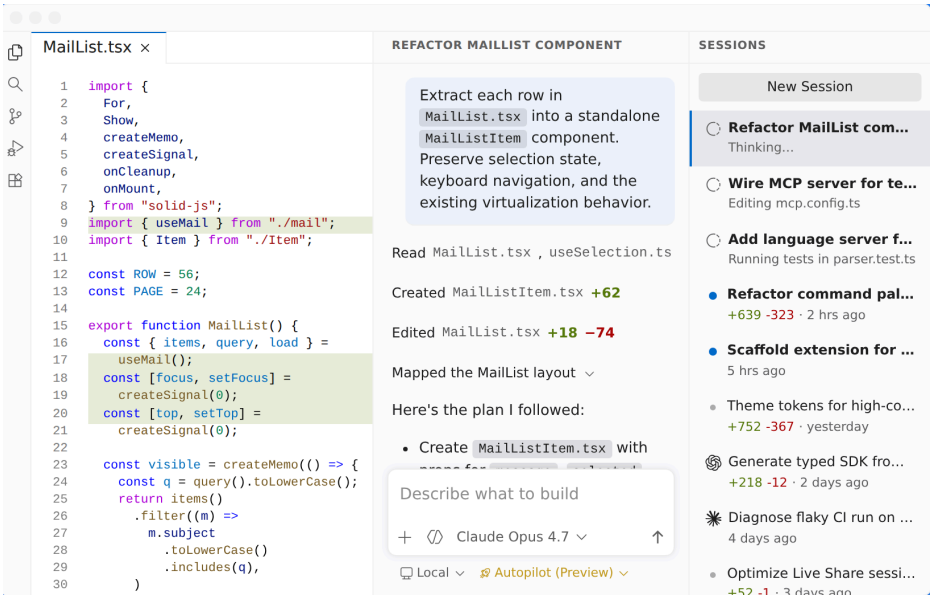


图 25　VSCode 的界面，写代码与和 AI 对话在同一个窗口里完成。来源：官网图。

第一天要装四个插件：

- 中文语言包
- Python

- Remote-SSH
- Claude Code

工具越强越要克制。十天里只会用到 VSCode 两成左右的功能，但用到的每一项都要练到熟练，形成习惯。

7.3 第一位 AI 同事

Claude Code 是学员的第一位 AI 同事，属于代理型工具，代理型的英文是 Agentic。代理型工具接到任务后，会先读取文件，再编写代码并运行命令，看到报错后继续修改，整个过程连续完成，而不是一问一答的聊天窗口。

Claude Code 修改文件或执行命令之前，会先请求用户确认，相当于自带安全带，最终决定权始终在人手里。合作时，可以把 Claude Code 看成新入职的聪明同事：背景交代得越清楚，产出越可靠。进一步，还可以在项目根目录放一份写给 AI 看的说明书，Claude Code 每次开始工作都会先读这份文件，D2 详细讲。

从第一天起，学员的产出是需求描述与验收判断，代码由 Claude Code 编写，结果由人负责。

7.4 CC Switch 切换器

CC Switch 用来给 Claude Code 切换模型供应商，相当于一键换引擎。CC Switch 是开源软件，项目获得了超过 11 万个 star。工作原理是改写环境变量 `ANTHROPIC_BASE_URL`，让 Claude Code 的请求发往各家官方提供的兼容接口。使用分三步：

1. 安装 CC Switch。
2. 选择预设的供应商，例如 GLM 或 DeepSeek，并填入对应的 Key。
3. 热切换，切换后不用重启。

CC Switch 的主界面上每一行是一家模型供应商，切换到哪一家，Claude Code 就调用哪一家的模型。FDE 常遇到三类场景：客户现场断开外网，预算受限，或者要求使用国产模型。这时工具链不用换，只换模型供应商，原有的工作流可以直接沿用。

下载时认准官方仓库 `farion1231/cc-switch`。要求付费登录的版本都是仿冒的，第三方中转服务要慎用。

7.5 常用命令行

命令行的英文缩写是 CLI。客户机房的服务器没有鼠标和图形界面，只能用命令行操作。第一天先认识常用命令，下午用到时再查。

命令	作用	说明
`pwd`，`ls` 与 `cd`	显示当前目录，列出内容与切换目录	在目录间移动的基本命令
`mkdir` 与 `cat`	新建文件夹与查看文件内容	
`grep`	在文件里搜索字符串	排查问题时常用
`curl`	在命令行发送网络请求	D3 调用 API 时主要使用
`ssh`	远程登录服务器	登录客户服务器的入口
`pip` 与 `npm`	安装 Python 与 Node 的包	分别管理两种语言的包
`python` 与 `node`	运行脚本	

Windows 学员统一使用 Git Bash 作为终端，Git Bash 随 git 一起安装，表中的命令和后续的环境命令都能在里面运行。这些命令不需要背，Claude Code 会代为输入，但每一条都要看得懂，这是验收者的底线。

7.6 国内镜像

在国内装机，下载依赖与模型要改用国内镜像，这部分可以看作装机手册的网络篇。

类别	国内镜像	用法
pip	清华 TUNA，阿里云与中科大	`pip install -i` 后接镜像地址
npm	npmmirror，也叫淘宝源	`npm config set registry` 后接镜像地址
模型	hf-mirror.com	把 huggingface.co 换成镜像域名

下载模型时必须把整个目录下载完整，safetensors 权重文件，tokenizer 分词器文件与 config 配置文件缺一不可。同一个装机脚本，在公司内网和客户现场往往要换用不同的镜像，这是 FDE 的第一课。

7.7 环境隔离与虚拟环境

装包之前，先确认进对了房间。环境隔离指给每个项目配一套独立的**虚拟环境**，英文是 Virtual Environment，一个项目一个房间。房间里有语言运行时，依赖包与配置文件，不同房间之间互不影响。Python 用 venv 创建虚拟环境，Node 侧用 nvm 管理版本，原理相同。

环境隔离有两条铁律。第一条，版本兼容先查后装，可以用 `pip list` 或 `npm ls` 查看已经安装的包。第二条，装包之前先确认自己在哪个房间。“在我电脑上是好的”是客户现场代价最高的一句话，环境隔离能预防这种情况。

进出虚拟环境的四条命令要练熟，以 Python 的 venv 为例：

命令	作用
`python -m venv .venv`	在项目目录里创建虚拟环境
`source .venv/bin/activate`	进入虚拟环境
`pip install -r requirements.txt`	按依赖清单安装所有包
`deactivate`	退出虚拟环境

Windows 上进入虚拟环境的写法不同。在 Git Bash 里用 `source .venv/Scripts/activate`，在 Git Bash 以外的 Windows 命令行里用 `.venv\Scripts\activate`。

进入虚拟环境后，提示符前面会显示环境名。装包前先看一眼环境名，再用 `which python` 确认当前使用的 Python。这一步只需几秒，却能避免装错环境后花几个小时排查。Node 侧用 nvm 管理版本，用 npx 临时运行工具包而不必全局安装，D2 的前端课会第一次用到。

7.8 git 版本控制

git 用来给作品上保险：每次存档都会记录下来，改坏了可以退回。第一天只用四条命令，后面几天逐步深入。

命令	比喻	作用
`git init`	开保险箱	在当前目录创建仓库
`git add -A`	装箱	把所有改动加入下一次存档
`git commit -m "..."`	落锁存档	提交一次存档，引号里写这次存档的说明
`git log`	看存档	查看存档历史

第一天就学**版本控制**，英文是 Version Control，原因是让 AI 大改代码之前要先存档，改坏了随时能回到上一个存档点。招聘方也会看提交历史，代码仓库的提交历史是比简历更有说服力的作品集，D9 会整理展示。第一天下午的个人主页至少要提交三次 commit，“能回退”的习惯从第一件作品开始养成。

7.9 装机自救与提问

装机时一定会遇到问题：照着教程安装，却发现链接返回 404，也就是网页不存在，或者版本不匹配。链接会失效，会搜索才是硬技能。例如教程里的模型页链接打不开，在网站内搜索，才发现原来的链接只差一个连字符。遇到报错时，按顺序使用自救三招：

1. 先读报错原文。
2. 再查官方文档。
3. 最后问 AI，提问时附上完整的报错信息与环境信息。

向 AI 提问有三要素：“你是谁，擅长什么，帮我做什么”。前两个要素写进**系统提示词**，英文是 System Prompt，作用是找对专家。第三个要素写进用户提示词，英文是 User Prompt，作用是问对问题。第一天下午与 Claude Code 的每一次对话，都是对这三要素的练习。

7.10 提示词的两层结构

提示词进阶的做法，是把三要素写成两层：系统提示词说明“是谁”，用户提示词说明“做什么”。例如系统层写“你是资深前端工程师，只输出可运行的单文件代码”，用户层写“以下是我的自我介绍，改写成首页文案，100 字内”。

层	内容	更新频率
系统提示词	角色，边界与风格	设定一次，每轮都生效
用户提示词	任务，材料与格式	每轮更新

两层各管各的内容，拼成一次请求发给模型。另有两个加分做法。一是给出一个例子，效果胜过三行形容词。二是让模型先复述需求，再开始动手。

“帮我做个网页”是不合格的问法。合格的问法写全“角色 + 任务 + 约束 + 验收”四件套，模型拿到这四项信息，就不用再猜。四件套是三要素的扩展：角色对应“你是谁，擅长什么”，任务对应“帮我做什么”，约束与验收是新增的两项。

7.11 首次对话示例

与 Claude Code 的第一次对话可以从一句提示词开始，练习的是格式化输出，也就是从一句话得到一个完整的网页。示例提示词是：“你是资深前端工程师，擅长响应式页面；帮我做一个单文件 HTML 个人主页，深色主题，含自我介绍与项目卡片”。

观察 Claude Code 的回应时，重点看三件事：怎样追问需求，怎样组织文件，怎样解释改动。这种开发方式叫“提示词驱动开发”，格式化输出的产物可以直接运行。

图中是 Claude Code 的界面，行首带加号的绿色行是这次改动新增的代码，下方是输入任务的对话框。

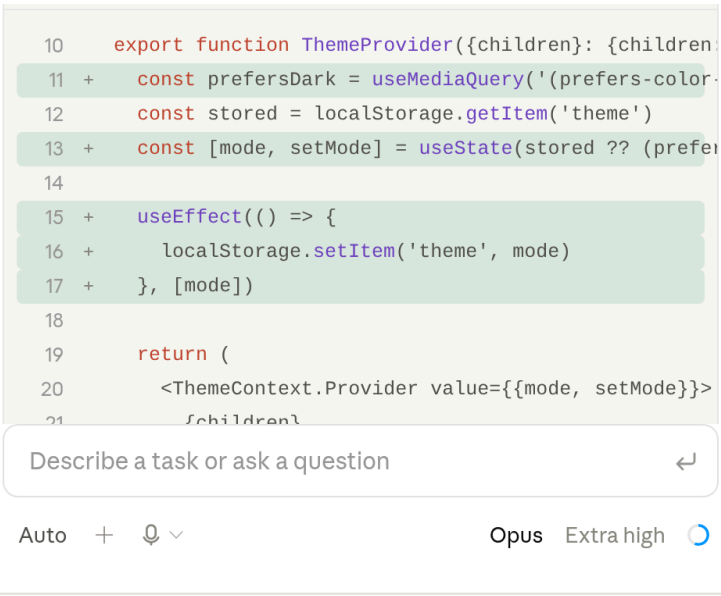


图 26　Claude Code 的界面，改动的代码逐行标出。来源：官网截图。

AI 原生开发的分工由此确定：人提出需求并作出判断，AI 编写代码并给出解释。

小结

第一天的工具链以 VSCode 为工作环境，以 Claude Code 为主力，Codex 提供第二意见，三件事各跑通一次才算装完。国内装机要准备镜像，每个项目使用独立的虚拟环境，大改代码之前先用 git 提交。装机出错时按照读报错，查文档和问 AI 的顺序自救。与 AI 对话时，用系统提示词与用户提示词两层写清四件套。

08
下午实践：本地 HTML 网页

第一天下午，学员要交付第一件作品。

8.1　下午任务

第一天下午的实践任务是用 Claude Code 做个人主页，时间为 13:30 到 17:00。任务要求交付一个单文件 HTML 个人主页，包含自我介绍，技能清单和项目卡片三块，项目卡片可以先用占位内容。开发全程通过与 Claude Code 对话完成，每一轮提示词都按三要素来写。

作品按**三层验收**检查，三层依次是跑通，看懂和能改，后一层建立在前一层之上，各层的具体指标列在验收细则里。

个人主页不只是一次练习，而是作品集的第一件作品，D9 修改简历时，会放进简历的作品链接里。预热五问的 Q1 在这里回答了一半：企业雇用的不是只会写代码的人，而是能带着 AI 完成交付的人。

8.2 三层验收细则

三层验收各有明确的指标，助教按验收表逐项检查。

层	指标	检查方法
跑通	浏览器直接打开，控制台没有红字	双击文件打开
看懂	任选两段代码，能说明作用	助教提问
能改	换主题色并加一个栏目	限时 10 分钟

提交物有三样：HTML 文件，一段 50 字的说明和至少三次 commit。50 字说明写清用了哪些提示词策略。

控制台是浏览器显示网页运行信息的窗口。查看方法是在页面上点右键，选“检查”，或者按 F12，再切换到 Console 标签，红色文字就是报错。

“跑通就行”是学生思维，“讲得清、改得动”才是交付思维，交付思维要从第一件作品开始养成。

8.3 起手式清单

第一轮提示词就要写对。每轮对话之前，先对照**起手式清单**检查一遍。起手式指开始动手时的标准写法，清单有四项：

- 角色：“你是资深前端工程师，擅长响应式单页。”
- 任务：做单文件 HTML 个人主页，包含自我介绍，技能清单和项目卡片三块。
- 约束：页面为单文件，采用深色主题，在手机和电脑上都能正常显示，不引用外部库。
- 验收：用浏览器直接打开就能使用。验收标准写清楚，AI 会自己对照检查。

写好第一轮之后，每轮只加一类需求：先搭骨架，再调样式，最后补细节，不要一次提出全部要求。这张清单不只适用于网页，十天后写方案，配置环境和排查 bug 时，第一轮提示词同样按这四项来写。

8.4 常见的坑与解法

下午的实践中，有四个问题出现的可能性很大。提前了解这些问题，遇到时就知道怎样处理。

1. 一句话提出全部需求。只写一句“帮我做个特别好看的主页”，产出必然偏离预期。解法是按起手式清单分轮推进。
2. 不读代码就要下一步。三轮之后，就看不懂自己的项目了。解法是每轮都让 AI 讲解改了什么。
3. 改坏了回不去。解法是大改之前先 `git commit`，出了问题就回到上一个存档。
4. 一报错就求助。解法是先用自救三招，依次读报错，查文档和问 AI，10 分钟内仍未解决，再向助教求助。

这四个问题都是三层验收的反面，解决这些问题的过程，就是在养成交付思维。

8.5 收尾与明日预告

第一天的收获有三样：一套认知坐标系，一套装好的工具链和一份本地跑通的主页。认知坐标系包括 AI 发展史与大模型原理，也包括能力边界与大模型格局。

复习时可以对照预热五问自查：第一天的内容已经能完整回答其中两问，能回答一半的也有两问，找出分别是哪几问。

D2 的主题是前端与 Skill 机制。学员要学会制作可以复用的技能包，而不只是做出一个页面，智能客服官网项目也在 D2 开工。实训营每天早上 9:00 进行 AI 快讯轮值，D2 的第一位轮值学员已经确定。

小结

第一天的作品是用 Claude Code 对话开发的单文件 HTML 个人主页。作品按跑通，看懂和能改三层验收，提交时附上提示词策略说明与至少三次提交记录。每轮提示词先对照起手式清单，需求分轮逐步加入。遇到问题先自救，大改之前先存档，每轮都让 AI 讲清改动。

练习与作业

复习题

1. 说明 FDE 这个岗位做什么，以及这个岗位缺人的原因。
2. 说明“知识从哪里来”这条主线把 AI 七十年分成的三个时期，以及每个时期遇到的瓶颈。
3. 写出两次 AI 寒冬共同的公式，并说明 FDE 怎样避免自己的项目重蹈覆辙。
4. 说明 token 与 API 计费的关系，并写出由业务量估算月账单的方法。
5. 说明大模型产生幻觉的三个根源。
6. 说明负责任的 AI 在事先，事中与事后三个阶段各做什么。
7. 说明海外旗舰能力更强时，落地项目仍以国产模型为主的四个理由。
8. 说明没有免费的午餐定理对模型选型的两条推论，以及读榜单时要先核对的三件事。
9. 写出显存估算的经验公式，并估算 14B 模型在 FP16 与 INT4 下各约需要多少显存。
10. 比较走 API 与走私有化在五个维度上的差别，并说明两者是否必须二选一。
11. 写出装机自救三招的顺序，并说明提问三要素与提示词四件套的对应关系。
12. 对照预热五问，找出第一天已经能完整回答的两问与只能回答一半的两问，并写出各自的答案要点。

课后作业

个人主页

个人主页在第一天下午的实践时间内完成，时间为 13:30 到 17:00。

- 任务：单文件 HTML 个人主页，包含自我介绍，技能清单和项目卡片三块，项目卡片可以先用占位内容。
- 要求：全程用 Claude Code 对话开发，每一轮提示词都按三要素来写。
- 提交物：HTML 文件，说明提示词策略的 50 字说明，以及至少三次 commit。

验收标准分三层：

- 跑通：双击文件用浏览器打开，控制台没有红字。
- 看懂：助教任选两段代码提问，学员能说明代码的作用。
- 能改：10 分钟内换好主题色，并加一个栏目。

平台注册

第一天课后至少注册三家国内大模型平台，其中 DeepSeek 必须注册，D2 前端课的第一个小时就要用到。注册之后，把同一个问题分别交给两个平台，比较回答，积累选型经验。