认知与环境

AI 发展史与大模型格局 · 模型选型与成本测算 · 工具链装机

主讲：烛龙智元 · DragonAI

DAY 1
认知与环境

DAY 2
前端 + Skill 机制

DAY 3
后端开发与模型接入

DAY 4
从 LLM 到 Agent - RAG

DAY 5
Git 协作与全栈部署

目录

01	开营·为什么是 FDE	03
02	AI 发展史·一部期望管理史	15
03	大模型白话原理	35
04	能力边界与责任	54
05	2026 大模型格局	63
06	模型选型与成本测算	71
07	工具链装机	87
08	下午实践·本地 HTML 网页	100

01

开营·为什么是 FDE

未来, 一个人的力量取决于他能调动多少个 AI 协同工作

1.1	开营第一问	04
1.2	FDE: 到底是个什么岗	05
1.3	招聘启事拆解: 市场到底要什么人	06
1.4	FDE 的一天: 先有个手感	07
1.5	智 + 能: 两千年前就定义好的岗位说明书	08
1.6	七类智能, 七条赛道	09
1.7	「人工智能」的四个经典定义 + 通行版	10
1.8	强 AI 与弱 AI	11
1.9	十天怎么走	12
1.10	这十天怎么学: 模仿 → 改写 → 编写	13
1.11	预热五问: 带着问题听完这十天	14

1.1 开营第一问

有了 AI, 人是不是可以躺平了?

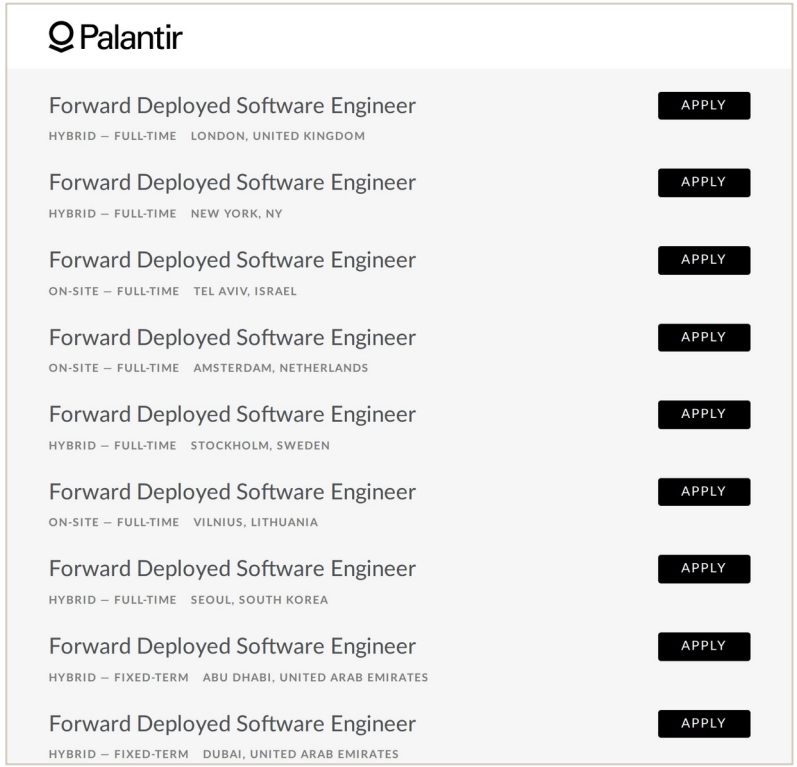
- 人工智能(Artificial Intelligence,AI)会写代码、会做设计、会读文档, 那企业还雇人干什么?
- 换一个问法:AI 能力已经过剩, **谁来把它接进一家具体的公司?**
- 缺的不是模型, 而是**把模型变成生产力的人**, 这正是你未来的岗位

本营信条 一个人的力量, 不取决于他自己多强, 而取决于他能调动多少个 AI 协同工作

今天的目标 先建立认知坐标系, 再装好吃饭的工具, 最后交付你的第一件作品

1.2 FDE: 到底是个什么岗

- 所谓 **FDE**(Forward-Deployed Engineer, 前线部署工程师), 就是驻在客户身边做 AI 落地的工程师
- FDE **一半是工程师**, 搭出能上线的应用;**一半是交付者**, 听懂需求、管好预期
- 国内招聘启事里, 它常叫解决方案工程师、交付工程师或大模型应用工程师
- 思考: 这个岗为什么缺人? 模型能力一年一跳,**会用的企业远少于想用的**



名字源自 Palantir(官网截图)

直接目标 十天之后, 你去面试的就是这类岗位——本营一切内容由此反推

1.3 招聘启事拆解: 市场到底要什么人

职位描述(Job Description,JD)高频要求逐条对照

JD 高频要求	说人话	本营对应
大模型应用开发经验	会用 API 搭出能上线的应用	D3 后端 · D6 工作流
熟悉 RAG 与知识库	会把企业文档变成 AI 的开卷资料	D4 全天
了解 Agent 框架	会让 AI 自己调用工具干活	D7 上午
私有化部署能力	会在客户机房里把模型架起来	D5 全天
客户沟通与需求分析	听得懂人话, 写得出方案	D8 – D10

读 JD 的姿势 每一条要求, 你都要能指着自己的一件作品说「这个我做过」——这十天, 攒的就是这些作品

口径 表由市面 FDE 类 JD 的高频要求归拢——注意: 几乎没有一条要求「发过论文、训过模型」

1.4 FDE 的一天: 先有个手感

驻场交付周里的一个典型工作日

- **上午 · 客户会议室**: 业务方说「想要个 AI 客服」, 你的活是把它拆成需求——接什么渠道、答哪些问题、答错了谁兜底
- **午后 · 工位**: 你要改提示词、调知识库, 把上午拆出的需求变成能点开的 Demo
- **傍晚 · 汇报**: 你给客户演示, 并**管住预期**: 能做到什么、暂时做不到什么、下周交什么
- 穿插全天的还有零碎追问:「会不会泄露数据」「这条为什么答错」——今天上午的认知课全是弹药

本质 FDE 一半时间写代码, 一半时间做翻译——在业务语言和技术语言之间来回翻

1.5 智 + 能: 两千年前就定义好的岗位说明书

荀子《正名篇》: 知有所合谓之智, 能有所合谓之能

- 荀子把「智能」拆而为二: **智**在内, 是知识与思考; **能**在外, 是动手与行动
- 映射到今天: 大语言模型(Large Language Model,LLM)即**智**, 智能体(Agent) 即**能**
- FDE 就是把「智」接上「能」、再交付给企业的那个人——又智又能



荀子(公有领域画像)

为什么先讲认知 有道无术, 术尚可求; 有术无道, 止于术——上午修道, 下午练术

1.6 七类智能, 七条赛道

加德纳《智能的结构》(1983)・多元智能理论

人的智能	对应的人工智能	你在哪天碰它
语言智能	NLP ・大语言模型	今天起, 天天见
逻辑数理智能	定理证明・代码生成	D2 – D3
空间智能	机器视觉・图像生成	D3(多模态 API)
音乐智能	语音识别・音频生成	D3(语音接口)
身体运动智能	机器人・自动驾驶	课外延伸
人际智能	对话系统・情感计算	D4(智能客服)
内省智能	Agent 的自我反思	D7

重要结论 「人工智能」不是一个东西, 而是一族技术——人的每类智能都在被逐一模拟

1.7 「人工智能」的四个经典定义 + 通行版

麦卡锡: 让机器的行为, 看起来像人所表现出的智能行为



麦卡锡(CC)

明斯基: 让机器去做那些过去只有人的智能才能做到的事



明斯基(CC)

尼尔逊: 关于知识的表示、获取与使用的学科



尼尔逊(CC)

温斯顿: 研究如何让计算机做过去只有人才能做的智能工作



温斯顿(CC)

通行表述 模拟、延伸和扩展人的智能的理论、方法、技术及应用系统

层级关系 人工智能 ⊃ 机器学习 ⊃ 深度学习——面试常见辨析题

1.8 强 AI 与弱 AI

把客户的科幻拉回工程

- **强 AI** 是指机器拥有心智与通用智能——至今只存在于论文与科幻里
- **弱 AI** 则是在具体任务上替代或超越人——人脸、车牌、下棋、聊天全是
- 思考:ChatGPT 是不是强 AI? 其实它只是「语言弱 AI」, 并没有自我

能力谱系 →

弱 AI · 专用智能	**强 AI / AGI · 通用智能**	**ASI · 超级智能**
人脸识别 · 下棋 · ChatGPT...	尚未实现	科幻与假设

今天所有落地的 AI,全部在这里

能力谱系: 今天所有落地的 AI 都在最左段(重制)

FDE 翻译术 客户要「什么都会的 AI」, 你要翻成「几个具体任务的弱 AI 组合」

压舱底线 AGI 何时到来无人能保证——方案里永远不要卖还不存在的东西

1.9 十天怎么走

每天下课, 手里都多一件硬产出

- **D1–D5 能力构建**: 沿环境 → 前端 → 后端 → RAG → 部署推进, 贯穿一条智能客服主线
- **D6–D10 产品化与就业**: 依次走过工作流 → Agent 与评测 → Demo Day → 简历与面试
- **大作业**在 D5 领题(真实客户业务), 周末与 D6/D7 下午开发, 到 D8 全天验收

学习方法 每天下午的实践, 都沿「模仿 → 改写 → 编写」这架梯子往上爬

每日惯例 开课前 10 分钟「AI 快讯轮值」——从今天起, 你要保持在行业信息流里

1.10 这十天怎么学: 模仿 → 改写 → 编写

三级爬梯, 无数工程师验证过的公共经验

- **模仿**是指照着做、先让它跑起来——不求甚解在这一级是美德
- **改写**是指改一处、看什么变了——理解往往藏在「改坏了」的那一刻
- **编写**则是从空白文件开始, 做出自己的版本——到这一级才算你的
- 从今天起养成两个习惯: **报错是教材**(读完再问); **先问 AI, 再核证**(别背, 会问)

进度设计 每天下午的实践按这三级排: 上手任务 = 模仿, 进阶任务 = 改写, 大作业 = 编写

1.11 预热五问: 带着问题听完这十天

每一问都标了收口日——今天起沿途埋砖, 到那天用作品收口

Q1	AI 都能写代码了, 企业为什么还雇你? 你卖的是什么?	D8 • D9
Q2	客户问「你们的 AI 会不会出错」, 你怎么答?	D7
Q3	同一个任务, 选 GPT 还是 DeepSeek? 凭什么?	今天上午
Q4	客户数据绝不能出公司, 方案怎么做?	D5
Q5	你没有 AI 行业经验, 凭什么要你?	D10

提示 面试官问的, 客户也会问——这五问就是你未来的日常

02

AI 发展史·一部期望管理史

AI 的每一次寒冬，都是承诺超过交付的代价

2.1	AI 出生前的三个准备：理论·机器·思想	16
2.2	图灵机：一条纸带划定「可计算」	17
2.3	图灵测试三连：从 1950 到手机验证码	18
2.4	达特茅斯会议：这桌饭有多贵	19
2.5	七十年速览：三次浪潮·两次寒冬	20
2.6	第一次浪潮：感知机点燃的狂热	21
2.7	第一次寒冬：莱特希尔报告	22
2.8	第二次浪潮：专家系统赚到了真钱	23
2.9	第二次寒冬：崩在维护成本上	24
2.10	深蓝：符号主义的巅峰一战	25
2.11	第三次浪潮：三支箭同时到位	26
2.12	AlphaGo：三大路线握手言和	27
2.13	一根主线看七十年：知识从哪里来	28
2.14	三大学派：各自模拟人的什么	29
2.15	FDE 视角重读历史：寒冬的公式	30
2.16	规模的体感：从一张糊猫到一部短片	31
2.17	Scaling Laws：大力出奇迹的定量版	32
2.18	涌现：规模跨过阈值，能力突然出现	33
2.19	大模型专属时间轴：从论文到你的工位	34

2.1 AI 出生前的三个准备: 理论·机器·思想

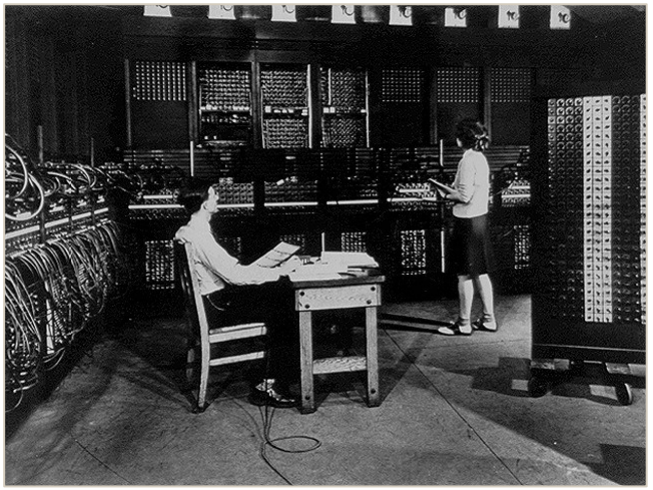
理论准备 • 1936: 图灵机划出了「可计算」的边界。

机器准备 • 1946: 第一台通用电子计算机 ENIAC 在宾夕法尼亚大学诞生。

思想准备 • 1951: 明斯基造出第一台神经网络计算机,「学习」进入机器。



图灵 • 1936 提出图灵机(公有领域)



ENIAC • 1946(公有领域)



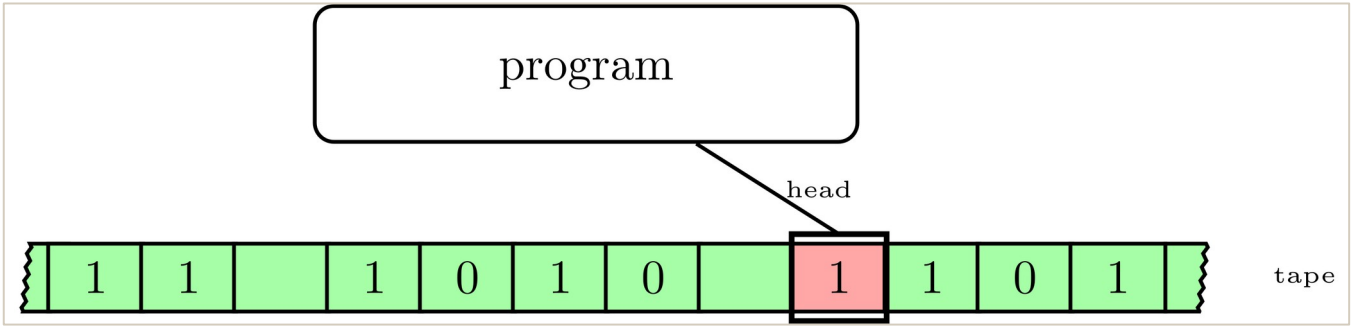
马文 • 明斯基(CC 照片)

面试弹药 「AI 之父是谁」有两个答案: 理论之父图灵, 命名之父麦卡锡——本节先后登场

2.2 图灵机: 一条纸带划定「可计算」

1936《论可计算数》· 一切计算机的理论模型

- 所谓图灵机(Turing Machine), 就是「纸带 + 读写头 + 规则表 + 状态 + 移动」五个零件构成的抽象计算模型(下图)
- 凡「可计算」的它都能算, 即**划出了计算的边界**



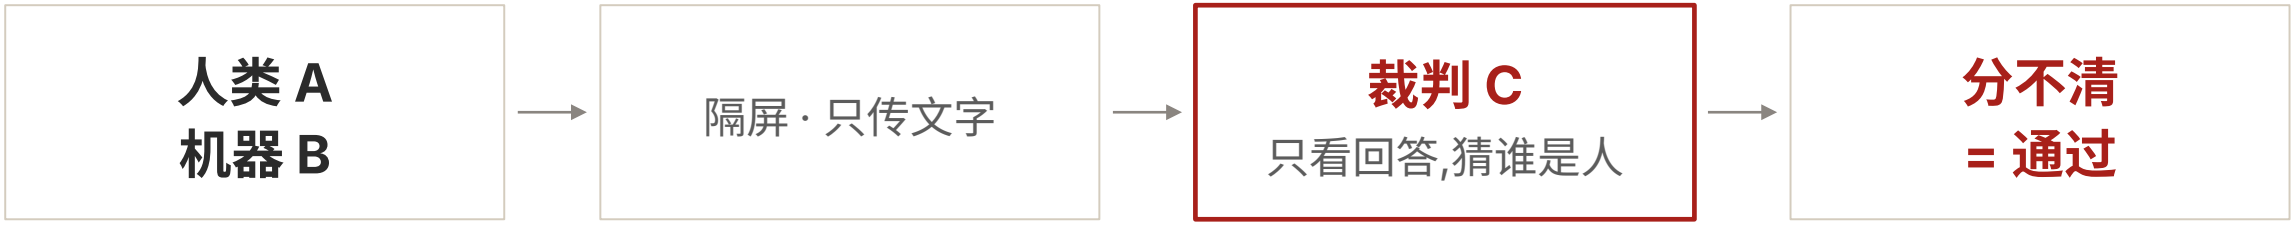
纸带 + 读写头 + 程序: 全部家当(CC 转引)

FDE 视角 「理论上能算」与「工程上算得动」是两回事, 每一次寒冬都栽在这条沟里

面试弹药 图灵机是可计算性的数学模型; 冯 · 诺伊曼机则是存储程序的工程模型

2.3 图灵测试三连: 从 1950 到手机验证码

- **图灵测试**(Turing Test,1950):隔屏问答, 裁判分不清即算通过;30% 本是图灵对 2000 年的预测;2014 年 Eugene Goostman 以 33% 首次「通过」(带引号)。
- **逆向图灵测试**: 你每天划的滑块验证码——这回是机器在验证你是不是人。
- **中文屋**(塞尔): 照规则搬符号, 算不算「理解」? 午饭聊。



模仿游戏: 裁判只看文字, 分不清就算过(重制)

面试弹药 这三个典故三十秒讲完; 面试聊「AI 边界」时的从容, 正是这么来的

2.4 达特茅斯会议: 这桌饭有多贵

1956 · 人工智能在此得名

- **1955 年 8 月**, 麦卡锡(达特茅斯)、明斯基(哈佛)、香农(贝尔实验室)、罗切斯特(IBM)四人联名提案,
  提案中**首次写下 Artificial Intelligence** (人工智能) 一词。
- 洛克菲勒基金会出资,**1956 年夏**开会研讨「模拟人的智能」
- 与会者的成色:4 位图灵奖 + 1 位诺奖(西蒙) + 香农 + 塞弗里奇。



与会学者合影(转引 · 人名现场点)

记住这一年 1956 = 现代 AI 元年; 可神仙们也没管住世界的期望——接着看代价

2.5 七十年速览: 三次浪潮·两次寒冬

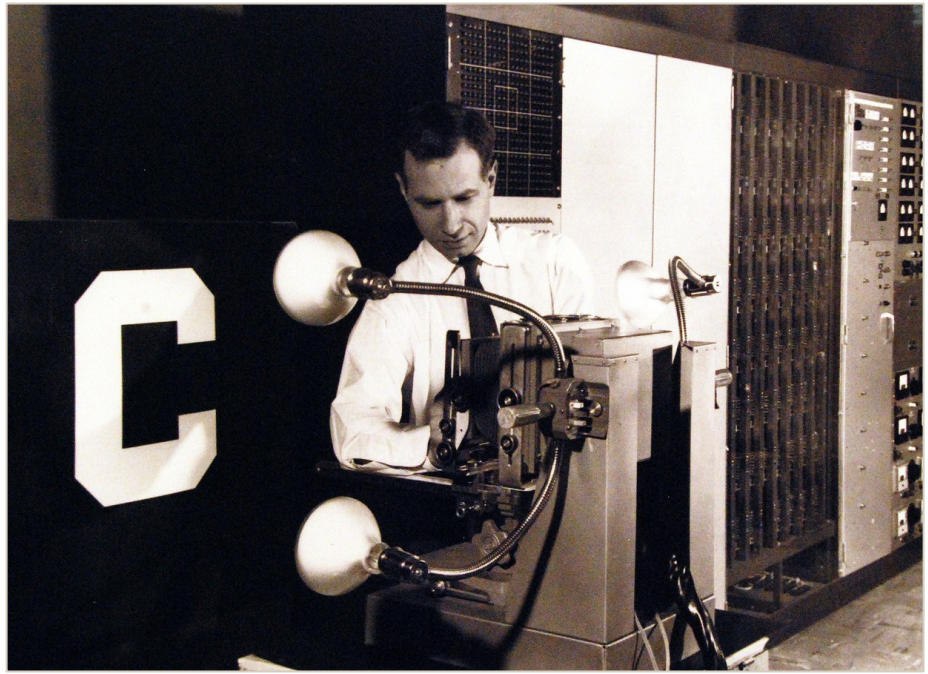
年表 · 讲到你入行为止——本节接下来逐段放大

年份	事件	潮汐
1956	达特茅斯会议; 次年感知器问世	第一次浪潮起
1965	Dendral: 第一个专家系统	
1973	莱特希尔报告:「只能解决玩具问题」	第一次寒冬
1980	XCON 专家系统商用;BP 算法(1986)	第二次浪潮起
1987	Lisp 机市场崩盘; 五代机随后未达目标	第二次寒冬
1997	深蓝胜卡斯帕罗夫;LSTM 提出	
2006	Hinton 深度学习; 次年 ImageNet 立项	第三次浪潮起
2012	GPU 算力突破, 深度学习起飞	
2016	AlphaGo 胜李世石	
2017	Transformer:Attention Is All You Need	
2022	ChatGPT, 大模型时代引爆	全面爆发
2024	Sora 文生视频;DeepSeek 登场	你入场的前夜

2.6 第一次浪潮: 感知机点燃的狂热

1957 · 罗森布拉特 · Mark I

- 罗森布拉特的 **Mark I 感知机 (Perceptron)** 用光电单元「看」字母、自动调权重, 是第一台**从样例中学习**的机器。
- 《纽约时报》写它是「能走路、说话、看东西、写字的电子计算机的胚胎」。
- 1969 年, 明斯基与佩珀特出版《感知机》一书: 单层网络连「异或」都学不会, 狂热应声降温。



罗森布拉特与 Mark I(公有领域)

熟悉的配方 头版吹上天 → 数学泼冷水 → 预算撤退, 这个剧本后面还要重演

2.7 第一次寒冬: 莱特希尔报告

1973 · 英国政府委托评估 AI 二十年成果

- 报告结论只有一句话:AI「只在玩具问题上成功」, 离承诺的通用智能遥遥无期。
- 技术根子是**组合爆炸**(Combinatorial Explosion): 搜索空间随问题规模指数增长, 当年的算力啃不动真实问题。
- 后果是英国基本砍停 AI 经费, 美国跟进收缩; 此后十年,「AI」在经费申请书里是个脏词。

记一条铁律 预算的耐心只有几年, 承诺必须落在预算周期内能交付的东西上

今日回声 客户问「多久见效」时, 你答案的量级(周 / 月) 就是从这条铁律来的

2.8 第二次浪潮: 专家系统赚到了真钱

1965 – 1987 · AI 第一次成为生意

- 所谓专家系统(Expert System), 就是**知识库**(if–then 规则) 加**推理引擎**(照规则推导)。
- 里程碑有 DENDRAL、MYCIN 与 **XCON** (1980, 替 DEC 配置订单, 一年省数千万美元)。
- 1982 年, 日本「五代机」立项跟注。



VAX-11/780(CC 转引)

重要结论 AI 不必「通用」也能创造商业价值; 专用系统解决具体问题, 到今天仍是正道

2.9 第二次寒冬: 崩在维护成本上

1987 – 1993

- **1987** 年专用 Lisp 机市场一夜崩盘: 通用工作站和 PC 更便宜更快。
- **知识获取瓶颈**是指: 规则靠工程师访谈专家一条条手写, 结果**写不动、改不完、互相打架**。
- **1992** 年五代机未达目标而收场, 第二次寒冬就此封冻全球。



一台 Lisp 机(CC 转引)

FDE 视角 系统上线只是开始, 维护成本才是杀死项目的头号杀手, 报价时要算进去

2.10 深蓝: 符号主义的巅峰一战

1997 · 机器首胜人类棋王

- 5 月,IBM 深蓝以 3.5 : 2.5 战胜国际象棋世界冠军卡斯帕罗夫。
- 它的底牌不是「理解棋」, 而是**每秒搜索约两亿个局面**, 外加大师手写的评估函数与开局库。
- 它下不了围棋, 也不会跳棋; 作为纯粹的专用智能, 换个任务就得从零再来。



深蓝主机(CC 转引)

记法 深蓝赢在「算得多」; 十九年后的 AlphaGo 则赢在「学得会」, 两页之后见

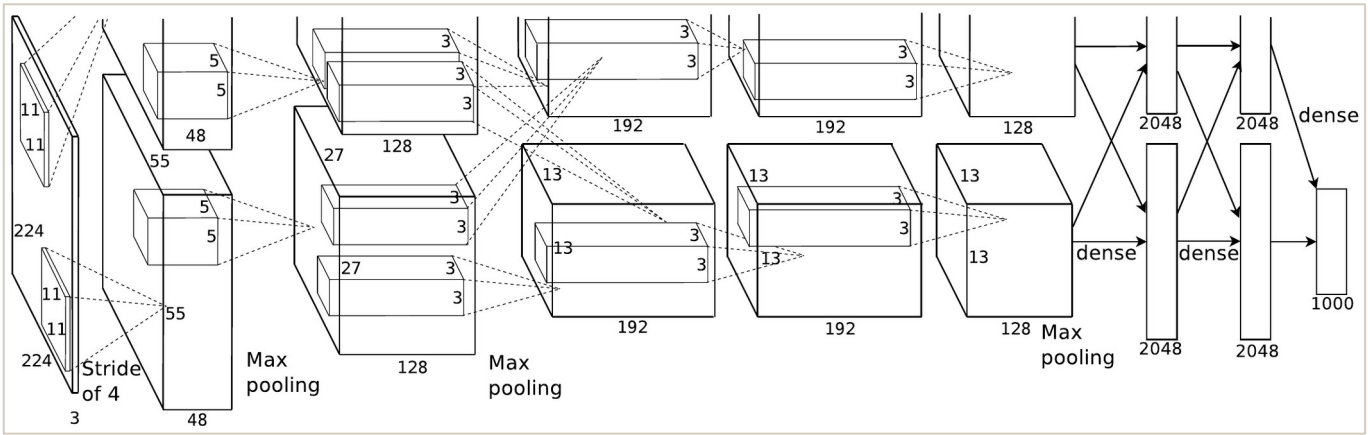
2.11 第三次浪潮: 三支箭同时到位

算法 · 数据 · 算力——缺一支都点不着

算法 · 2006: 辛顿让「深」网络第一次训得动——**深度学习**得名

数据 · 2009:ImageNet 上线, 众包标注攒到 1400 万张(李飞飞)

算力 · 2012:AlexNet 用两张游戏显卡(下图), 错误率 26% →16%



AlexNet 的双 GPU 流水线(论文图 · 转引)

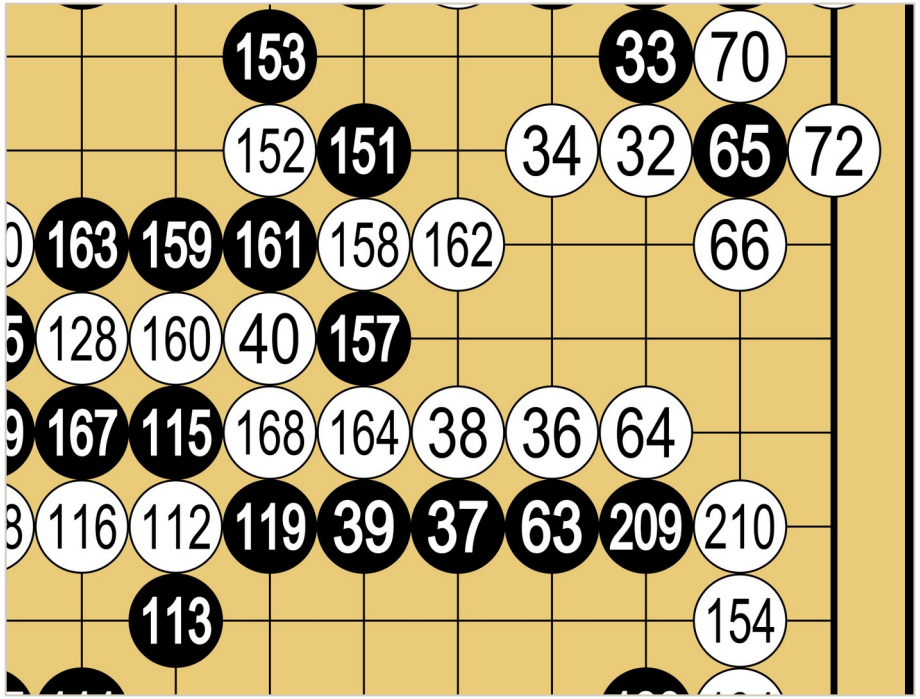
重要结论 前两次浪潮死于「想法超前于资源」; 这一次, 资源终于追上了想法

记法 GPU 本是打游戏的; 通用算力的溢出效应, 是技术浪潮的常见剧情

2.12 AlphaGo: 三大路线握手言和

2016 · 深蓝之后十九年

- 3 月它以 4 : 1 胜李世石; 围棋局面数远超宇宙原子数, 暴力搜索此路不通。
- 配方是三家各出一味: **神经网络**估局面 + **树搜索**选着法 + **自我对弈强化学习** (RL)。
- 第二局第 37 手(右图) 让解说直呼「非人类」, 机器第一次展示出「棋风」。



第 2 局 · 第 37 手一带(CC 转引)

方案启示 现代 AI 系统全是混合系统; 你未来的方案也一样: 大模型 + 检索 + 规则, 各取所长

2.13 一根主线看七十年: 知识从哪里来

推理期→知识期→学习期

时期	年代	思路	卡在哪
推理期	1956 – 70s	智能 = 逻辑推理, 教机器推理	光会推理, 肚里没知识
知识期	70s – 90s	智能 = 知识, 人工把知识灌进去	知识写不动、维护不起
学习期	90s – 今	智能 = 学习, 机器自己从数据学	数据与算力的军备竞赛

- 思考: **知识从哪里来**? 三次转段转的都是这个问题——人写不动, 只好让机器自己学。

面试弹药 被问「AI 发展脉络」时别背年份, 讲这条「知识来源」主线, 高下立判

2.14 三大学派: 各自模拟人的什么

符号主义・联结主义・行为主义

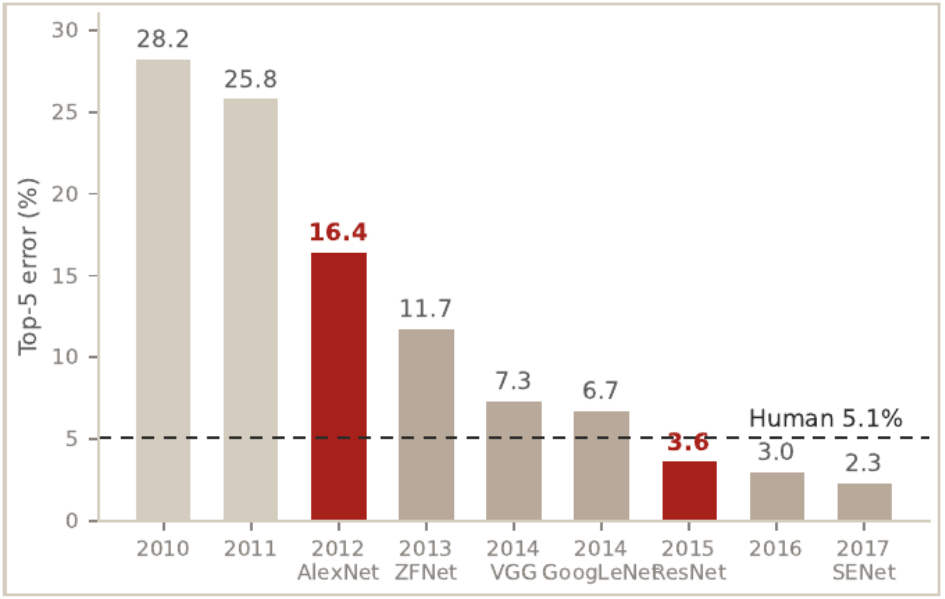
学派	模拟对象	技术路线	短板	代表作
符号主义	人的心智	知识表示 + 逻辑推理	脆弱, 跟不上变化	专家系统・深蓝
联结主义	脑的结构	神经网络, 从数据学	黑盒, 耗算力	AlexNet ・ChatGPT
行为主义	人的行为	强化学习, 试错得奖惩	试错成本高	AlphaGo ・自动驾驶

- 今天的主流是联结主义(Connectionism); 客户问「AI 为什么解释不了自己」, 根子就在这。
- 可解释的活儿(风控、合规校验) 仍是符号主义(Symbolism) 的地盘, 即**规则引擎兜底大模型**。

方案启示 三个学派不是历史名词, 而是你工具箱的三个格子; 好方案常常三格都开

2.15 FDE 视角重读历史: 寒冬的公式

- 两次寒冬的死法相同: **承诺超过交付, 预算就会消失**。
- 承诺会自己膨胀: 媒体加一层, 甲方再加一层; 你不主动管理, 它就失控。
- 右图是反例: 第三次浪潮里交付(错误率)追上了承诺, 热潮才没有熄火。



第三次浪潮: 交付追上承诺(重制)

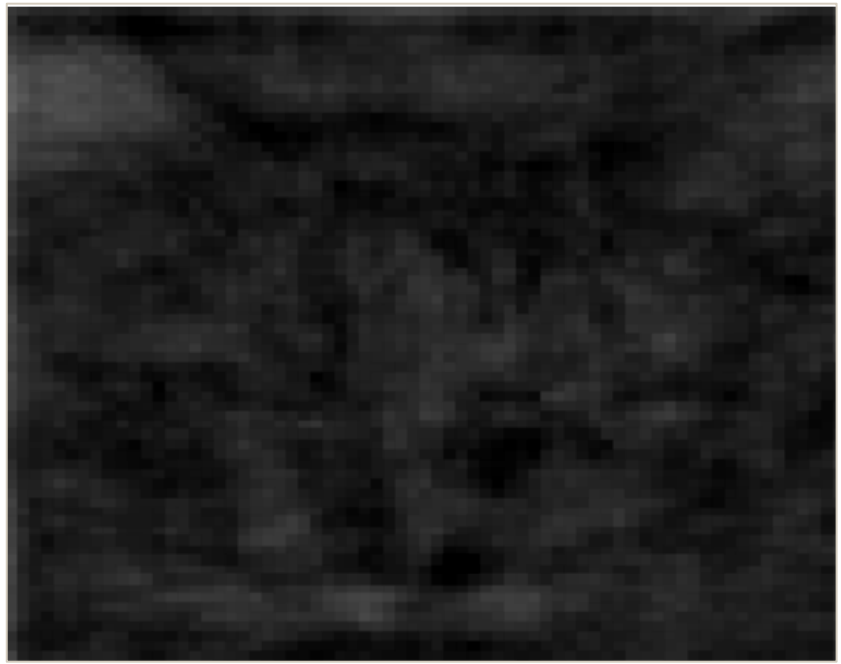
FDE 的日常 管好客户期望、按里程碑交付, 不让第三次寒冬发生在你的项目里

预热五问 Q2 「AI 会不会出错」的答案从承认边界开始, 本节先埋下第一块砖

2.16 规模的体感: 从一张糊猫到一部短片

- **2012 · 谷歌猫脸实验**:1.6 万核 CPU 加一千万张图片训练 3 天, 产出一张模糊猫脸。
- **今天**: 一句话生成短片——变的是**数据 × 算力 × 参数**

模型	年份	参数
GPT-1	2018	1.17 亿
GPT-2	2019	15 亿
GPT-3	2020	1750 亿
GPT-4	2023	约 1.8 万亿



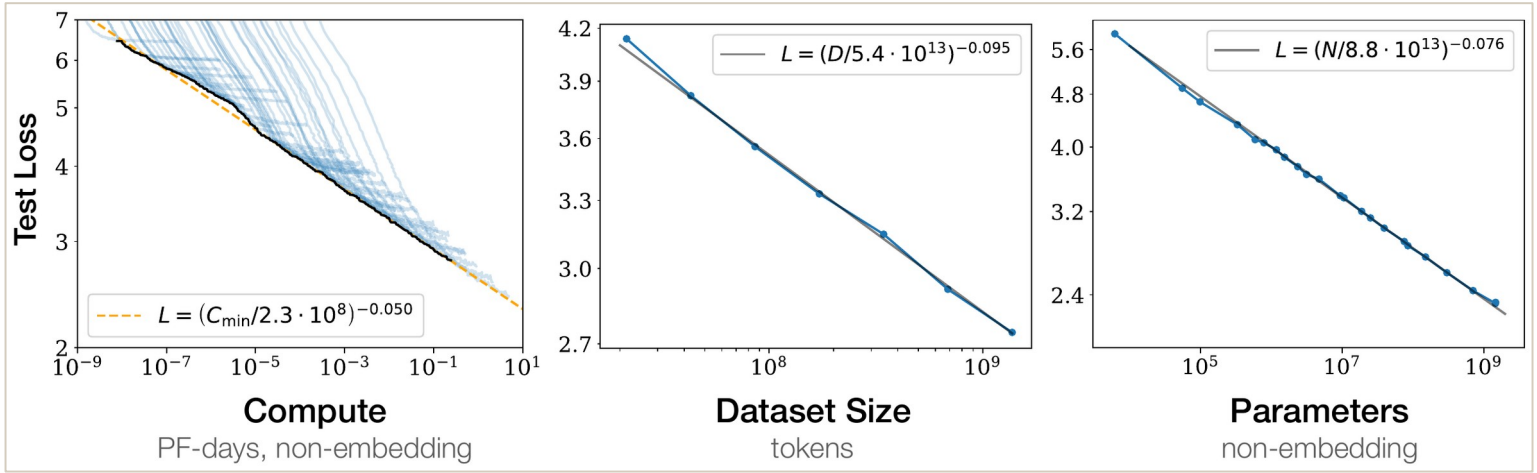
那张猫脸(论文原图)

备注 GPT-4 参数系业界估算——对客户报数注明口径, 是职业习惯

2.17 Scaling Laws: 大力出奇迹的定量版

Kaplan et al., 2020 ——规模竞赛的理论许可证

- 缩放定律(Scaling Laws),OpenAI 实测: 损失随**算力、数据、参数**按**幂律**下降
- 砸钱由此从赌博变成投资: 1750 亿参数就是按曲线下的注。
- 续集 Chinchilla(2022): 参数与数据要**配比**着长, 否则白搭。



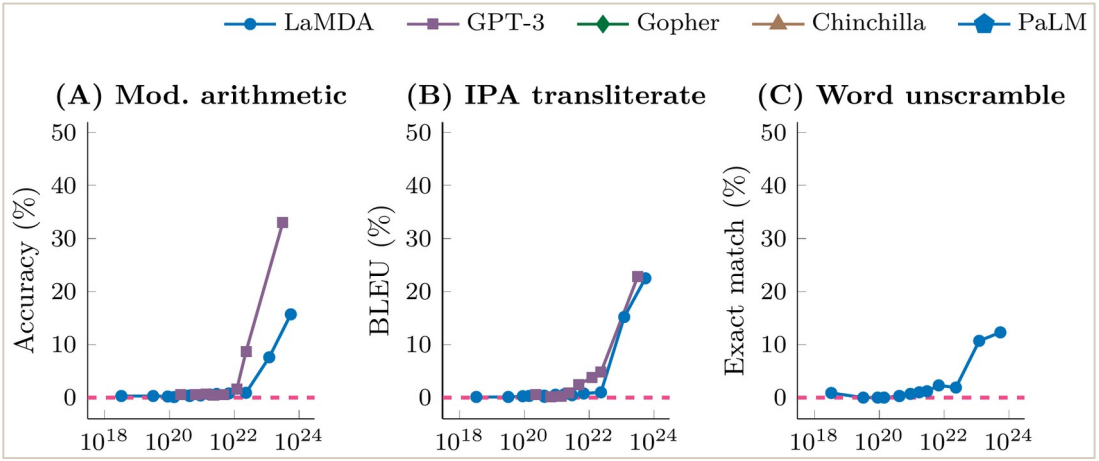
损失随算力 / 数据 / 参数幂律下降(论文图 · 转引)

看懂军备竞赛 这三条直线撑起了此后每一轮千亿融资——「数据枯竭」由此成为热词

2.18 涌现: 规模跨过阈值, 能力突然出现

Wei et al., 2022

- 所谓涌现(Emergence): 算术、解词谜这类任务, 中小模型得分≈乱猜, **跨过某个规模突然起跳**(右图)。
- 思考: 涌现是真能力, 还是打分方式造成的视觉假象? 学界仍在争论, 两说都要知道。
- 对你的意义: 模型能力**无法从小模型外推**, 换模型必须重新实测。



三个任务同时起跳(论文图 · 转引)

伏笔 「必须实测」这四个字, 到选型那节课有个定理给它撑腰

2.19 大模型专属时间轴: 从论文到你的工位

2017–2026 · 后半段就是你要吃饭的行当

时间	事件	意义
2017.06	Transformer	自注意力, 可并行, 一切的地基
2018	GPT-1 · BERT	生成与理解两条路线分野
2020.05	GPT-3	1750 亿参数, 少样本能力涌现
2022.11	ChatGPT	对话式 AI 走进大众
2023.02	LLaMA 权重开放(研究许可)	开放权重冒头 · 7 月起开源商用
2023.03	GPT-4	多模态, 能力天花板抬升
2024	GPT-4o · o1 · DeepSeek-V3	全模态与推理模型之年
2024.11	MCP 发布	工具接入标准化,Agent 的插座
2025.01	DeepSeek-R1 开源	低成本推理, 行业价格重估
2025-26	Agent · Claude Code 普及	从「会聊天」到「会干活」

重要结论 价值重心正从「模型本身」移向「把模型接进业务的人」, 后者就是你

03

大模型白话原理

搜索是找, 生成是造

3.1	生成式 AI 与搜索引擎的分野	36
3.2	六个基本名词, 一页说清	37
3.3	Token: 大模型的计量单位与计费单位	38
3.4	Embedding: 一张给万物的打分表	39
3.5	注意力机制(Attention): 类比与例句	40
3.6	Transformer: 一条流水线, 几个工位	41
3.7	一套骨架, 三种用法:BERT ·GPT ·T5	42
3.8	现场演示①: 大模型的五脏六腑	43
3.9	为什么同一个问题, 两次答案不一样	44
3.10	预训练: 一场读完互联网的通识教育	45
3.11	对齐: 从「会补全」到「肯听话」	46
3.12	上下文窗口: 模型的工作记忆	47
3.13	推理模型: 先打草稿, 再给答案	48
3.14	一句话进大模型的完整旅程	49
3.15	大模型会一本正经地错	50
3.16	幻觉: 它不是在撒谎, 它在补全	51
3.17	多模态: 模型长出了眼睛和耳朵	52
3.18	文生图白话:CLIP 懂话, 扩散作画	53

3.1 生成式 AI 与搜索引擎的分野

同一首《天净沙・秋思》的两种命运

- 所谓**生成式 AI**(Generative AI,GAI), 就是能造出世上原本没有的新内容的模型——有惊喜, 也有幻觉(稍后见)
- 若交给**搜索引擎**, 则检索出**已经存在**的图——**找**; 若交给**生成模型**, 则产出**世上没有过**的画——**造**



通义万相依这首小令生成的四幅水墨——世上原本没有这四幅画(转引)

客户话术 「搜索是找, 生成是造」——给非技术客户解释生成式 AI, 一句够用

3.2 六个基本名词, 一页说清

面试与客户沟通的最小词汇表

名词	一句话
AIGC	AI 生成的内容(文字、图、音、视频)
GAI	生成式 AI ——会「造」内容的那类 AI
LLM	大语言模型: 数据大、参数大、耗资大
GPT	生成式预训练 Transformer, 一种模型架构
ChatGPT	OpenAI 用 GPT 做的聊天产品
AGI	通用人工智能: 领域无关、任务无关——尚未实现

层级关系 深度学习模型⊃预训练模型⊃生成式大模型⊃大语言模型

3.3 Token: 大模型的计量单位与计费单位

- 所谓 **token**(词元), 即模型读文本的最小单位:9 字实测 16 token(下图)
- 词表是门平衡术:《通用规范汉字表》8105 字,《牛津英语词典》60 万词——切太碎句子变长, 切太粗词表爆炸
- 为什么要懂: **API 按 token 计费**, 中英文可差数倍



这 9 个字→实测 16 个 token → 每个都有数字 ID(截图)

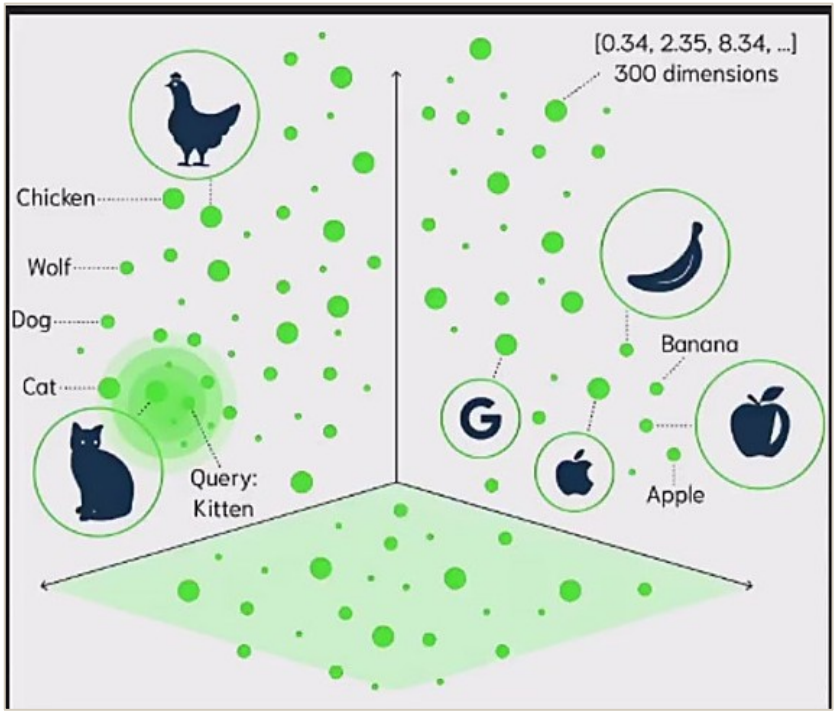
选型课用到 帮客户估算成本, 第一步就是把业务量换算成 token 量——本页是地基

3.4 Embedding: 一张给万物的打分表

词向量 · 语义都是数

词	水果	公司	手机	粮食
橘子	0.92	0.23	0.02	0.19
苹果	0.96	0.77	0.85	0.15
小米	0.08	0.81	0.98	0.87
华为	0.02	0.93	0.95	0.01

- 所谓**词嵌入**(Embedding), 就是把语义变成一组数, **相近的意思离得近**
- 语境不同则向量不同:「农民的苹果歉收」≠「苹果的用户增加」

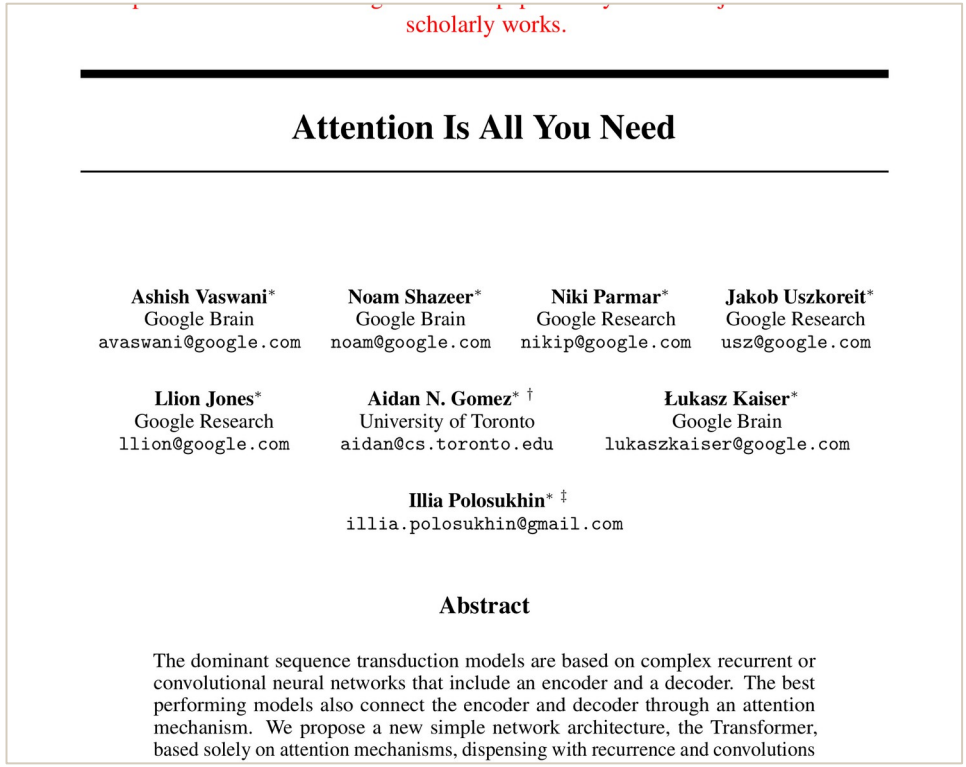


近义即近邻(转引)

伏笔 D4 知识库检索(RAG)就建在这张打分表上——到时候你会亲手用它

3.5 注意力机制(Attention): 类比与例句

- **鸡尾酒会效应**: 满屋嘈杂, 你仍听得清对面的人——大脑在分配注意力
- **没有注意力**= 死记硬背整本书; **有注意力** = 回原文划重点
- 经典例句(出自 Transformer 团队的官方解读): The animal didn't cross the street because **it** was too tired ——it 指动物; 把 tired 换成 wide,it 就指街道: 注意力随语义消歧



scholarly works.

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions

2017 · 一篇论文改变行业(转引)

重要结论 所谓注意力, 就是让模型学会「看哪里、重点关注哪里」, 而非一视同仁

3.6 Transformer: 一条流水线, 几个工位

所谓 Transformer:2017 年提出, 沿用至今的大模型骨架

- 读入: 分词→词嵌入 + **位置编码**(词序补回来)
- 主体: 几十层堆叠, 每层两道工序——**自注意力**(全句找关联)+ **前馈**(逐位加工)
- 输出: 对「下一个 token」给出整个词表上的概率分布
- 上一代网络逐字串行, 它则**整句并行**——规模竞赛由此成为可能

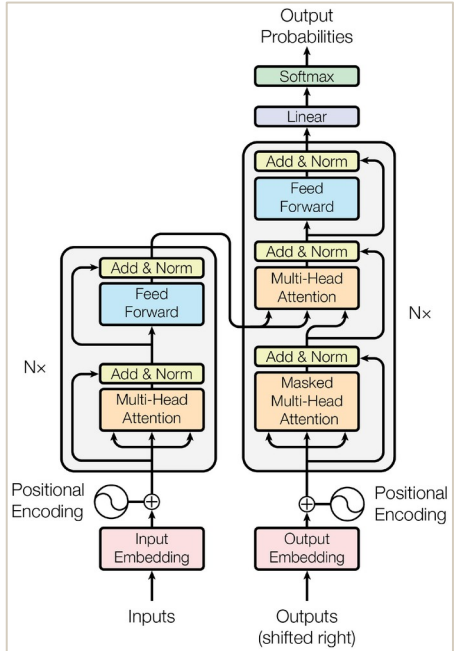


Figure 1: The Transformer - model architecture.

原论文架构图(转引)

记法 注意力管「看哪里」, 前馈管「想什么」——堆得越深, 想得越深

3.7 一套骨架, 三种用法:BERT ·GPT ·T5

架构	只用哪半	擅长	代表场景
BERT(2018)	编码器	理解: 分类、抽取	搜索引擎排序
GPT(2018)	解码器	生成: 续写、对话、代码	ChatGPT 一族
T5(2019)	编码器-解码器	翻译式: 文本进文本出	早期统一框架

编码器栈(读)

解码器栈(写)

T5:全都要
(翻译式)

BERT:只用左半 · 理解

GPT:只用右半 · 生成

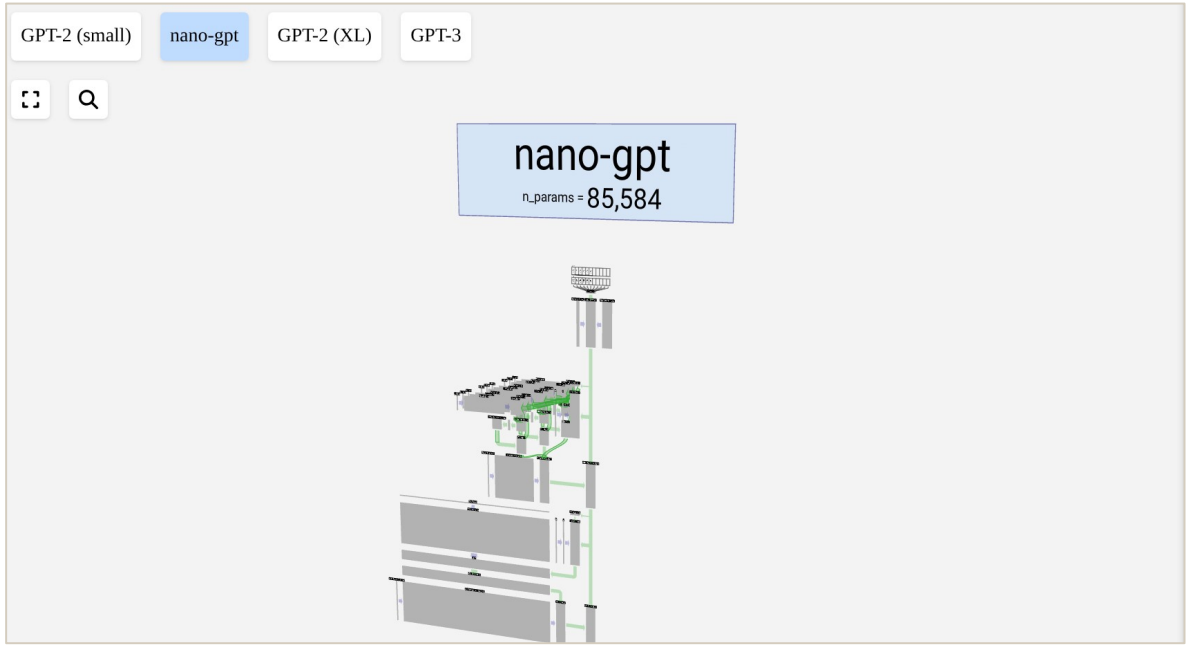
同一副骨架, 三种拆法(重制)

思考 为什么 GPT 胜出? 生成能模拟一切任务——聊起 BERT 你也要接得住

3.8 现场演示①: 大模型的五脏六腑

bbycroft.net/llm ・再用 AI 讲 AI

- 打开页首这个网址, 选 **nano-gpt**(8.5 万参数)——看它把 CBABBC 排成 ABBBCC, 逐层过 Embedding →Attention → 输出
- 切到 **GPT-3** 视图: 同样的结构, 体量放大两百万倍——规模自己会说话
- 回到 **Claude**(Anthropic 的对话 AI, 稍后装的 Claude Code 是它的编程版):「请通俗解释注意力机制」——**用 AI 讲 AI**



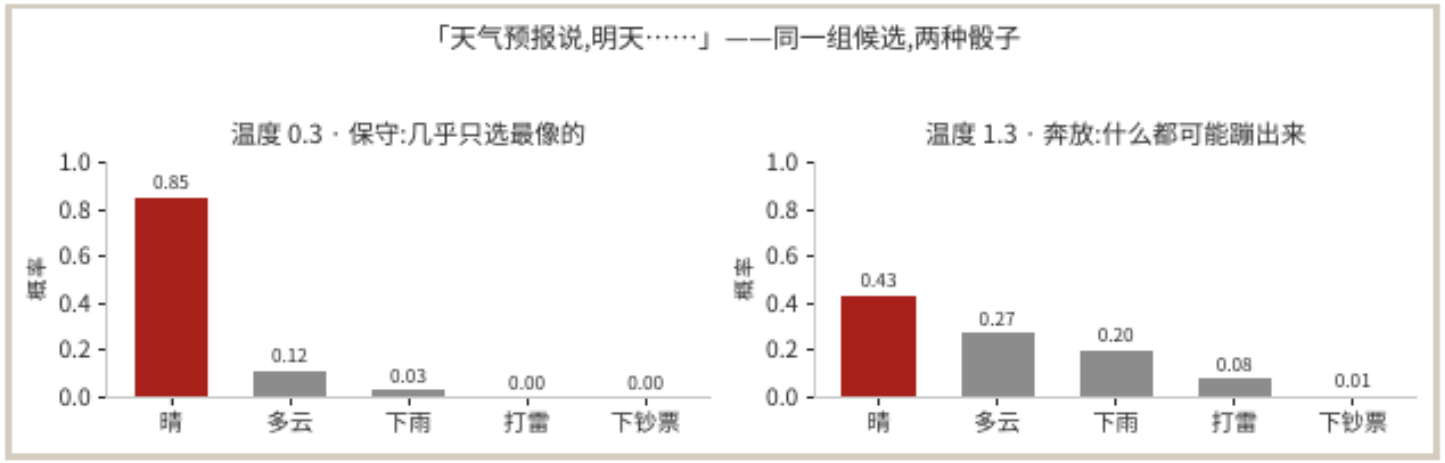
nano-gpt ・85,584 参数(截图)

顺便学会的事 这就是你今后查概念的标准姿势: 先问 AI, 再核证——别背, 会问

3.9 为什么同一个问题, 两次答案不一样

自回归(Autoregressive)+ 采样:「手抖」是设计的

- 所谓**自回归**, 就是逐 token 往外蹦——每一步都在整个词表上掷骰子
- **temperature**(温度) 就是骰子的形状——演示与评测, **先把温度调低**



同一组候选, 两种骰子: 低温收敛, 高温放飞(重制)

客户话术 「答案会变」不是故障, 是生成模型的天性——要稳定就固定参数、加模板、上评测

下午就用 同一句提示词让 Claude Code 重做, 结果不完全一样——原因就在这一页

3.10 预训练: 一场读完互联网的通识教育

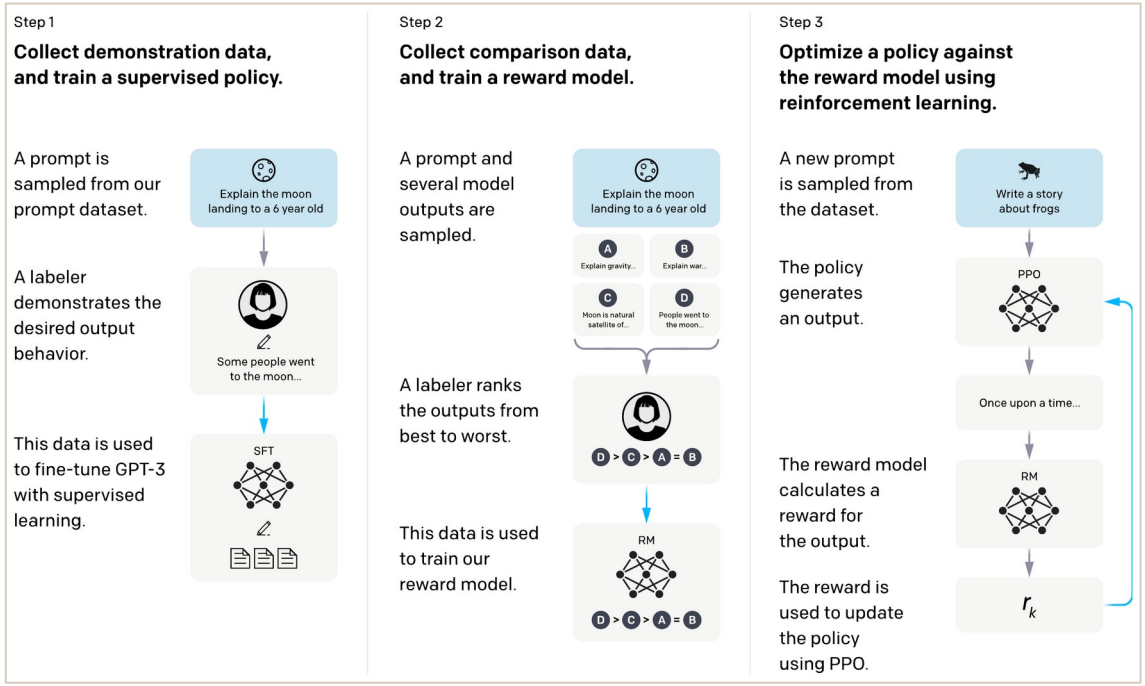
- 所谓**预训练**(Pre-training), 就是用一个简单到难以置信的任务读完互联网:**预测下一个词**——猜错就调参数, 重复万亿次
- 为什么这能学出知识? 要把「巴黎是法国的____」猜对, 就得把地理装进参数——**记住知识是猜词的副产品**
- 语料配比是门手艺: 网页、书籍、代码、论文——代码占比高的模型, 推理往往更强

类比 预训练 = 通识教育: 读万卷书, 但不针对任何岗位——上岗前还差一步「入职培训」, 下一页

3.11 对齐: 从「会补全」到「肯听话」

RLHF(Reinforcement Learning from Human Feedback)・ChatGPT 真正的秘密武器

- GPT-3(2020)早已博学, 可你问它问题, 它常回你更多问题——它只会**续写**
- 三步调教(右图):**SFT** 人写示范→**奖励模型**人排好坏→**强化学习**按偏好优化
- 这就是 RLHF, 即基于人类反馈的强化学习——**ChatGPT = GPT-3.5 + 对齐**: 能力没大变,「能用」了

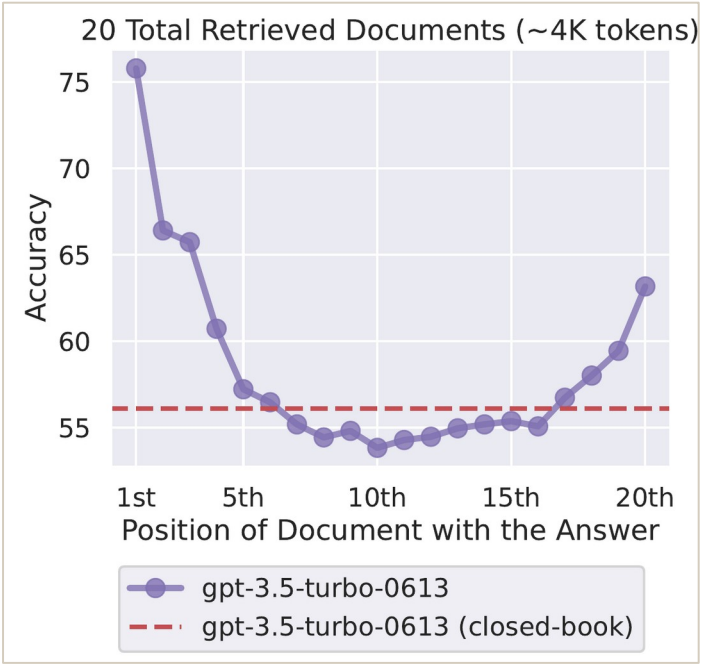


RLHF 三步(论文图・转引)

实用直果 下开源模型认准-Instruct / -Chat 后缀——base 版没对齐, 拿来即用会怀疑人生

3.12 上下文窗口: 模型的工作记忆

- 所谓**上下文窗口**(Context Window), 是指一次对话里模型**能同时看见**的 token 上限
- 量级:8K ≈ 长文 · 128K ≈ 中篇小说 · 1M ≈ 一小柜文档
- 陷阱一: 窗口大≠都记牢——**中间最容易被忽略**(右图)
- 陷阱二: 塞得越满, **越贵越慢**



答案埋在中间, 准确率垫底(论文图 · 转引)

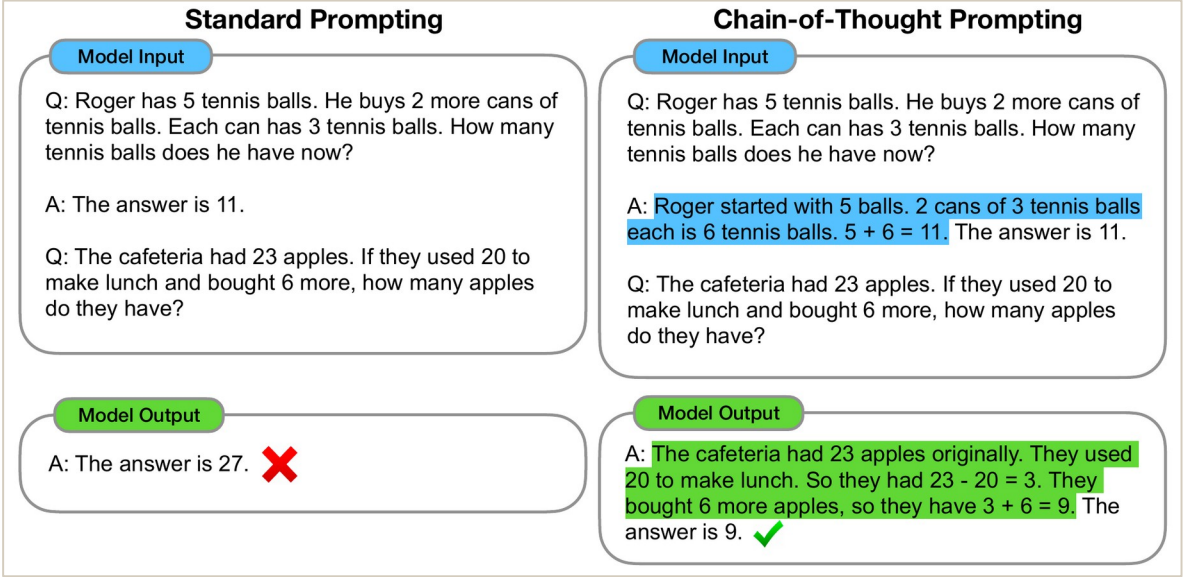
方案直觉 「把全公司文档塞进窗口」不是方案, 是账单——检索出相关几段再塞才是(D4)

顺手一算 中文 1 字≈1–2 token ——刚学的分词, 在这里第一次派上用场

3.13 推理模型: 先打草稿, 再给答案

从思维链(Chain-of-Thought,CoT)到 o1 / DeepSeek-R1

- 发现(2022):提示里让模型「一步步想」, 数学题正确率暴涨——**思维链**(右图)
- 升级(2024–25):o1 / R1 把「打草稿」内化成训练目标——答题前先生成长长的推理过程
- 代价: 更慢、更贵——**闲聊客服用不着, 数学、代码、规划才值得**



思维链提示对比(论文图・转引)

选型预告 「快思考」与「慢思考」模型按任务混用——成本课上给它算笔账

3.14 一句话进大模型的完整旅程

把本节所有零件装回一条链

- **进**: 你的话 + 系统提示词→分词成 token → 变向量; **算**: 几十层加工→采样
- **出**: 逐 token 流式蹦回屏幕——「打字机」式答案由此而来
- 三个商业事实都挂在这条链上:**按 token 计费 · 首字延迟 · 上下文上限**



一句话的旅程: 红色回环就是「逐 token 生成」(重制)

D3 预告 后端课上, 这条链的每个环节对应 API 的一个参数——今天看懂, 那天上手

3.15 大模型会一本正经地错

两个三十秒的演示, 胜过一小时说教

算错还很自信:

算缺角矩形周长, 步骤头头是道, 答案错了——「**你就说快不快吧!**」

不认识自己:

拿平台自家 logo 问「这是谁家的」, 答不出——没有实时知识, 也没有「自我」

三个推论 要接外部知识(D4 RAG)・要接工具(D7 Agent)・要建评测(D7 Evals)

预热五问 Q2 「AI 会不会错」——会, 而且理直气壮; 方案的价值在于兜住它

3.16 幻觉: 它不是在撒谎, 它在补全

- 根源一: 模型的世界里只有「像不像」, 没有「真不真」——**概率补全没有真值表**
- 根源二: 训练数据有边界——问它数据之外的事(比如你公司的产品), 它只能编得像
- 根源三: 对齐教它「有问必答」——宁可编一个, 也不肯冷场(除非你明确允许它说不知道)

重要结论 所谓**幻觉**(Hallucination), 就是把「最像的」当「对的」说出来——是属性, 不是故障

提示词急救 在系统提示词里写明「不确定就说不知道」, 幻觉立减一档——下午可以试

3.17 多模态: 模型长出了眼睛和耳朵

- 视觉模型看完一段「奇幻动物」视频, 能完整解读: 长颈鹿 + 火烈鸟、鲸鱼 + 章鱼……**模型真的「看懂」了**
- 所谓 **MLLM**(Multimodal LLM), 即多模态大模型: 文本、图像、语音进同一个模型——主流押注的 AGI 路径之一
- 对你意味着: 客户的需求正从「能聊」升级为「能看单据、能听录音」

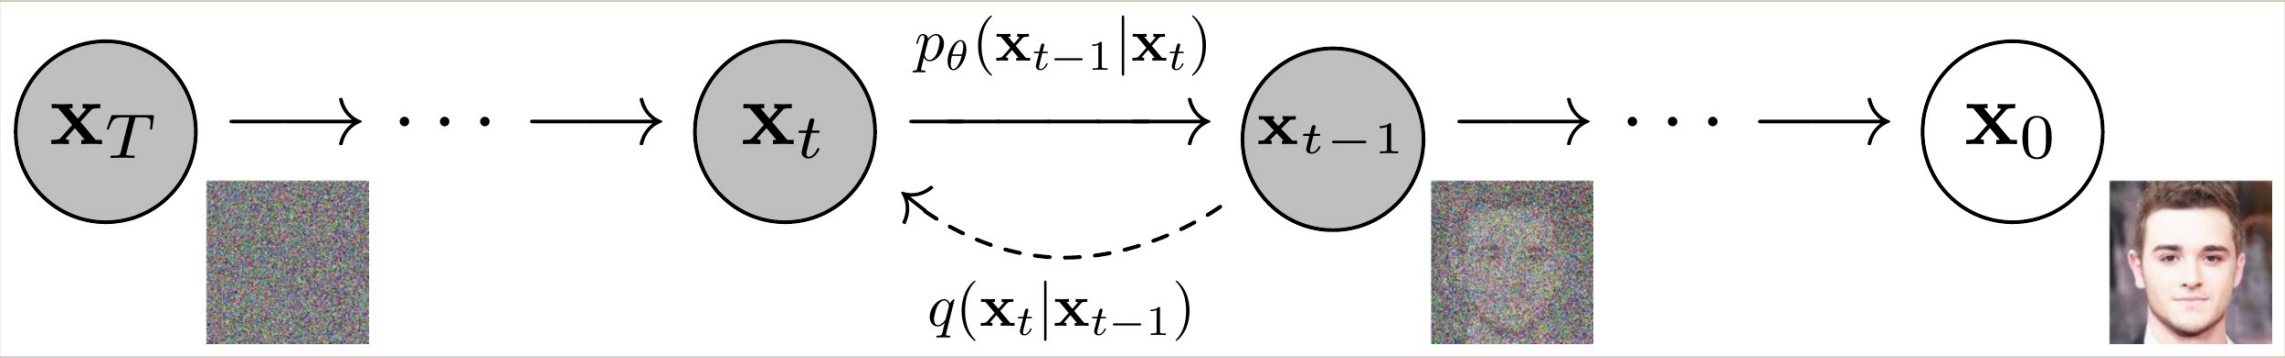


看懂之外, 还能生成(转引)

伏笔 D3 后端课接多模态 API, 你的智能客服会「看图」

3.18 文生图白话:CLIP 懂话, 扩散作画

- **CLIP**(2021):用 4 亿「图-文」对练出一双眼睛——图和话在同一空间里比远近
- 所谓**扩散模型**(Diffusion Model, 下图), 就是训练时把图一步步加噪成雪花、学会**反着走**的模型——生成 = 从纯噪声一步步「去噪」出画
- 文字经 CLIP 变成方向盘, 扩散照着方向去噪——「一句话出图」的全部秘密



右向加噪、左向去噪的马尔可夫链(论文图・转引)

顺口溜 CLIP 懂话, 扩散会画; 话给方向, 噪里出画——视频生成是它在时间轴的延伸

04

能力边界与责任

能力越强, 越要知道它在哪儿会翻车

4.1	双刃剑: 每一项能力都有影子	55
4.2	给客户设预期	56
4.3	隐私泄露的三条路径	57
4.4	深度伪造: 眼见不再为实	58
4.5	电车难题: 机器有道德选择权吗	59
4.6	一线合规常识: 两部规矩, 一条红线	60
4.7	负责任的 AI	61
4.8	三道思辨题, 留给午饭	62

4.1 双刃剑: 每一项能力都有影子

六个战场, 正反各一句

战场	亮面	影子
自动化	生产效率跃升	岗位替代焦虑
推荐算法	千人千面的服务	偏见、歧视与信息茧房
数据建模	医疗、科研提速	隐私滥用
AIGC	创作平权	造假与学术诚信危机
个性教学	因材施教	教育资源新鸿沟
智能机器	交通、制造升级	自主武器与事故责任

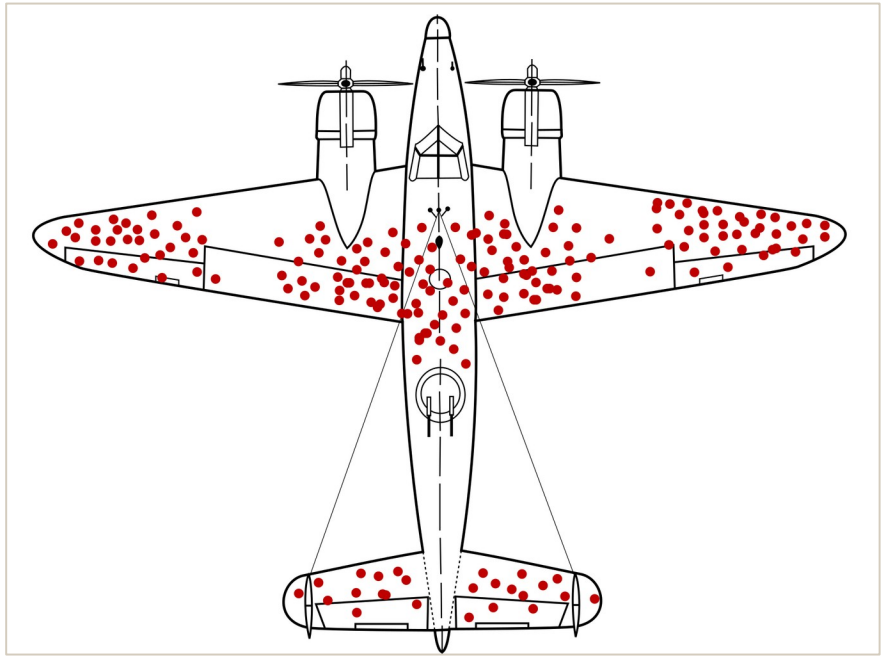
- 这张表并不是伦理课作业: 表里的每一行, 都可能变成客户会议室里的一句质疑。

FDE 姿势 若正反都讲, 则是专业; 若只讲亮面, 则是销售——客户分得出来

4.2 给客户设预期

三句压舱石

- **AI 系统没有 100% 正确率**——传统程序做得到, 机器学习做不到; 方案要谈的是准确率、边界与兜底。
- **模型的局限多源自数据筛选**——最出名的是幸存者偏差(Survivorship Bias, 右图); 一切结论都默认「训练数据代表现实」。
- **模型可以复制, 数据不可复制**——客户最值钱的资产是数据, 这也是劝他自建知识库的理由。



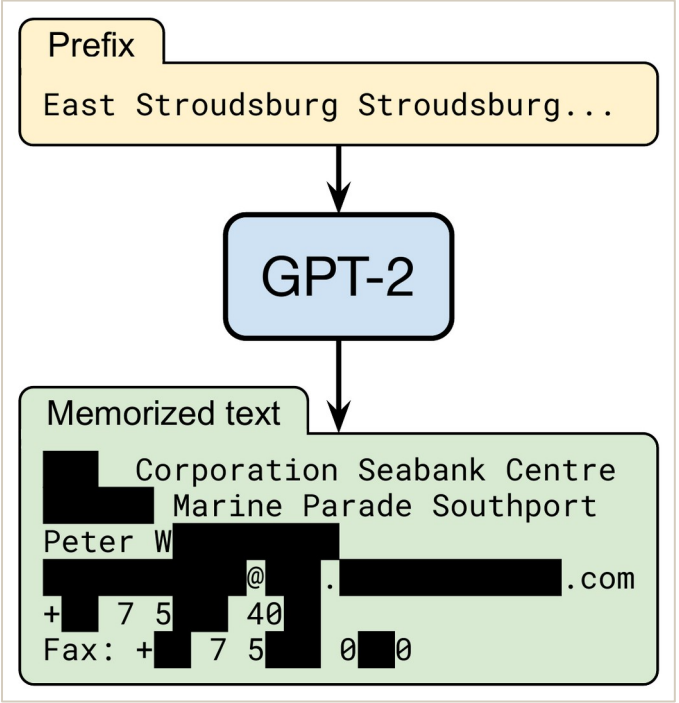
该加固的是没弹孔的地方(转引)

预热五问 Q2 收一半 会错 + 错多少可测 + 错了有兜底——至于怎么测, 留给 D7 补全

4.3 隐私泄露的三条路径

有论文实锤

- **训练数据被吐出来**: 研究者用前缀诱导 GPT-2 逐字吐出真人姓名、电话与邮箱(右图, 论文原文已打码)。
- **生成即复现**: 文生图模型可能近乎原样复现训练集里的照片。
- **AI 当帮凶**: 大模型把「搜集拼接已泄露信息」的成本压到趋近于零。



GPT-2 训练数据提取(论文图 • 转引)

FDE 三问 客户数据进模型前先问: 能不能出域? 要不要脱敏? 合同里怎么写?——预热五问 Q4 先收一角

4.4 深度伪造: 眼见不再为实

- 所谓深度伪造(Deepfake), 就是用 AI 伪造人脸与声音: 换脸短剧、克隆声音的诈骗电话, 门槛已低到人人可为。
- 斯坦福 2017 年实验发现: 面对网上真假信息, 历史学家和大学生都栽了, **只有职业事实核查员过关**, 靠流程不靠眼力。
- 工程对策: 生成内容嵌水印、平台配检测工具、发布流程保留人工审核位。

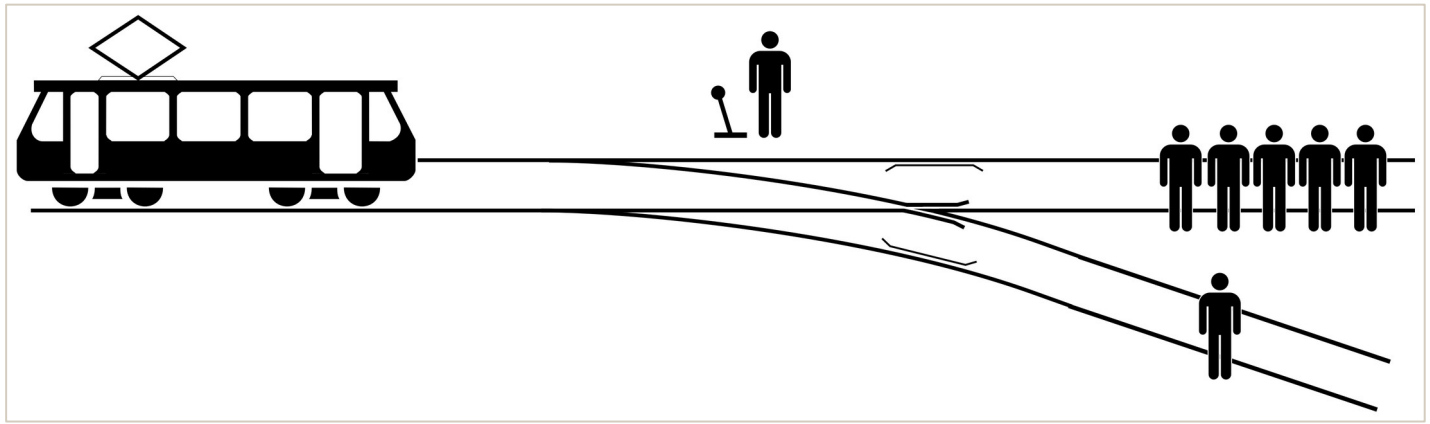


同一张脸的真身与四种伪造(论文图・转引)

交付红线 《深度合成管理规定》要求 AI 生成内容须显著标识——生成出口, 标识和审核位是标配

4.5 电车难题: 机器有道德选择权吗

- **电车难题**(Trolley Problem): 扳道吗? 撞一人救五人(下图)——哲学吵了六十年没吵完
- 思考: 自动驾驶危急瞬间保行人还是保乘客? 这不是思想实验, 而是产品参数
- 工程共识是**高风险决策, 人必须在环**: 机器建议、人拍板, 责任写进合同



电车难题(CC 转引)

方案落点 给客户画系统边界时, 先画「哪些决定永远留给人」——这条线画得清, 单子签得下

4.6 一线合规常识: 两部规矩, 一条红线

以现行有效版本为准 · 方案书必有「合规」一节

- 《生成式 AI 服务管理暂行办法》(2023.8, 下图) 规定: 面向公众的服务须**备案**, 内容责任在服务方
- 《深度合成管理规定》(2023.1):AI 生成内容须**显著标识**
- 数据出境还有安全评估门槛, 不是「买个国外 API」那么简单



官方发布页(截图)

一条红线 客户数据不出域是很多行业的默认前提——这正是私有化部署(D5)存在的理由

4.7 负责任的 AI

所谓负责任的 AI(Responsible AI), 就是把护栏做进交付物

- **事先**: 数据来源合法、脱敏入库——别让问题进门。
- **事中**靠提示词约束、敏感词与越权拦截, 别让问题出门。
- **事后**有审计日志、兜底话术与责任认定, 问题追得回来。
- 阿西莫夫「三守则」(右图) 是科幻公约而非工程标准, 工程标准是上面三行。



阿西莫夫(公有领域)

预热五问 Q2 再收一角 「AI 会不会出错」的完整答案 = 边界(上文)+ 兜底(本页)+ 度量(D7)

4.8 三道思辨题, 留给午饭

没有标准答案, 但面试官和客户都可能问

- **思考一**:AI 是工具还是伙伴? 你对它说过「谢谢」吗, 为什么?
- **思考二**: 算法出了偏见, 该由谁负责——写规则的、供数据的、拍板上线的, 还是模型自己?
- **思考三**: 中文屋(Chinese Room) ——只照规则搬符号的大模型, 到底「理解」了没有? 这重要吗?

为什么聊这个 价值观题没有对错, 但有「想过」和「没想过」的区别——D8 答辩、D10 面试都可能撞上

05

2026 大模型格局

看清牌桌上都有谁, 再决定跟谁玩

5.1	2026 大模型格局	64
5.2	闭源三家: 各自的人设	65
5.3	开源梯队: 免费的午餐, 有菜单	66
5.4	为什么国产模型是你的主战场	67
5.5	工具层:AI 原生开发的两代工具	68
5.6	今晚的作业从注册开始: 平台清单	69
5.7	行业一年三变, 怎么不掉队	70

5.1 2026 大模型格局

三层看清楚——闭源模型、开源模型与工具层

层	玩家	你该知道
闭源模型	GPT / Claude / Gemini	能力顶尖, 按 token 计费
开源模型	DeepSeek / Qwen / Llama / GLM	可私有化, 中文生态强
工具层	Claude Code / Codex / Cursor	AI 原生开发, 你的吃饭家伙

- 合规提醒: ChatGPT 等国外服务在国内使用受限, **给客户做方案时必须考虑**。
- 国产开源(DeepSeek、Qwen) 已站上第一梯队, 是私有化(Private Deployment)方案的底气所在。

预热五问 Q3 「选 GPT 还是 DeepSeek」的答案在下一节, 先记住格局。

5.2 闭源三家: 各自的人设

能力会随版本漂移——记住「长期气质」, 用时以实测为准

家	长期气质	你常在哪用到
OpenAI ・GPT	生态最大, 通用旗舰	通用问答、多模态
Anthropic ・Claude	代码与长文档见长, Agent 工具链全	Claude Code、写代码
Google ・Gemini	超长上下文、多模态, 绑谷歌生态	视频理解、检索融合

- 三家的共同点是**按 token 计费**且国内直连受限, 给国内客户做方案时这是硬约束。

提醒 「哪家最强」每季度换人, 面试答这题的正确姿势是「分任务说 + 我实测过」。

5.3 开源梯队: 免费的午餐, 有菜单

开放权重(Open Weights)≠随便商用——先看许可证

- **DeepSeek** 推理强、许可宽松(MIT), 正是 2025 年初的那声惊雷。
- **Qwen(通义)** 家族尺寸最全, 居中文生态第一梯队, 多为 Apache 2.0。
- **Llama(Meta)** 是国际生态的基石, 但走「社区许可」, 商用有条件。
- **GLM(智谱)** 常驻国内私有化项目。



开源模型的货架(截图)

FDE 必修 给客户选开源模型, 第一眼看能力, 第二眼必须看 LICENSE, 法务问起你要答得上。

5.4 为什么国产模型是你的主战场

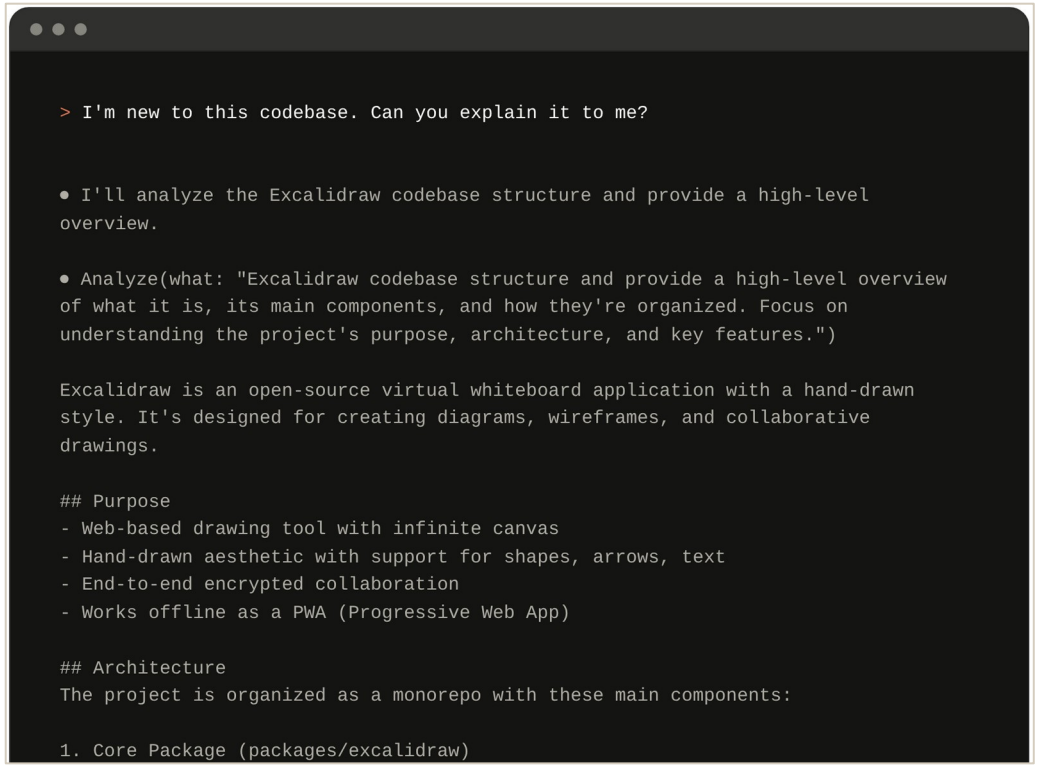
思考: 海外旗舰更强, 为什么吃饭靠国产?

- **合规**: 境内面向公众的服务必须用**已备案**模型, 国外 API 直接服务 C 端是一条红线。
- **中文**: 在中文语料与文化语境上, 国产模型常见反超, 下一节横评就有例子。
- **价格**: 同档能力下, 国产 API 单价常低一个量级, 成本课上会算给你看。
- **私有化**: 开源权重加国产硬件适配, 才进得了政企机房。

重要结论 通用天花板看海外, 落地主战场在国产; 两边都要熟, 吃饭靠后者。

5.5 工具层:AI 原生开发的两代工具

- **补全型**(上一代) 是指你写代码, 它替你接下半句。
- **代理型**(当下) 则是 Claude Code、Codex、Cursor: 你说目标, 它**读文件 • 改代码 • 跑命令**, 看报错再改(右图)。
- 角色随之变化: 你从「打字的人」变成了「验收的人」。



代理循环实况(官方文档截图)

本营选择 以 Claude Code 为主(一线团队常用), Codex 做第二意见, 今天稍后的装机课上手。

5.6 今晚的作业从注册开始: 平台清单

平台	直连	用途分工
DeepSeek	国内直连	推理、代码, 今晚必注册
通义 / Kimi / 豆包	国内直连	长文阅读、日常问答
ChatGPT / Claude / Gemini	视网络条件	对照体验海外旗舰

- 使用时要留心: 同一个问题丢给两家, **对比着看**, 选型的手感就是这样攒起来的。

最低要求 国内平台今晚至少注册三家, 明天前端课第一小时就要用。

5.7 行业一年三变, 怎么不掉队

- **一手信息**: 指各家的官方发布与技术报告; 新模型出来, 先读官方自己怎么说。
- **榜单**: 指 LMArena 等第三方竞技场, 只可当参考、不可当圣旨, 下一节有定理。
- **社区**:HuggingFace 趋势榜与技术社区周报, 是开源世界的风向标。
- 用法: **每天 20 分钟**, 只追「和手头任务有关」的更新; 全追等于不追。

呼应 每早的「AI 快讯轮值」就是这 20 分钟的集体版, 轮到你那天别拉胯。

06

模型选型与成本测算

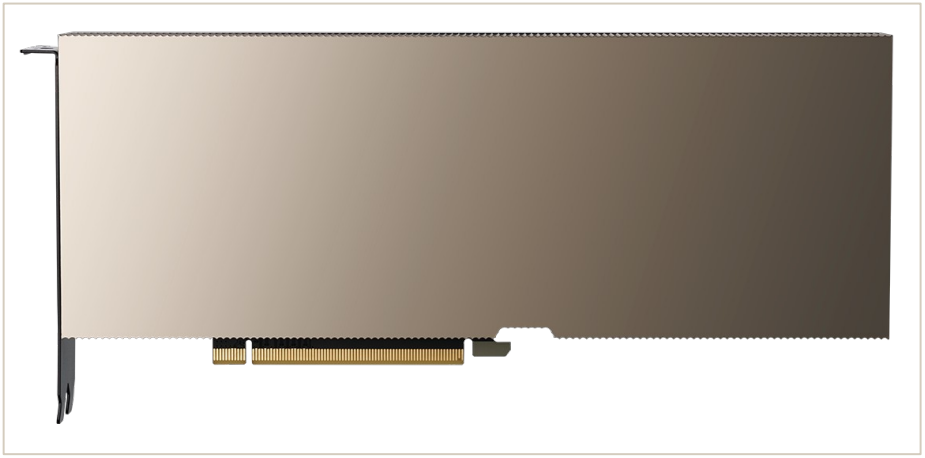
没有免费的午餐: 选型必须按任务实测

6.1	先看清成本的量级: 大模型为什么这么贵	72
6.2	选型的理论依据: 没有免费的午餐	73
6.3	一个横评案例: 榜单第一≠你的任务第一	74
6.4	榜单地图: 四份权威榜, 四种口径	75
6.5	性价比象限: 智力和账单放在同一张图上	76
6.6	模型多大, 要多少资源: 先有体感	77
6.7	显存怎么估: 一条经验公式走天下	78
6.8	FDE 选型五问: 接到需求先过一遍	79
6.9	把账算出来: 一个智能客服的月账单	80
6.10	DeepSeek 4: 一共就两款, 把价目读透	81
6.11	GLM 全系: 一张价目表读出产品策略	82
6.12	API 还是私有化: 一张决策表	83
6.13	模型不够强怎么办: 三条增强路线	84
6.14	微调白话: 五种方式, 一张表	85
6.15	RAG 三分钟预览: 检索增强生成	86

6.1 先看清成本的量级: 大模型为什么这么贵

以 GPT-4(2023)为参照 · 三个数字均为业界估算口径, 量级至今成立

13 万亿	token 总量——互联网读一遍
1.8 万亿	参数规模(官方未公布)
7800 万美元	一次完整训练的成本量级



算力的长相: 一张 A100(官方图)

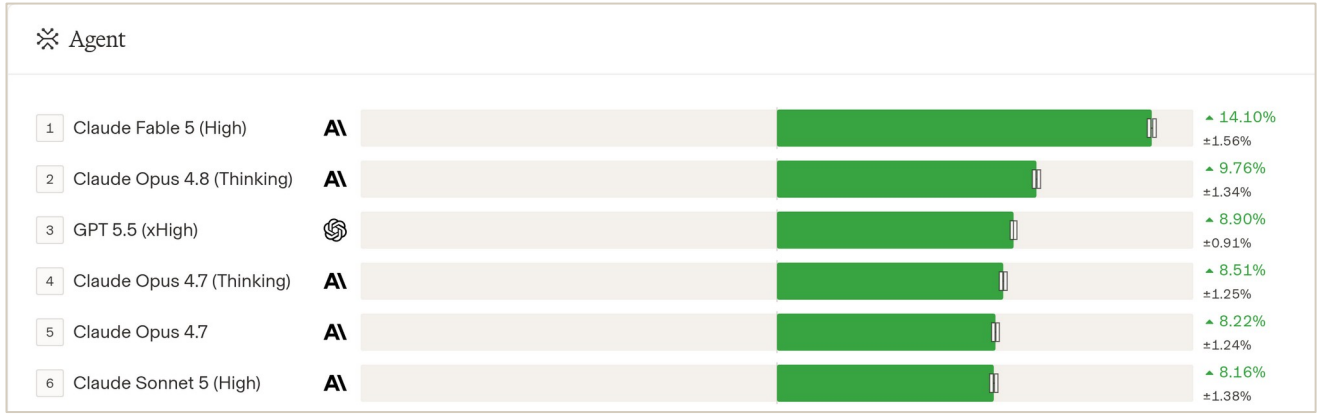
- 行业分工: 巨头炼模型, 企业**租**模型(API)或**养**小模型(私有化)

客户话术 客户若问「为什么不自己训一个」, 这页的三个数字就是答案

6.2 选型的理论依据: 没有免费的午餐

No Free Lunch,NFL · Wolpert & Macready, 1997

- NFL 定理是指: 若 A 赢在这类任务, 则必输在另一类——**不存在全能最优**。
- 推论一: 没有「最好的大模型」, 只有「最适合这个任务的模型」。
- 推论二: 榜单分数测的是别人的任务; **你的任务, 必须你自己测**。



LMArena Agent 榜 · 2026.07(截图)

选型第一原则 具体问题具体分析, 听起来像废话, 但它有定理背书。

预热五问 Q3 收口 「选 GPT 还是 DeepSeek」的答案就是: 凭任务实测选「最适合的」, 不凭榜单。

6.3 一个横评案例: 榜单第一≠你的任务第一

同一道题实测:「写一首人工智能主题的五言绝句」· 2026 春口径, 版本以当时为准

结果	模型	说明
合格	文心一言 · GPT-4 · 通义千问	格律正确
不合格	Claude · GPT-4o mini · Gemini 等	格式或格律出错

- 通用能力顶尖的模型, 在**中文格律**这种具体任务上照样会翻车。
- 由此得出两个结论: 一是任务级实测不可省; 二是**中文场景, 国产模型可能反超**。

伏笔 D7 结论会漂移; 到那天把实测做成可重复的评测集与基线对比, 你就拉开差距。

6.4 榜单地图: 四份权威榜, 四种口径

快照 2026-07-12 · 引用榜单必须连日期一起引

榜单	怎么测	当前领跑	国产位置
AA 智力指数	榜方自测 9 套题	Claude Fable 5(60)	GLM-5.2 51, 国产最高
LMArena 总榜	真人盲测 Elo	claude-fable-5(1509)	开源子榜 GLM-5.1 居首
LMArena Agent	真实会话遥测	Claude Fable 5	GLM-5.2 第 10
SWE-bench	第三方提交实测	脚手架+Claude 4.5(79.2%)	GLM-5 72.8%(bash 榜)

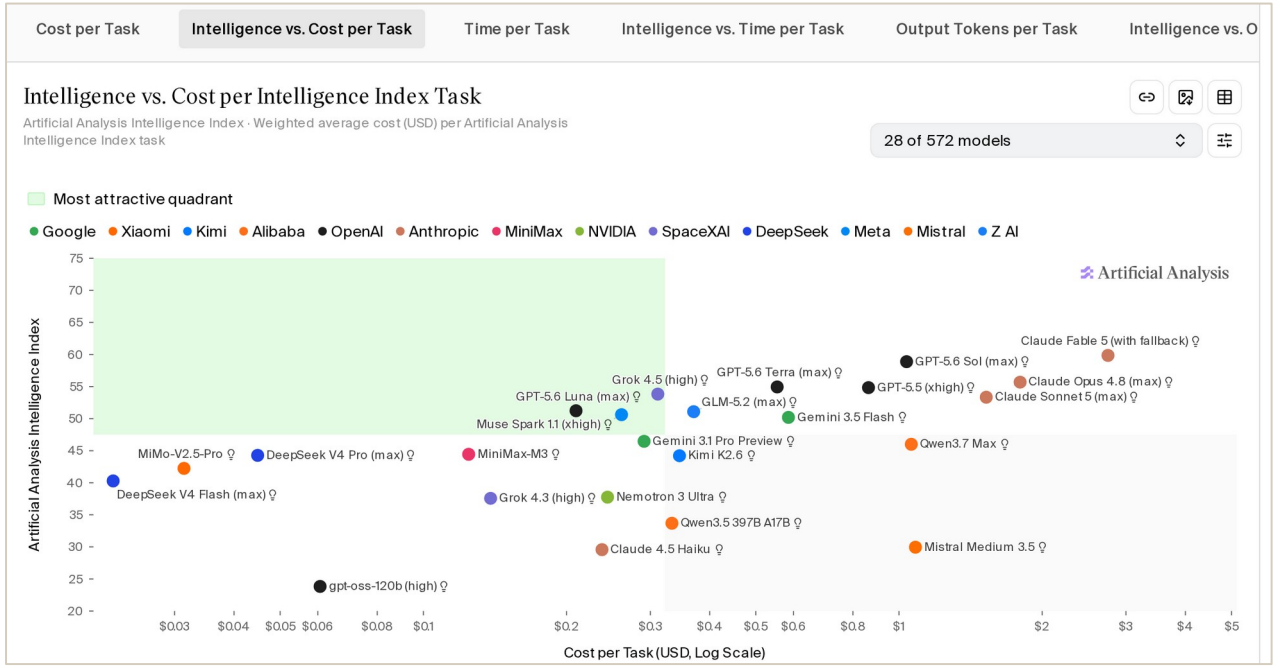
- **榜方自测 · 真人众测 · 提交实测**是三种不同口径, 分数互相之间不可比。
- 思考: **当下旗舰为什么都没上** SWE-bench? 因为收录停在 2026-02, 引用榜单要先看更新日期。

读榜第一课 先看「谁在测、怎么测、测到哪天」, 再看分数; 这是一道面试分水岭。

6.5 性价比象限: 智力和账单放在同一张图上

Artificial Analysis 智力 × 每任务成本 · 2026-07-12 快照

- 纵轴买能力, 横轴花预算: 最高点是 Fable 5, **最智也最贵**($2.75 / 任务)
- 全场最便宜:DeepSeek V4 Flash(40 分 · $0.02)——便宜百倍, 够用就是赢
- 高性价比带代表:GLM-5.2(51 分 · $0.37), 国产旗舰的典型站位



智力-成本象限(榜单截图 · 转引)

选型直觉 客户要的答案通常落在左上象限(够聪明又便宜), 很少是图上的最高点。

6.6 模型多大, 要多少资源: 先有体感

体积按 4bit 量化(Quantization) 下载包计 · 全精度约再乘 4

参数量	体积参照	跑在哪	典型用途
0.2 B	约 0.2 GB	手机也行	玩具与教学
1.5 B	约 1.1 GB	无 GPU 笔记本	轻量本地助手
8 B	约 4.7 GB	单张消费级显卡	私有化常客
数百 B	数百 GB	服务器集群	旗舰 API 背后

- 现场跑一个试试: `ollama run deepseek-r1:1.5b`, 一台笔记本就能养起本地模型。

伏笔 D5 到私有化部署日, 我们会用 Ollama / vLLM 正经把开源模型架起来。

6.7 显存怎么估: 一条经验公式走天下

客户报出显卡型号, 你要能秒答「能跑什么」

- 【例 6-1】客户报来一张 4090(24 GB),14B 能跑吗?
  解:(1)**显存 ≈ 参数量 × 每参数字节 × 1.2**, 留两成余量;
- (2)每参数字节 FP16=2 ・INT8=1 ・INT4=0.5;(3)查表:INT4 约 8 GB, 从容

模型	FP16	INT4	落点
8 B	约 19 GB	约 5 GB	消费卡(8 GB)跑量化版
14 B	约 34 GB	约 8 GB	单张 4090(24 GB)从容
70 B	约 168 GB	约 42 GB	多卡服务器起步

再留一手 并发与长上下文还要吃缓存; 生产部署的余量怎么留,D5 现场教

6.8 FDE 选型五问: 接到需求先过一遍

- **任务**是什么? 生成、抽取、问答还是多模态, 这决定模型类型。
- **数据**有多敏感? 能出域就走 API, 不能出域就走私有化(预热五问 Q4 先收一半)。
- **预算**多少? 先按 token 估算月账单, 再对比私有化的显卡与运维。
- **延迟**要求多高? 在线客服要秒回, 离线分析可以慢慢算。
- **合规**约束呢? 行业监管、国产化要求, 有时直接锁死选项。

成本测算起手式 业务量 → token 量 → 单价 × 用量 = 月账单; 接需求先过一遍,D5 正式开算。

6.9 把账算出来: 一个智能客服的月账单

方法比数字重要 · 单价以官网当日为准

- 【例 6-2】日均 1000 会话 × 8 轮 ×(输入 800 + 输出 150)token, 月账几何?
- 解:(1)月输入约 1.9 亿、输出约 3600 万;(2)按下图单价一乘: 同档旗舰**输入差 5–6 倍, 输出差 6–11 倍**。

Flagship models

Our latest models

Prices per 1M tokens.

Model	Short context Input	Cached input	Cache writes	Output
gpt-5.6-sol	$5.00	$0.50	$6.25	$30.00
gpt-5.6-terra	$2.50	$0.25	$3.125	$15.00
gpt-5.6-luna	$1.00	$0.10	$1.25	$6.00
gpt-5.5	$5.00	$0.50	-	$30.00
gpt-5.5-pro	$30.00	-	-	$180.00

OpenAI 定价页(截图)

MODEL		deepseek-v4-flash(1)	deepseek-v4-pro
PRICING	1M INPUT TOKENS (CACHE HIT)	$0.0028	$0.003625
	1M INPUT TOKENS (CACHE MISS)	$0.14	$0.435
	1M OUTPUT TOKENS	$0.28	$0.87

(1) The model names `deepseek-chat` and `deepseek-reasoner` will be deprecated on 2026/07/24 15:59 UTC. For compatibility, they correspond to the non-thinking mode and thinking mode of `deepseek-v4-flash`, respectively.

DeepSeek 定价页(截图)

省钱正道 简单问题路由给便宜模型, 难题才上旗舰——常见省三至七成

6.10 DeepSeek 4: 一共就两款, 把价目读透

官网 2026-07-12 现价 · 元 / 百万 token · 以当日官网为准

模型	定位	输入	缓存命中	输出
deepseek-v4-flash	经济高吞吐(激活 13B)	1 元	0.02 元	2 元
deepseek-v4-pro	旗舰(激活 49B)	3 元	0.025 元	6 元

- 两款都是 1M 上下文, **思考 / 非思考同价**(默认思考), 推理不再单独卖。
- 旧名 deepseek-chat / reasoner 将于 **2026-07-24 弃用**, 统一映射到 v4-flash 的两个模式。

读价目的门道 缓存命中 0.02 元 vs 未命中 1 元, 差 50 倍; 固定前缀省大钱,D3 见。

6.11 GLM 全系: 一张价目表读出产品策略

open.bigmodel.cn ・2026-07-12 现价・元 / 百万 token

版本	输入	输出	定位
GLM-5.2(新品・1M)	8	28	长任务旗舰
GLM-5.1	6–8	24–28	次旗舰(按输入长度分档)
GLM-5-Turbo	5–7	22–26	旗舰系提速版
GLM-5	4–6	18–22	入门旗舰
GLM-4.7	2–4	8–16	主力中端(双维分档)
GLM-4.5-Air	0.8–1.2	2–8	轻量性价比
GLM-4.7-FlashX	0.5	3	付费轻快档
GLM-4.7-Flash(200K)	免费	免费	**唯一全免费档**

读出策略 免费档引流, 旗舰档挣钱; 给客户选型, 先问预算落在哪一档。

口径 长输入 / 长输出自动跳高档;「限时免费」指缓存存储费, 别读成模型免费

6.12 API 还是私有化: 一张决策表

维度	走 API	走私有化
数据敏感度	数据可出域	数据绝不出域(硬门槛)
前期投入	近乎为零	显卡 + 适配 + 运维
单位成本	量小便宜	量大摊薄后反超
能力上限	旗舰模型随取随用	受限于开源 + 本地算力
运维要求	无	要有人管机器和升级

- 思考:API 与私有化必须二选一吗? 不必, 实战常态是**混合**: 敏感数据走本地模型, 通用能力走 API。

预热五问 Q4 收另一半 客户说「数据绝不能出公司」, 就走私有化或混合; 完整方案 D5 亲手搭。

6.13 模型不够强怎么办: 三条增强路线

今天记住类比 · D4/D5 动手

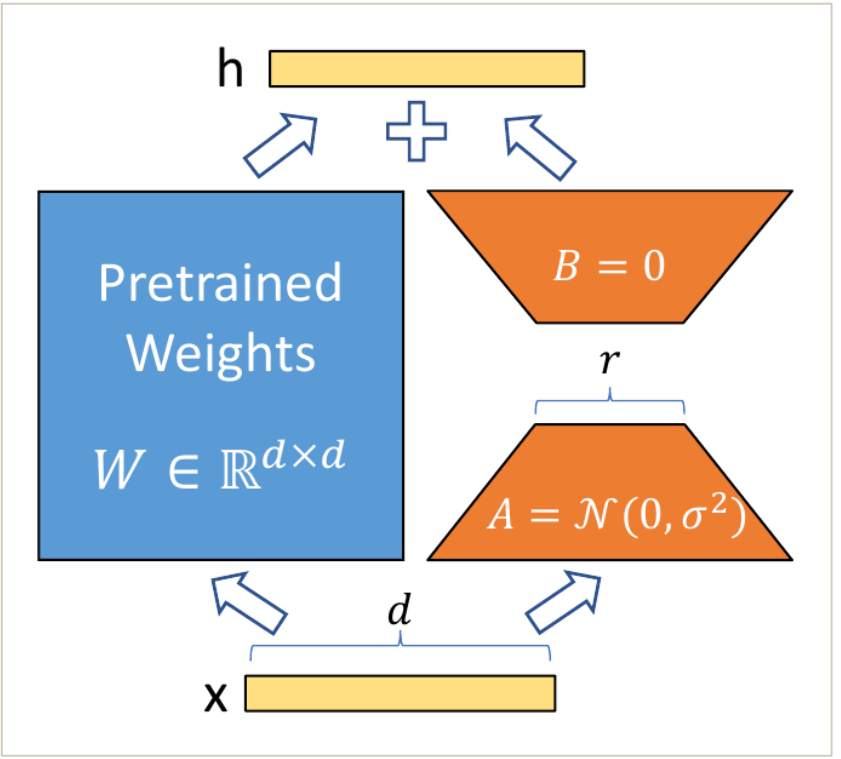
路线	类比	适用
提示词工程	把任务布置清楚	零成本起步, 立即可用
RAG 检索增强	开卷考: 发资料再答题	知识常更新, 要可溯源
微调	闭卷考: 先背进脑子再上场	任务固定, 有标注数据

- 顺序有讲究: **先提示词, 再 RAG, 最后才考虑微调**, 成本依次抬升。

客户话术 「开卷考 / 闭卷考」这组类比, 给客户讲方案时可以直接用。

6.14 微调白话: 五种方式, 一张表

方式	一句话	成本
全参微调	全身大手术	极高
部分微调	冻大半, 动几层	高
PEFT / LoRA	旁挂小电路(右图)	中(单卡可为)
提示词微调	只学「软提示」	低
RLHF	按人类偏好对齐	极高



LoRA: 冻结 W, 只训旁路 A · B(论文图 · 转引)

- **微调**(Fine-tuning) 的门票不是算力而是**数据**——客户喊微调, 先问「数据在哪」

面试高频 何时微调? 任务固定、提示词与 RAG 穷尽、有标注数据——齐了才动手

6.15 RAG 三分钟预览: 检索增强生成

Retrieval-Augmented Generation ・开卷考的完整流程・D4 全天亲手搭

- 五步串成一条线(下图), **向量化**用的正是 Embedding 那张打分表。
- 三大优点直击企业痛点: 知识**随文档更新**, 答案**可溯源**, **数据不动模型**。
- 边界也要讲清: 检索不到就答不出, 切块质量决定一切, 这是 D4 的主战场。

开卷考:先发资料,再答题



RAG 五步: 开卷考的完整流水线(重制)

为什么是第一方案 不训模型、不出数据、周级上线, 这三个词足以说服客户: 低风险。

07

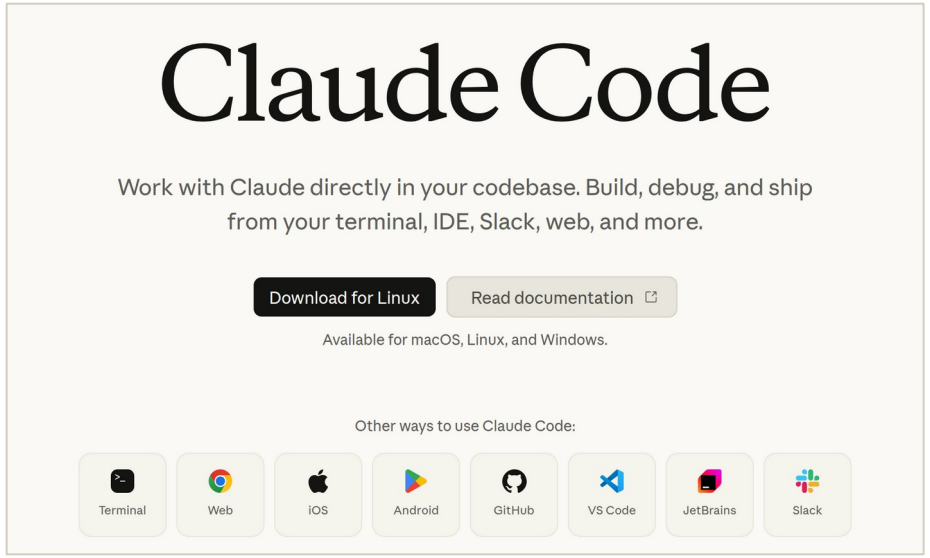
工具链装机

链接会烂, 文档会过时; 会自救, 才算装完机

7.1	今天装什么, 为什么是这一套	88
7.2	VSCode: 为什么编辑器成了主战场	89
7.3	Claude Code: 你的第一位 AI 同事	90
7.4	CC Switch: 给 Claude Code 一键换引擎	91
7.5	命令行(CLI) 不可怕: 先混个脸熟	92
7.6	国内网络生存包: 装机手册「网络篇」	93
7.7	环境隔离: 装包之前, 先进对房间	94
7.8	进对房间: 四条命令的肌肉记忆	95
7.9	git 三分钟: 给作品上保险	96
7.10	装机自救三招 + 提问三要素	97
7.11	提示词进阶: 把三要素写成两层	98
7.12	演示②: 与 Claude Code 第一次对话	99

7.1 今天装什么, 为什么是这一套

- **VSCode** 是主战场, **Claude Code** 是结对的 AI 工程师, **Codex** 负责提供第二意见
- 配套底座是 Node.js 与 Python 环境, 下午实践立刻要用
- 思考: 为什么是这一套? 高校通识课多在教通义灵码, 而不少企业一线团队已在用 **Claude Code** ——你带走的是贴近市场前沿的工具链

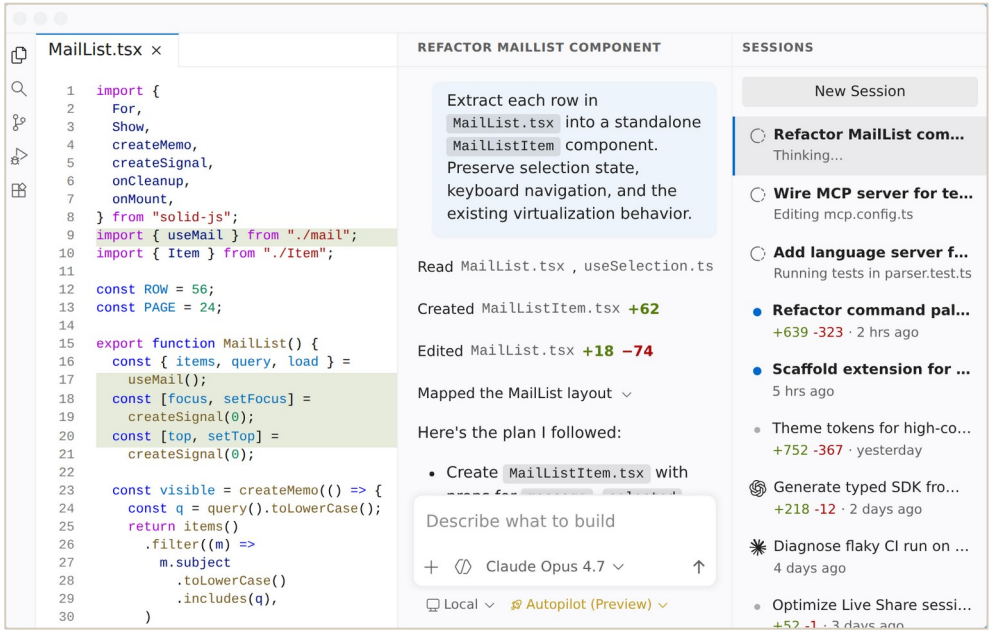


Claude Code 官网(截图)

装机验收 AI 对话、生成文件、解释报错三件事各跑通一次——缺一件都不算装完机

7.2 VSCode: 为什么编辑器成了主战场

- 它早已不只是编辑器, 而是代码 + **集成终端** + 插件生态 + **Remote-SSH** 远程直连的集合体
- 对 FDE 而言, 客户的服务器没有图形界面, **VSCode 一头连你, 一头连机房**
- 今天要装四个插件: 中文语言包、Python、Remote-SSH 与 Claude Code



VSCode(官网图)

重要结论 工具越强越要克制: 十天只用它两成的功能, 但每一样都要练成肌肉记忆

7.3 Claude Code: 你的第一位 AI 同事

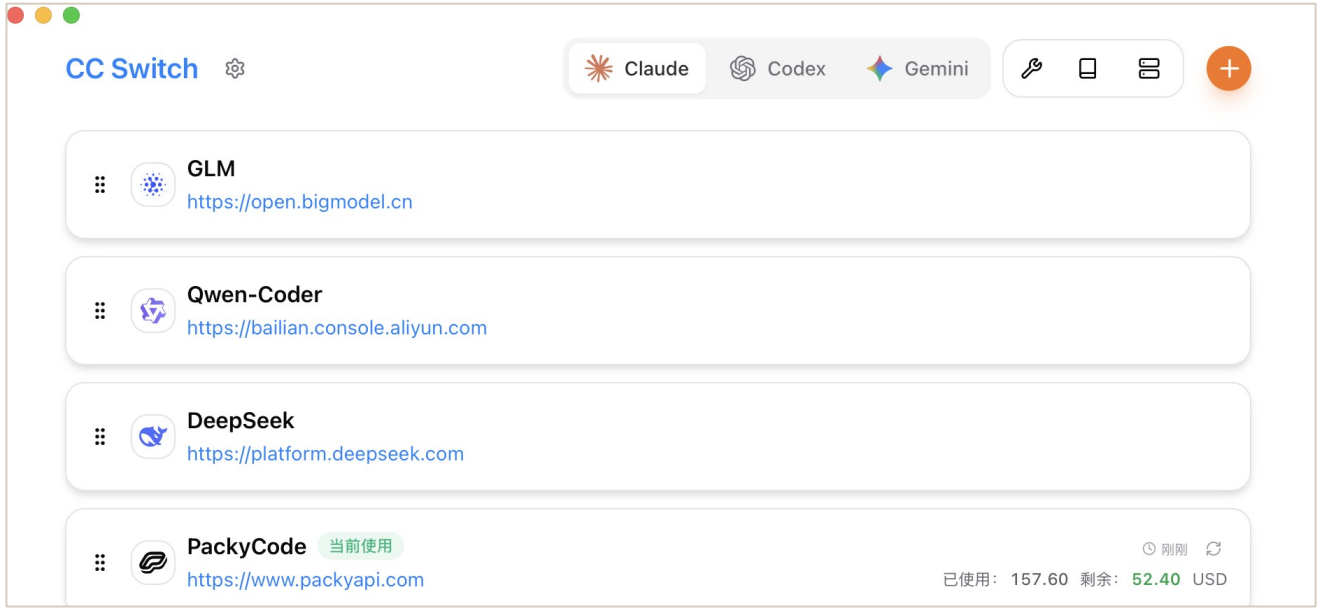
「代理型」工具到底长什么样

- 所谓「代理型(Agentic)」工具, 就是接到任务后**自己读文件、写代码、跑命令、看报错、再修改**的一条龙, 而不是一问一答的聊天窗
- 它自带安全带: 动文件、执行命令之前会**请求你的确认**, 方向盘始终握在你手里
- 相处之道是把它当作**新入职的聪明同事**: 背景交代得越清楚, 产出就越靠谱
- 进阶一步: 在项目根目录放一份「给 AI 看的说明书」, 它每次开工都会先读——D2 细讲

角色转换 从今天起, 你的产出就是「需求描述 + 验收判断」: 代码由它写, 责任由你担

7.4 CC Switch: 给 Claude Code 一键换引擎

- **是什么**: 开源切换器(11 万 + star), **一键切换**模型供应商
- **原理**: 改写 `ANTHROPIC_BASE_URL`, 指向官方兼容端点
- **三步**: 装应用→选预设(GLM / DeepSeek) 填 Key → 热切换免重启



CC Switch 主界面(项目官图・转引)

FDE 场景 断外网、卡预算、要国产: 工具链不换, 只换引擎——工作流直接落地

认准官方 官方仓库 farion1231/cc-switch; 要付费登录的皆仿冒, 第三方中转慎用

7.5 命令行(CLI) 不可怕: 先混个脸熟

客户机房里没有鼠标・今天只求认识, 下午用到再查

命令	干什么	备注
`pwd / ls / cd`	我在哪・有什么・去哪里	走路三件套
`mkdir / cat`	建文件夹・看文件内容	
`grep`	在文件里搜字符串	查案神器
`curl`	命令行发网络请求	D3 调 API 主力
`ssh`	远程登录服务器	进客户机房的门
`pip / npm`	装 Python / Node 的包	各管一摊
`python / node`	运行脚本	

Windows 学员 统一用 Git Bash 当终端(装 git 时自带)——表里命令与后面的环境命令全部可用

不用背 Claude Code 会替你敲——但每一条你都要看得懂, 这是验收者的底线

7.6 国内网络生存包: 装机手册「网络篇」

生态	国内镜像	用法
pip	清华 TUNA / 阿里云 / 中科大	`pip install -i` 镜像地址
npm	npmmirror(淘宝源)	`npm config set registry`
模型	hf-mirror.com	替换 huggingface.co 域名

- 下载模型必须**整目录取全**: safetensors 权重、tokenizer 与 config 三类文件缺一不可

经验 同一个装机脚本, 在公司内网和客户现场往往要换镜像——这是 FDE 的第一课

7.7 环境隔离: 装包之前, 先进对房间

- 所谓环境隔离, 就是给每个项目配一套独立的虚拟环境(Virtual Environment,venv / nvm), 即一个项目一个**房间**
- 房间里有语言运行时、依赖包与配置文件, 换房间互不串味
- 两条铁律: **版本兼容先查后装**(`pip list` / `npm ls`); 装包之前先确认自己在哪个房间

为什么较真 「在我电脑上是好的」是客户现场最贵的一句话, 环境隔离就是它的疫苗

7.8 进对房间：四条命令的肌肉记忆

Python 用 venv 示范 · Node 侧原理相同

- `python -m venv .venv` ——在项目目录里建出房间
- `source .venv/bin/activate` ——进入房间 (Windows:`.venv\Scripts\activate`)
- `pip install -r requirements.txt` ——按依赖清单进货
- `deactivate` ——退出房间

自查动作 装包前先看一眼提示符里的环境名，再用 `which python` 确认——两秒钟能省两小时

Node 侧 nvm 管版本、npx 临时借工具——明天前端课第一次用到

7.9 git 三分钟: 给作品上保险

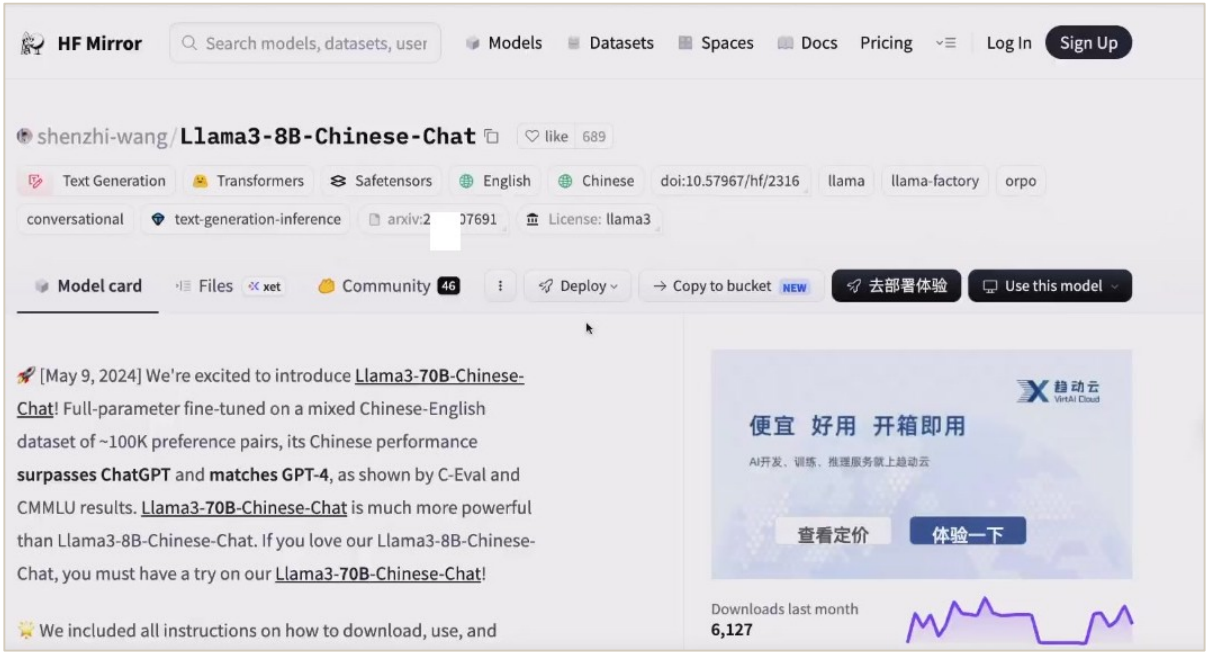
今天只用四条 · 后面几天自然加深

- `git init` 开保险箱→`git add -A` 装箱→`git commit -m "..."` 落锁存档→`git log` 看存档
- 思考: 为什么第一天就要学版本控制(Version Control)? 因为**让 AI 大改代码之前, 先存档**, 改坏了随时能回到上一个存档点
- 招聘方真的会看: 代码仓库的提交历史是比简历更硬的作品集——D9 打包展示

下午的要求 个人主页至少提交三次 commit ——「能回退」要从第一件作品开始养成习惯

7.10 装机自救三招 + 提问三要素

- **下午一定会遇到**: 照教程装, 却发现链接 404、版本对不上——链接会烂, **会搜才是硬技能**(右图: 站内一搜, 原来只差一个连字符)
- **自救三招**: 先读报错原文, 再搜官方文档, 最后问 AI 并贴全报错与环境信息
- **提问三要素**: 你是谁、擅长什么、帮我做什么——系统提示词(System Prompt) 管找对专家;用户提示词(User Prompt) 管问对问题



站内搜索找到的正确模型页(截图)

下午就用 跟 Claude Code 的每一次对话, 都是这三要素的练习

7.11 提示词进阶: 把三要素写成两层

系统提示词管「是谁」; 用户提示词管「做什么」

- **系统层**:「你是资深前端工程师, 只输出可运行的单文件代码」
- **用户层**:「以下是我的自我介绍, 改写成首页文案,100 字内」
- 加分项: **给一个例子**胜过三行形容词; 让它「先复述需求再动手」



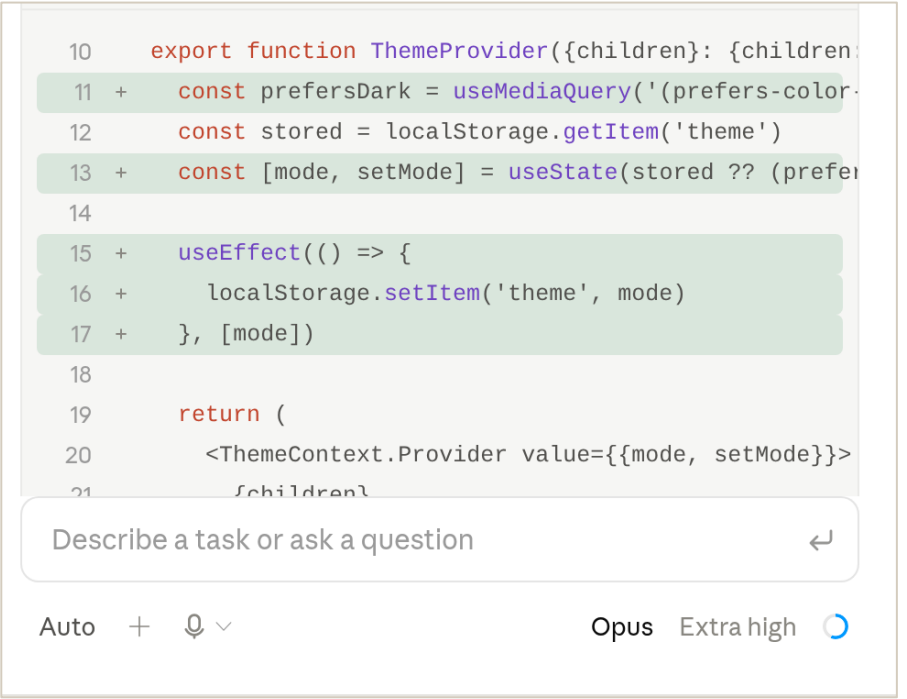
两层各管各的, 拼成一次请求(重制)

记法 坏的问法是「帮我做个网页」; 好的问法是「角色 + 任务 + 约束 + 验收」——四件套齐了, 它才不用猜

7.12 演示②: 与 Claude Code 第一次对话

格式化输出: 从一句话到一个网页

- 演示提示词:「你是资深前端工程师, 擅长响应式页面; 帮我做一个单文件 HTML 个人主页, 深色主题, 含自我介绍与项目卡片」
- 重点看三件事: 怎么**追问需求**、怎么**组织文件**、怎么**解释改动**
- 这就是「提示词驱动开发」: **格式化输出**的产物直接可运行



Claude Code 界面(官网截图)

本质 AI 原生开发就是你出需求与判断, AI 出代码与解释——角色转换从今天开始

08

下午实践·本地 HTML 网页

今天下午，你交付第一件作品

8.1	下午任务: 用 Claude Code 做个人主页	101
8.2	验收细则: 三层各有硬指标	102
8.3	第一轮提示词就写对: 起手式清单	103
8.4	今天下午你大概率会踩的四个坑	104
8.5	今天的收尾与明天的开场	105

8.1 下午任务: 用 Claude Code 做个人主页

13:30–17:00 · 讲师与助教全程答疑

- **任务**: 交付单文件 HTML 个人主页, 含自我介绍、技能清单、项目卡片(先占位)。
- **要求**: 全程用 Claude Code 对话式开发, 每一轮提示词都按三要素来写。
- **三层验收**: 跑通(浏览器能开)→看懂(每段代码能讲)→能改(换色、加一栏)。

这不是练习 这是你作品集的第一块砖——D9 打磨简历时, 它会出现在你的链接里。

预热五问 Q1 收一半 企业雇的不是写代码的人, 而是能带着 AI 交付的人——下午体会。

8.2 验收细则: 三层各有硬指标

下课前助教按这张表逐项打勾

层	指标	怎么验
跑通	浏览器直接打开, 控制台无红字	现场双击
看懂	任抽两段代码, 能说出干什么	助教抽问
能改	现场换主题色 + 加一个栏目	限时十分钟

- 提交物为 HTML 文件、50 字说明(用了什么提示词策略)与**至少三次 commit**。
- 怎么看控制台: 页面右键→检查(或按 F12)→Console 标签, 红字就是报错。

为什么较真 「跑通就行」是学生思维,「讲得清、改得动」才是交付思维, 从第一件作品养成。

8.3 第一轮提示词就写对: 起手式清单

下午每轮对话前, 先照这张单子过一遍

- **角色**: 你是资深前端工程师, 擅长响应式单页。
- **任务**: 做单文件 HTML 个人主页, 含自我介绍、技能清单、项目卡片三块。
- **约束**: 单文件、深色主题, 手机电脑都能看, 不引外部库。
- **验收**: 浏览器直接打开即可用——验收写清楚,AI 会自己对着检查。
- 然后**一轮只加一类需求**: 先骨架→再样式→再细节, 别一口气全要。

通用心法 这张清单不是网页专用, 十天后你写方案、配环境、查 bug, 起手式都是它。

8.4 今天下午你大概率会踩的四个坑

提前打疫苗・踩了别慌, 都有解法

- **一句话要全部**: 一句「帮我做个特别好看的主页」产出必跑偏, 解法是按起手式清单分轮推进。
- **不读代码直接要下一步**: 三轮之后你已看不懂自己的项目, 解法是每轮让 AI 讲解改了什么。
- **改坏了回不去**: 解法是大改前先 `git commit`, 出事就回滚到上一个存档。
- **一报错就举手**: 解法是先走自救三招(读报错→查文档→问 AI), 十分钟没解再叫助教。

说破 这四个坑正是「三层验收」的反面, 坑坑都在把你往交付思维上赶。

8.5 今天的收尾与明天的开场

今天带走什么 · 明天做什么

- 今天你带走三样: 认知坐标系(史 + 原理 + 边界 + 格局)、一套装好的工具链、一份本地跑通的主页。
- 睡前思考: 今天的五问, 你已经能全答两问、半答两问, 对对看是哪几问?
- **明日预告 · D2 前端与 Skill 机制**: 把「会做一个页面」升级成「会造可复用的技能包」, 智能客服官网开工。

每日惯例 明早 9:00 开始 AI 快讯轮值, 第一棒已在群里认领。

明天见

HELLO@DRAGONAI.CN · DRAGONAI.CN
2026